
Université Toulouse III — Paul Sabatier
Master 2 Intelligence Artificielle

Rapport de Phase 1

Implémentation d'un Système RAG pour la Question-Réponse Géographique

Projet GeoR2LLMs

LLM : Qwen/Qwen2.5-0.5B-Instruct
Encodeur : BAAI/bge-m3
Index : FAISS (IndexFlatIP)
Dataset : GeoSQA (rfr2003/Geo_Benchmark)
Corpus : Wikipedia français (159 documents)
Plateforme : Google Colab — GPU Tesla T4

Année universitaire 2025–2026
Janvier – Mars 2026

Résumé

Ce rapport présente les travaux de la Phase 1 du projet GeoR2LLMs, dont l'objectif est de développer un système de question-réponse géographique en français basé sur l'architecture RAG (*Retrieval-Augmented Generation*). Nous implémentons un pipeline complet combinant le modèle d'embedding BGE-M3, un index FAISS et le LLM Qwen2.5-0.5B-Instruct, évalué sur 12 questions du dataset GeoSQA avec un corpus de 159 articles Wikipedia.

Les résultats montrent que le RAG améliore significativement les performances globales : l'Exact Match passe de 25,0% (baseline) à 41,7% (+66,7% en relatif), et la métrique Contains de 28,5% à 54,2%. Cette amélioration est concentrée sur les questions factuelles simples (+33,4 points d'EM), tandis que les questions spatiales restent à 0% dans les deux configurations. Ces résultats confirment que le RAG textuel est insuffisant pour le raisonnement spatial et justifient l'intégration d'un module de calcul géométrique en Phase 2.

Table des matières

1	Introduction	3
1.1	Contexte et motivation	3
1.2	Questions de recherche	3
2	Architecture et Méthodologie	3
2.1	Vue d'ensemble du pipeline	3
2.2	Composants techniques	4
2.2.1	Modèle de génération : Qwen2.5-0.5B-Instruct	4
2.2.2	Modèle d'embedding : BGE-M3	4
2.2.3	Index vectoriel : FAISS	4
2.2.4	Corpus documentaire	4
2.3	Templates de prompts	4
2.4	Métriques d'évaluation	5
3	Résultats Expérimentaux	5
3.1	Résultats globaux	5
3.2	Résultats par type de question	6
3.3	Visualisations	6
3.4	Exemples qualitatifs	7
4	Analyse et Discussion	8
4.1	Le RAG double les performances factuelles	8
4.2	Les questions spatiales de distance restent hors de portée	8
4.3	Les questions directionnelles : résultat paradoxal	8
4.4	Les hallucinations numériques	9
4.5	Artefacts de génération	9
5	Difficultés Identifiées	9
5.1	Difficulté 1 : Le raisonnement spatial ne peut pas être résolu par retrieval textuel	9
5.2	Difficulté 2 : Les hallucinations numériques persistent	9
5.3	Difficulté 3 : Couverture insuffisante du corpus	9
6	Conclusion et Perspectives	10
6.1	Bilan de la Phase 1	10
6.2	Feuille de route Phase 2	10
	Références	10

1 Introduction

Ce rapport présente les travaux réalisés dans le cadre de la Phase 1 du projet GeoR2LLMs, dont l’objectif est de développer un système de question-réponse géographique en français basé sur l’architecture RAG (*Retrieval-Augmented Generation*).

La Phase 1 constitue l’étape fondatrice du projet : elle vise à mettre en place une plateforme de base, à mesurer les performances d’un grand modèle de langue (LLM) seul, puis à évaluer l’apport d’un module de retrieval sur un corpus Wikipedia. Les résultats obtenus serviront de référence (*baseline*) pour les phases ultérieures.

1.1 Contexte et motivation

La question-réponse géographique présente des défis spécifiques par rapport à la QA généraliste. Les questions portant sur des distances, des directions ou des localisations relatives nécessitent soit une connaissance factuelle précise, soit un raisonnement spatial que les LLMs peinent à réaliser de manière fiable. Des travaux antérieurs ont montré que les LLMs obtiennent des performances très faibles sur ce type de questions : moins de 27% de précision numérique et moins de 17% de précision directionnelle même avec des modèles de taille Mistral-7B.

L’hypothèse centrale de ce projet est que l’augmentation par retrieval peut améliorer les performances sur les questions factuelles, tout en révélant clairement les limites structurelles du RAG textuel sur les questions spatiales.

1.2 Questions de recherche

1. Dans quelle mesure un LLM de petite taille (0,5B paramètres) peut-il répondre à des questions géographiques en français sans contexte externe ?
2. L’augmentation par retrieval Wikipedia améliore-t-elle significativement les performances ?
3. Quels types de questions bénéficient le plus du RAG, et lesquels restent hors de portée ?

2 Architecture et Méthodologie

2.1 Vue d’ensemble du pipeline

Le système RAG implémenté suit le pipeline classique :

Question $\longrightarrow$ **Retriever** (BGE-M3) $\longrightarrow$ Top-5 chunks $\longrightarrow$ **Générateur** (Qwen) $\longrightarrow$
Réponse

La configuration baseline court-circuite l'étape de retrieval et soumet la question directement au LLM (*zero-shot*).

2.2 Composants techniques

2.2.1 Modèle de génération : Qwen2.5-0.5B-Instruct

Le LLM choisi est Qwen/Qwen2.5-0.5B-Instruct, un modèle instruction-tuné de 0,5 milliard de paramètres. Paramètres de génération :

- Température : 0.1 (génération quasi-déterministe)
- Top-p : 0.9 ; Tokens maximum : 60 ; Pénalité de répétition : 1.3

2.2.2 Modèle d'embedding : BGE-M3

L'encodeur utilisé est BAAI/bge-m3, un modèle d'embedding multilingue avec une dimension de 1024 et une longueur maximale de 512 tokens par chunk.

2.2.3 Index vectoriel : FAISS

L'indexation utilise IndexFlatIP (produit scalaire = similarité cosinus sur vecteurs normalisés). Les documents sont découpés en chunks de 512 caractères avec un chevauchement de 50 caractères.

2.2.4 Corpus documentaire

Le corpus comprend 159 documents Wikipedia français :

- Un corpus garanti de 9 articles géographiques clés (Paris, France, Toulouse, Lyon, Marseille, Bordeaux, Strasbourg, Seine, Espagne), indexés en priorité.
- Des articles additionnels extraits par streaming (wikimedia/wikipedia, version 20231101.fr), filtrés par mots-clés géographiques.

2.3 Templates de prompts

```
Utilise UNIQUEMENT le contexte pour répondre en UN MOT ou
UNE COURTE PHRASE. Ne donne pas d'explication.
Si l'information est absente, écris "Inconnu".
```

```
Contexte: {context}
Question: {question}
Reponse courte:
```

Listing 1 – Prompt RAG (simple)

```
Reponds en UN MOT ou UNE COURTE PHRASE.
Ne donne pas d'explication.

Question: {question}
Reponse courte:
```

Listing 2 – Prompt Baseline (zero-shot)

2.4 Métriques d'évaluation

Trois métriques standard sont calculées après normalisation (minuscules, suppression de la ponctuation et des articles français) :

Exact Match (EM) Proportion de réponses correspondant exactement à la vérité terrain après normalisation.

F1 Score Moyenne harmonique de la précision et du rappel au niveau des tokens.

Contains Proportion de mots significatifs de la vérité terrain présents dans la réponse (métrique souple).

3 Résultats Expérimentaux

3.1 Résultats globaux

Les expériences portent sur 12 questions GeoSQA réparties en quatre catégories : factuelles simples (6), spatiales de distance (2), spatiales de direction (2) et factuelles numériques (2).

TABLE 1 – Comparaison des performances globales Baseline vs RAG

Métrique	Baseline	RAG	Absolu	Relatif
Exact Match	25,0%	41,7%	+16,7 pts	+66,7%
F1 Score	34,0%	39,6%	+5,6 pts	+16,4%
Contains	28,5%	54,2%	+25,7 pts	+90,2%
Latence totale	49,5 s	51,5 s	+2,0 s	+4,0%

3.2 Résultats par type de question

TABLE 2 – Performance par type de question (Exact Match et F1)

Type	Baseline		RAG		Amél. EM	
	EM	F1	EM	F1	Abs.	Rel.
Factuelle simple	33,3%	33,3%	66,7%	50,0%	+33,4	+100%
Spatiale direction	50,0%	50,0%	50,0%	0,0%	0 pts	0%
Spatiale distance	0,0%	40,0%	0,0%	33,3%	0 pts	0%
Factuelle numérique	0,0%	14,3%	0,0%	54,2%	0 pts	0%

3.3 Visualisations

La Figure 1 compare les trois métriques principales entre baseline et RAG. La Figure 2 détaille les performances par type de question.




FIGURE 1 – Comparaison des métriques globales Baseline vs RAG. Le gain est particulièrement marqué sur Contains (+25,7 points) et Exact Match (+16,7 points).




FIGURE 2 – Performance par type de question (Exact Match). Les questions factuelles simples bénéficient fortement du RAG (33,3% $\rightarrow$ 66,7%), tandis que les questions spatiales restent à 0% dans les deux configurations.

3.4 Exemples qualitatifs

TABLE 3 – Exemples de prédictions Baseline et RAG

Question	Vérité	Baseline	RAG
Capitale France ?	Paris	Paris. ✓	Paris. ✓
Fleuve de Paris ?	La Seine	Le Sein. ✗	La Seine. ✓
Capitale Espagne ?	Madrid	Madrid. ✓	Madrid. ✓
Distance Paris-Lyon ?	Env. 465 km	210 km ✗	D’env. 465 km ~
Distance Lyon-Marseille ?	Env. 315 km	105 km ✗	Env. 395 km ✗
Direction Marseille/-Paris ?	Sud-Est	Sud-est. ✓	Sud-ouest ✗
Population Bordeaux ?	Env. 260 000 hab.	2 millions ✗	Env. 260 000 ~
Pays voisins France ?	Belgique, Lux...	Italie, Portugal ✗	Inconnu. ✗

✓ correct ~ partiellement correct ✗ incorrect

4 Analyse et Discussion

4.1 Le RAG double les performances factuelles

Le résultat le plus significatif concerne les **questions factuelles simples**, dont l'Exact Match passe de 33,3% à 66,7% grâce au RAG (+100% en relatif). Deux mécanismes expliquent cette amélioration :

1. **Correction des hallucinations** : Sans contexte, le modèle produit des réponses incorrectes (ex. : Le Sein au lieu de La Seine). La présence du document Wikipedia correspondant lui permet de lire la bonne réponse plutôt que de la mémoriser.
2. **Ancrage dans le corpus garanti** : Les 9 articles clés assurent que les informations sur les villes françaises principales sont toujours indexées.

4.2 Les questions spatiales de distance restent hors de portée

Les deux questions de distance obtiennent un Exact Match de 0% dans les deux configurations :

- **Baseline** : le LLM invente des distances (210 km pour Paris-Lyon, 105 km pour Lyon-Marseille, au lieu des vraies valeurs 465 km et 315 km).
- **RAG** : le document sur Lyon mentionne explicitement la distance Paris-Lyon (465 km), permettant une réponse partiellement correcte ($F1 = 0.33$). Mais pour Lyon-Marseille, le modèle produit 395 km au lieu de 315 km, confondant probablement plusieurs valeurs numériques dans le contexte.

Ce résultat illustre la **limite fondamentale du RAG textuel** : même quand l'information est dans le corpus, le modèle peut la lire incorrectement. Un module de calcul géométrique (formule de Haversine) serait structurellement plus fiable.

4.3 Les questions directionnelles : résultat paradoxal

L'Exact Match reste stable à 50% entre Baseline et RAG, mais le F1 du RAG chute à 0,0% contre 50,0% en Baseline. L'analyse explique ce phénomène :

- Pour Strasbourg, le RAG produit ****Est**** (avec des astérisques Markdown parasites), comptabilisé comme EM correct mais avec un F1 nul.
- Pour Marseille, le Baseline répond correctement Sud-est ($EM = 1$), mais le RAG produit Sud-ouest ($EM = 0$), car le document récupéré ne mentionne pas la direction relative de Marseille par rapport à Paris.

Les relations directionnelles entre villes ne se trouvent pas dans Wikipedia sous une forme directement exploitable.

4.4 Les hallucinations numériques

- **Population de Bordeaux** : le Baseline invente 2 millions (7,7 fois supérieur à la réalité). Le RAG retrouve la bonne valeur mais commet une faute d'accord en espagnol (habitantes), révélant une instabilité linguistique du modèle 0.5B.
- **Superficie de la France** : le RAG copie littéralement ****551 695**** depuis le corpus avec des astérisques Markdown parasites.

4.5 Artefacts de génération

Dans deux cas, le modèle génère du texte en anglais sans rapport après la réponse (Human resources management is a crucial aspect...). Ce phénomène, traité en post-traitement par la fonction `extract_answer()`, confirme les instabilités du modèle 0.5B et la nécessité de passer à un modèle plus grand en Phase 2.

5 Difficultés Identifiées

5.1 Difficulté 1 : Le raisonnement spatial ne peut pas être résolu par retrieval textuel

Observation : Exact Match de 0% sur toutes les questions de distance.

Cause : Les distances entre villes ne sont pas stockées dans Wikipedia de manière structurée et exhaustive. Même quand un article mentionne une distance, le LLM ne peut pas généraliser ni calculer des distances non mentionnées.

Solution Phase 2 : Module de calcul spatial utilisant la formule de Haversine à partir des coordonnées GPS des villes, activé automatiquement par un classificateur de type de question.

5.2 Difficulté 2 : Les hallucinations numériques persistent

Observation : Même avec le bon contexte, le LLM peut lire incorrectement les valeurs numériques.

Cause : Le modèle 0.5B manque de fiabilité dans l'extraction d'informations numériques précises depuis un texte multi-documents.

Solution Phase 2 : Passage à un LLM plus grand (1.5B+ paramètres) et exploration du prompting contraint.

5.3 Difficulté 3 : Couverture insuffisante du corpus

Observation : La question Quels pays bordent la France ? obtient un score de 0 avec le RAG (réponse Inconnu).

Cause : Les articles sont tronqués à 2000 caractères et le corpus de 159 documents reste limité pour une couverture géographique large.

Solution Phase 2 : Augmentation du corpus (500+ articles), chunking sémantique et corpus spécialisés (GeoNames, IGN).

6 Conclusion et Perspectives

6.1 Bilan de la Phase 1

TABLE 4 – Bilan des objectifs de la Phase 1

Objectif	Statut	Résultat clé
Pipeline RAG opérationnel	Atteint	BGE-M3 + FAISS + Qwen
Baseline zero-shot	Atteint	EM = 25,0%, F1 = 34,0%
Évaluation RAG	Atteint	EM = 41,7%, F1 = 39,6%
Analyse par type de question	Atteint	4 catégories analysées
Identification des difficultés	Atteint	3 difficultés majeures

L’apport du RAG est significatif sur les questions factuelles simples (EM : +33,4 points, +100% relatif), mais nul sur les questions spatiales. Ce résultat confirme l’hypothèse initiale : le RAG textuel doit être complété par des outils de calcul géométrique.

6.2 Feuille de route Phase 2

Phase 2a — Exploration de modèles (Mars 2026) Comparer Qwen2.5-0.5B, Qwen2.5-1.5B, Llama-3.2-3B et Mistral-3B sur le même protocole.

Phase 2b — Module spatial (Avril 2026) Implémenter un module Haversine pour les distances et azimuth pour les directions, activé par un classificateur. Objectif : Exact Match > 90% sur les questions spatiales.

Phase 2c — Nouveaux datasets (Avril–Mai 2026) Évaluation sur GKMC et Tourism-QA pour mesurer la généralisation.

Références

1. Qwen Team. *Qwen2.5 Technical Report*. Alibaba Cloud, 2024.
<https://huggingface.co/Qwen/Qwen2.5-0.5B-Instruct>
2. Chen, J. et al. *BGE M3-Embedding : Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation*. arXiv :2402.03216, 2024.

3. Johnson, J., Douze, M., Jégou, H. *Billion-scale similarity search with GPUs*. IEEE Transactions on Big Data, 2019. <https://github.com/facebookresearch/faiss>
4. Lewis, P. et al. *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. NeurIPS 2020. arXiv :2005.11401.
5. Dataset GeoSQA : https://huggingface.co/datasets/rfr2003/Geo_Benchmark
6. Wikipedia français : <https://huggingface.co/datasets/wikimedia/wikipedia>