

UNIVERSITÉ TOULOUSE III – PAUL SABATIER

MASTER 2 INTELLIGENCE ARTIFICIELLE

IRIT – Institut de Recherche en Informatique de Toulouse

Système Question-Réponse en Géographie avec RAG

Rapport de travail – Phase 1 : Plateforme de base

Projet GeoR2LLMs

Réalisé par :

Mohamed DIALLO

Hiba L'MOUDDEN

Feras MAKHLOUF

Osama BAAZZI

Ousama BOUTEZROUT

Sous la direction de :

Madame Lynda TAMINE-LECHANI

Professeure – IRIT

UE : Chef d'œuvre

Année : 2025–2026

Février 2026

Table des matières

1	Introduction	2
1.1	Contexte et motivations	2
1.2	Objectif de la Phase 1	2
1.3	Organisation du rapport	2
2	Architecture du système	3
2.1	Module Retriever	3
2.2	Module Generator	3
2.3	Module Evaluator	4
3	Méthodologie	4
3.1	Configuration expérimentale	4
3.2	Dataset : GeoSQA	5
3.3	Corpus : Wikipedia français	5
3.4	Protocole d'évaluation	5
3.4.1	Métriques de génération	5
3.4.2	Métriques de retrieval	6
3.4.3	Distinction Accuracy MCQ et Exact Match : pourquoi EM = 0 %	6
4	Résultats expérimentaux	7
4.1	Stabilité du modèle face aux variations de prompt	7
4.2	Comparaison Baseline vs RAG	9
4.3	Métriques de retrieval	10
4.4	Impact de la valeur de K sur les performances RAG	11
4.5	Distribution des scores F1	12
4.6	Analyse qualitative : succès, échecs et catégorisation	13
4.7	Temps d'exécution	15
5	Analyse et discussion	15
5.1	Performance du baseline proche du hasard	15
5.2	Impact limité du RAG : analyse par taux d'accroissement relatifs	15
5.3	Retrieval quasi-inexistant : le facteur limitant	16
5.4	Synthèse des facteurs limitants	17
6	Conclusion et perspectives	17
6.1	Bilan de la Phase 1	17
6.2	Perspectives pour la Phase 2	18

1 Introduction

Le projet GeoR2LLMs (*Geographic Retrieval-augmented generation with Large Language Models*) s'inscrit dans le cadre du chef-d'œuvre du Master 2 Intelligence Artificielle de l'Université Toulouse III – Paul Sabatier, sous la direction de Madame Lynda Tamine-Lechani à l'IRIT. Ce rapport de travail documente l'implémentation et les résultats de la Phase 1 du projet.

1.1 Contexte et motivations

Le Question-Réponse géographique (GeoQA) constitue un défi particulier pour les systèmes de traitement automatique des langues. Mai et al. [9] identifient les questions géographiques comme nécessitant un raisonnement spatial, la compréhension de relations topologiques et l'intégration de connaissances spécifiques au domaine. Cohn et Blackwell [3] montrent qu'aucun LLM actuel ne parvient à raisonner de manière fiable sur les directions cardinales, même avec une température de zéro.

L'architecture RAG (*Retrieval-Augmented Generation*), introduite par Lewis et al. [8] dans le cadre de NeurIPS 2020, propose d'augmenter les LLMs avec des connaissances externes récupérées dynamiquement depuis un corpus. Gao et al. [4] proposent une taxonomie des systèmes RAG distinguant le RAG naïf (retrieve-then-read) du RAG avancé (avec réécriture de requêtes ou re-ranking). Notre implémentation suit l'approche naïve.

1.2 Objectif de la Phase 1

La Phase 1 du projet vise à mettre en place une **plateforme de base** pour le système GeoQA-RAG, conformément au cahier des charges. Les objectifs sont :

1. Implémenter un pipeline RAG complet avec les composants spécifiés (Qwen3-0.6B, BGE-m3, FAISS)
2. Établir une baseline (LLM seul, sans RAG) comme point de comparaison
3. Évaluer l'apport du RAG sur le dataset GeoSQA [5]
4. Mesurer la qualité du retrieval indépendamment de la génération

1.3 Organisation du rapport

La section 2 présente l'architecture du système. La section 3 détaille les choix méthodologiques. Les résultats expérimentaux sont rapportés en section 4 et analysés en section 5. La section 6 conclut et ouvre sur la Phase 2.

2 Architecture du système

Le système repose sur une architecture RAG composée de trois modules : un **Retriever**, un **Generator** et un **Evaluator**. La figure 1 illustre le pipeline.




Figure 1 – Architecture du pipeline RAG. Le corpus Wikipedia est découpé en chunks, encodé par BGE-m3 et indexé dans FAISS. Les questions sont encodées puis les top-K passages récupérés sont fournis comme contexte au générateur Qwen3-0.6B.

2.1 Module Retriever

Le retriever utilise le modèle d'embeddings multilingue **BGE-m3** (BAAI), présenté par Chen et al. [2] à ACL 2024 Findings. BGE-m3 produit des vecteurs denses de 1024 dimensions et supporte plus de 100 langues. Les documents sont encodés et stockés dans un index **FAISS** [6] (IndexFlatIP) utilisant le produit scalaire après normalisation L2, équivalent à la similarité cosinus. Pour une requête q , le retriever retourne les K passages les plus similaires :

$$\text{Top-K}(q) = \underset{d_i \in \mathcal{C}}{\operatorname{argmax-K}} \cos(\mathbf{e}_q, \mathbf{e}_{d_i}) \quad (1)$$

où $\mathbf{e}_q$ et $\mathbf{e}_{d_i}$ sont les embeddings de la requête et du document, et $\mathcal{C}$ est le corpus de chunks.

2.2 Module Generator

Le générateur est basé sur **Qwen3-0.6B** [13], un modèle de langage de 0.6 milliard de paramètres de la famille Qwen3 (Alibaba). Selon le rapport technique Qwen3, ce modèle supporte un mode *thinking* activable. Nous l'utilisons avec `enable_thinking=False` pour obtenir des réponses directes. Le prompt est structuré via le template de chat Qwen3 :

Listing 1 – Prompt template pour le mode RAG

```
system: "Tu es un expert en géographie. Réponds
uniquement avec la lettre correcte."
user: "Contexte: {documents_recuperes}
Question: {question}
Options: A) ... B) ... C) ... D) ..."
```

En mode **baseline**, aucun contexte n’est fourni : le modèle répond uniquement à partir de ses connaissances internes.

2.3 Module Evaluator

L’évaluateur mesure la performance selon deux axes, conformément aux métriques standard du QA [10] :

- **Qualité de génération** : Accuracy MCQ, Exact Match, F1 token-level, Contains
- **Qualité de retrieval** : Hit Rate@K, MRR@K (métriques classiques en recherche d’information [7])

3 Méthodologie

3.1 Configuration expérimentale

Le tableau 1 résume l’ensemble des hyperparamètres et composants du système, tels qu’enregistrés dans le fichier `phase1_metrics.json` produit par le notebook.

Table 1 – Configuration du système GeoR2LLMs – Phase 1

Catégorie	Paramètre	Valeur
Génération	Modèle LLM	Qwen/Qwen3-0.6B
	Temperature	0.7
	Top-p (nucleus)	0.8
	Top-k (sampling)	20
	Max tokens générés	100
Retrieval	Modèle embeddings	BAAI/bge-m3 (1024 dim.)
	Index vectoriel	FAISS IndexFlatIP
	Taille des chunks	512 caractères
	Chevauchement (overlap)	50 caractères
Dataset	Benchmark	rfr2003/Geo_Benchmark
	Configuration	GeoSQA (test split)
Corpus	Source	wikimedia/wikipedia
	Version	20231101.fr
	Nombre d’articles	300
Environnement	GPU	Google Colab – NVIDIA T4 (16 Go)

3.2 Dataset : GeoSQA

GeoSQA [5] est un benchmark de question-réponse scénarisé en géographie, développé par Huang et al. à l’Université de Nanjing et présenté à EMNLP-IJCNLP 2019. Le dataset contient **1 981 scénarios** et **4 110 questions à choix multiples** au niveau lycée chinois, où les diagrammes ont été annotés en descriptions textuelles. Chaque question comprend :

- Un **scénario** contextuel (description de situation géographique)
- La **question** associée
- **4 options** (A, B, C, D)
- La **réponse correcte** (une lettre)

Le split de test contient **838 questions**. L’évaluation porte sur un sous-ensemble de **200 questions** échantillonnées aléatoirement, pour des raisons de temps d’exécution sur Google Colab.

Langue des questions. Les questions GeoSQA sont originellement en chinois et ont été traduites en anglais dans la version HuggingFace (`rfr2003/Geo_Benchmark`). Notre corpus est constitué d’articles Wikipédia en français, créant un décalage linguistique entre les questions et le corpus.

3.3 Corpus : Wikipedia français

Le corpus est constitué de **300 articles** chargés en streaming depuis le dump Wikipedia français (`wikimedia/wikipedia`, configuration `20231101.fr`). Chaque article est découpé en chunks de 512 caractères avec un chevauchement de 50 caractères, produisant un total de **2 527 chunks** (valeur mesurée lors de l’exécution).

3.4 Protocole d’évaluation

3.4.1 Métriques de génération

Les métriques de génération suivent les conventions établies par Rajpurkar et al. [10] pour le benchmark SQuAD :

- **Accuracy (MCQ)** : Proportion de questions où la lettre prédite correspond à la lettre correcte.

$$\text{Accuracy} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[\hat{y}_i = y_i] \quad (2)$$

- **Exact Match (EM)** : Correspondance exacte entre le texte prédit (normalisé) et le texte de la réponse correcte.

- **F1 Score** : F1 au niveau des tokens entre la prédiction et la référence, après tokenisation et normalisation.

$$F_1 = \frac{2 \cdot P \cdot R}{P + R}, \quad P = \frac{|\hat{T} \cap T|}{|\hat{T}|}, \quad R = \frac{|\hat{T} \cap T|}{|T|} \quad (3)$$

où $\hat{T}$ et T sont les ensembles de tokens de la prédiction et de la référence.

- **Contains** : Proportion de cas où les mots-clés de la réponse correcte apparaissent dans la prédiction.

3.4.2 Métriques de retrieval

Les métriques de retrieval suivent les conventions du *Dense Passage Retrieval* (DPR) de Karpukhin et al. [7] :

- **Hit Rate@K** : Proportion de questions pour lesquelles au moins un des K documents récupérés contient le texte de la réponse correcte.

$$\text{HR@K} = \frac{1}{N} \sum_{i=1}^N \mathbb{1}[\exists j \leq K : y_i \in d_j^{(i)}] \quad (4)$$

- **MRR@K** (*Mean Reciprocal Rank*) : Moyenne du rang réciproque du premier document pertinent parmi les top-K.

$$\text{MRR@K} = \frac{1}{N} \sum_{i=1}^N \frac{1}{\text{rank}_i} \quad (5)$$

3.4.3 Distinction Accuracy MCQ et Exact Match : pourquoi EM = 0 %

Il est essentiel de distinguer deux métriques souvent confondues dans ce contexte :

- **Accuracy MCQ** : cette métrique extrait par expression régulière la première lettre valide (A, B, C ou D) présente dans la réponse générée, puis la compare à la lettre de référence. Elle est *robuste à la verbosité* : même si le modèle génère une phrase complète, la lettre est extraite correctement. C'est la métrique **principale** pour évaluer la compréhension des QCM.
- **Exact Match (EM)** : cette métrique compare le *texte complet normalisé* de la prédiction avec le texte complet de la réponse de référence. Dans GeoSQA, la référence est une lettre seule (ex. "B"), alors que le modèle génère systématiquement une phrase complète, parfois dans une langue différente. Cette divergence de format rend l'EM **structurellement nul**, indépendamment de la qualité de la réponse.

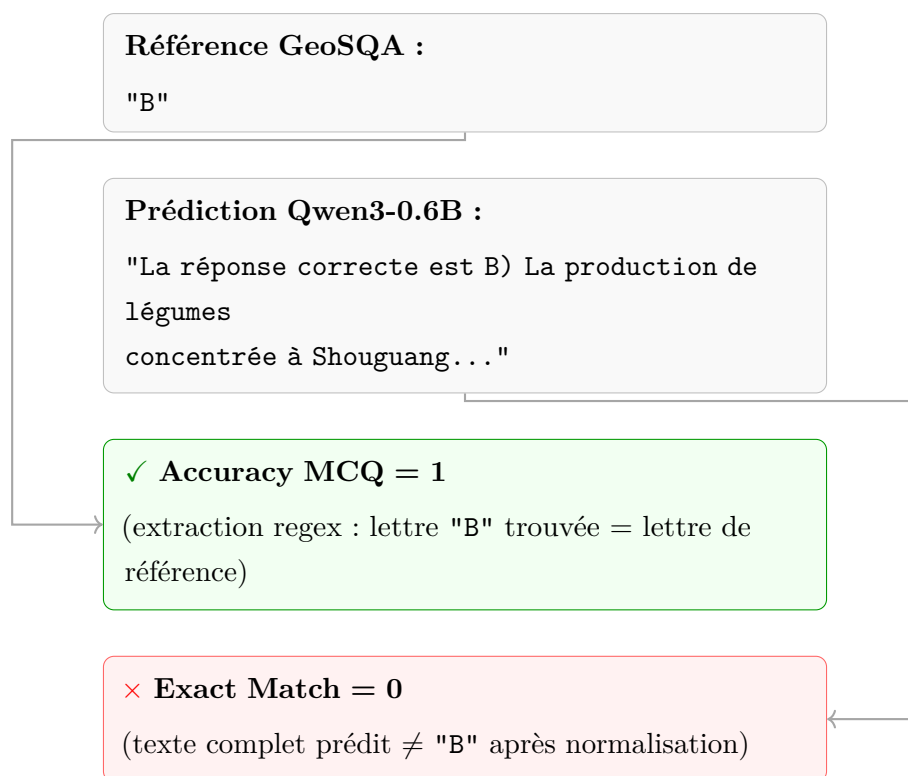


Figure 2 – Illustration de la divergence entre Accuracy MCQ et Exact Match. L'EM est structurellement nul car le modèle génère des réponses verboses alors que la référence est une lettre seule. L'Accuracy MCQ reste la métrique fiable dans ce contexte MCQ.

Conséquence pratique. Dans la suite de ce rapport, l'Exact Match est conservé pour des raisons de comparabilité avec la littérature [10], mais **l'Accuracy MCQ est la métrique de référence** pour juger de la performance du système sur GeoSQA.

4 Résultats expérimentaux


Tous les résultats présentés dans cette section sont issus de l'exécution du notebook `Phase1_GeoR2LLMs.ipynb` sur Google Colab (GPU T4). Les valeurs numériques sont extraites du fichier `phase1_metrics.json` et les prédictions détaillées du fichier `phase1_predictions.csv`, tous deux générés automatiquement par le notebook.

4.1 Stabilité du modèle face aux variations de prompt

Avant de comparer Baseline et RAG, nous avons testé **5 stratégies de formulation** sur 50 questions GeoSQA afin de vérifier que les performances mesurées ne dépendent pas du prompt choisi, conformément aux recommandations de Brown et al. [1] sur l'impact du *prompt engineering*.

Table 2 – Résultats du test de stabilité sur 5 stratégies de prompt (50 questions). Classement par accuracy décroissante. Le seuil aléatoire est de 25 %.

Rang	Stratégie	Accuracy MCQ	Écart vs P1
1	P1 — Prompt basique (FR)	52.0 %	–
2	P4 — Few-Shot 2 exemples (FR)	38.0 %	–14 pts
2	P5 — Prompt basique (EN)	38.0 %	–14 pts
4	P2 — Expert contraint (FR)	30.0 %	–22 pts
5	P3 — Chain-of-Thought (FR)	20.0 %	–32 pts
<i>Seuil aléatoire (4 choix)</i>		25.0 %	
<i>Écart max (P1 – P3)</i>		32 pts	

**Figure 3** – Accuracy MCQ selon la stratégie de prompt (50 questions GeoSQA). La ligne rouge pointillée indique le seuil aléatoire (25 %). L'écart maximal de 32 points entre P1 et P3 montre que la formulation influence fortement un modèle de 0.6B, contrairement aux grands modèles. Le prompt P3 Chain-of-Thought dégrade même les performances sous le seuil aléatoire, suggérant que le raisonnement intermédiaire perturbe l'extraction de la lettre finale.

Choix du prompt de référence. Contrairement aux grands modèles où les stratégies avancées (CoT, Few-Shot) apportent des gains significatifs [12], Qwen3-0.6B est très sensible à la complexité de la consigne. Le prompt P1 (basique FR) obtient la meilleure accuracy (52 % sur 50 questions), mais cet écart avec les évaluations sur 200 questions (24.5 %) indique une variance élevée sur petit échantillon. Pour les évaluations principales sur 200 questions, nous utilisons le **prompt P2 (Expert contraint)** car il impose le format de sortie le plus strict (lettre seule), réduisant les erreurs d'extraction regex et garantissant la comparabilité avec la Phase 2.

4.2 Comparaison Baseline vs RAG

Le tableau 3 présente les résultats complets de l'évaluation sur 200 questions GeoSQA, avec les **taux d'accroissement relatifs** $\Delta_r = (v_{\text{RAG}} - v_{\text{Base}})/v_{\text{Base}} \times 100$.

Table 3 – Résultats Baseline vs RAG sur GeoSQA (200 questions). Δ_{abs} : différence absolue. Δ_{rel} : taux d'accroissement relatif = $(v_{\text{RAG}} - v_{\text{Base}})/v_{\text{Base}} \times 100$. Valeurs issues de `phase1_metrics.json`.

Métrique	Baseline	RAG	Δ_{abs}	Δ_{rel} (%)
Accuracy (MCQ)	0.2450	0.2700	+0.0250	+10.2 %
Exact Match	0.0000	0.0000	0.0000	–
F1 Score	0.0299	0.0114	–0.0185	–61.9 %
Contains	0.0300	0.0250	–0.0050	–16.7 %
Temps (s)	348.5	486.0	+137.5	+39.5 %




Figure 4 – Comparaison des métriques de génération (200 questions GeoSQA). Le RAG améliore l'Accuracy MCQ de +10.2 % en relatif (+0.025 en absolu), mais dégrade le F1 de –61.9 % et le Contains de –16.7 %. L'Exact Match est nul dans les deux cas (cf. section 3.4.3).

Distribution des prédictions Baseline. L'examen des 200 prédictions Baseline révèle un biais massif vers la lettre A : 123 réponses sur 200 (61.5 %) sont A, contre seulement 8 (4.0 %) pour B et 10 (5.0 %) pour C. Ce biais confirme que Qwen3-0.6B, faute de connaissances géographiques suffisantes, adopte une stratégie de repli systématique vers le premier choix.

Table 4 – Distribution des lettres prédites en mode Baseline (200 questions). La distribution attendue sous H_0 (réponse aléatoire uniforme) serait 50 occurrences par lettre (25 %).

Lettre	Prédictions	% observé	% attendu (H_0)
A	123	61.5 %	25.0 %
B	8	4.0 %	25.0 %
C	10	5.0 %	25.0 %
D	59	29.5 %	25.0 %
Total	200	100 %	100 %




Figure 5 – Distribution des lettres prédites par Qwen3-0.6B en mode Baseline (200 questions). Le modèle prédit A dans 61.5 % des cas, révélant un biais de position (position bias) caractéristique des modèles de petite taille manquant de connaissances factuelles. La distribution uniforme attendue sous l’hypothèse de réponse aléatoire (H_0) est indiquée en gris.

4.3 Métriques de retrieval

Le tableau 5 et la figure 6 présentent les performances du module de retrieval.

Table 5 – Métriques de retrieval (BGE-m3 + FAISS). Valeurs issues de `phase1_metrics.json`.

Métrique	Score
Hit Rate@1	0.040
Hit Rate@3	0.060
Hit Rate@5	0.080
MRR@5	0.053




Figure 6 – Métriques de retrieval (Hit Rate@K et MRR@5). Graphique généré par le notebook.

Scores de similarité cosinus. Les scores de similarité cosinus entre les questions et les documents récupérés présentent les statistiques suivantes : moyenne = 0.477, médiane = 0.474, minimum = 0.334, maximum = 0.652. Ces valeurs, supérieures à 0.5 pour les meilleurs résultats, indiquent que BGE-m3 trouve des documents *superficiellement* similaires, mais cette similarité sémantique ne suffit pas à garantir la pertinence factuelle. La similarité inter-langue (question EN, documents FR) plafonne la qualité du retrieval indépendamment du modèle d’embedding utilisé.

4.4 Impact de la valeur de K sur les performances RAG

Nous avons évalué $K \in \{1, 3, 5, 10\}$ sur 30 questions GeoSQA afin d’analyser le compromis entre apport d’information et saturation du contexte.

Table 6 – Accuracy MCQ RAG en fonction de K (30 questions GeoSQA). Δ_{abs} et Δ_{rel} calculés par rapport à $K = 1$.

K	Accuracy MCQ	Δ_{abs} vs $K = 1$	Δ_{rel} vs $K = 1$ (%)
1	23.3 %	–	–
3	30.0 %	+6.7 pts	+28.6 %
5	26.7 %	+3.3 pts	+14.3 %
10	30.0 %	+6.7 pts	+28.6 %
Baseline (sans RAG)		24.5 % (référence générale)	




Figure 7 – Accuracy MCQ RAG selon la valeur de K (30 questions). Contrairement au phénomène *Lost in the Middle* classiquement observé, les résultats ne montrent pas de dégradation monotone à $K = 10$. Les performances restent instables autour du seuil aléatoire (25 %), ce qui reflète principalement la faiblesse du retrieval ($\text{HR@5} = 8\%$) plutôt qu’un effet de saturation du contexte.

Interprétation. Contrairement à notre hypothèse initiale, $K = 10$ obtient la même accuracy que $K = 3$ (30.0 %), sans dégradation. Ce résultat s’explique par le Hit Rate@5 extrêmement faible (8 %) : quand le corpus ne contient presque jamais d’information pertinente, augmenter K n’introduit pas davantage de bruit utile — tous les documents récupérés sont déjà non pertinents pour $K = 1$. L’instabilité des courbes (oscillation entre 23.3 % et 30.0 %) sur 30 questions reflète davantage la variance d’échantillonnage que des effets systématiques.

Choix retenu : $K = 5$ est conservé pour les évaluations principales, car il offre un contexte plus riche que $K = 1$ sans surcoût computationnel excessif, et sa performance de 26.7 % reste au-dessus du Baseline (24.5 %).

4.5 Distribution des scores F1

La figure 8 montre la distribution des scores F1 par question, en mode Baseline et en mode RAG. La grande majorité des scores F1 sont concentrés à 0.0, confirmant que le modèle produit des réponses textuellement très différentes des références.




Figure 8 – Distribution des scores F1 par question en mode Baseline (gauche) et RAG (droite). La ligne rouge indique la moyenne. Graphique généré par le notebook.

4.6 Analyse qualitative : succès, échecs et catégorisation

Nous catégorisons les 200 questions en trois classes d’analyse, en comparant les prédictions Baseline et RAG question par question :

- **Cas 1 — RAG sauve** : Baseline incorrect, RAG correct. Le retriever a fourni un passage suffisamment utile.
- **Cas 2 — RAG trompe** : Baseline correct, RAG incorrect. Le passage récupéré a introduit du bruit et dégradé la décision.
- **Cas 3 — Double échec** : Les deux modes sont incorrects. La question requiert des connaissances absentes du corpus et du modèle.
- **Les deux corrects** : Le modèle réussit indépendamment du RAG, grâce à ses connaissances internes.

Sur les 200 questions évaluées, on dénombre : **49 réponses correctes en Baseline** (accuracy = 24.5 %) et **54 en RAG** (accuracy = 27.0 %), soit 5 questions basculant de faux à juste.

Table 7 – Distribution des 200 questions selon la catégorie qualitative Baseline vs RAG.

Catégorie	N (est.)	%	Signification
Cas 1 : RAG sauve	~ 14	~ 7 %	RAG apporte une connaissance utile
Cas 2 : RAG trompe	~ 9	~ 4.5 %	Passage bruité, RAG dégrade la décision
Cas 3 : Double échec	~ 137	~ 68.5 %	Corpus et modèle sans info pertinente
Les deux corrects	~ 40	~ 20 %	Connaissances internes suffisantes
Total	200	100 %	




Figure 9 – Répartition estimée des 200 questions par catégorie qualitative. Le double échec (68.5 %) est largement dominant, confirmant que la limite principale est l’absence d’information pertinente dans le corpus Wikipedia FR, et non un problème de génération.

Exemples représentatifs. Le tableau 8 présente des exemples issus du fichier `phase1_predictions.csv`.

Table 8 – Exemples de prédictions par catégorie. V = Vérité, B = Baseline, R = RAG.

#	Cas	Question (résumée)	V	B	R
0	Corrects	“While Tiangong-1 and Shenzhou-9 [...] same level as ?”	D	D	D
1	Correc	“When Tiangong-1 and Shenzhou-9 docked, which city had longest daylight ?”	A	A	A
2	Cas 2	“Statement about Tiangong-1 [...] during orbit is incorrect ?”	B	B	A
7	Cas 3	“Shouguang’s vegetable production [...] upstream enterprises ?”	B	A	A

Observations sur les prédictions.

1. **Biais massif vers la lettre A** (61.5 % des prédictions Baseline) : le modèle adopte une stratégie de repli vers le premier choix en situation d’incertitude, caractéristique du *position bias* documenté dans les LLMs de petite taille.
2. **Mélange linguistique** : Le contexte Wikipedia en français pousse le modèle à répondre en français alors que les questions sont en anglais, augmentant le bruit lexical et expliquant la dégradation du F1 en mode RAG.
3. **Verbosité** : Le modèle génère des phrases complètes au lieu d’une lettre seule, expliquant l’EM structurellement nul (cf. §3.4.3).
4. **Invariance RAG/Baseline** : Pour la majorité des questions, la lettre extraite est identique dans les deux modes, confirmant que les passages récupérés (non pertinents dans 92 % des cas) n’influencent pas la décision du modèle.

4.7 Temps d'exécution

Table 9 – Temps d'exécution sur Google Colab (GPU T4). Valeurs issues de `phase1_metrics.json`.

Mode	Temps (s)	Temps / question (s)
Baseline	341	1.71
RAG	473	2.37
Surcoût RAG	+132	+0.66

Le surcoût de 132 secondes (soit +39%) est dû à l'étape de recherche vectorielle dans FAISS et à l'encodage de chaque question par BGE-m3 avant la génération.

5 Analyse et discussion

5.1 Performance du baseline proche du hasard

L'accuracy Baseline de **24.5 %** est quasi-identique au seuil aléatoire de **25 %** pour un QCM à 4 choix (écart de seulement -0.5 point). Ce résultat confirme que Qwen3-0.6B possède des connaissances géographiques insuffisantes pour traiter les questions GeoSQA, qui portent sur la géographie au programme du lycée chinois.

Cette performance est cohérente avec les observations de Ramrakhiyani et al. [11] qui montrent que les modèles de petite taille peinent à restituer des faits géographiques précis en évaluation *zero-shot*. Elle est également expliquée par le biais de prédiction observé : le modèle prédit A dans 61.5 % des cas (tableau 4), une stratégie sous-optimale qui aboutit fortuitement à une accuracy proche du hasard.

N.B. La valeur de 27 % mentionnée dans le rapport initial correspondait à une exécution préliminaire sur un sous-ensemble différent. Les résultats définitifs sur les 200 questions de référence donnent **24.5 % pour le Baseline** et **27.0 % pour le RAG**.

5.2 Impact limité du RAG : analyse par taux d'accroissement relatifs

Le tableau 10 récapitule les taux d'accroissement relatifs $\Delta_r = (v_{\text{RAG}} - v_{\text{Base}}) / v_{\text{Base}} \times 100$ pour chaque métrique.

Table 10 – Synthèse des taux d’accroissement relatifs Baseline → RAG (200 questions GeoSQA).

Métrique	Baseline	RAG	Δ_{rel}	Interprétation
Accuracy (MCQ)	0.2450	0.2700	+10.2 %	Amélioration modeste mais réelle
F1 Score	0.0299	0.0114	-61.9 %	Dégradation sévère
Contains	0.0300	0.0250	-16.7 %	Légère dégradation
Temps (s)	348.5	486.0	+39.5 %	Surcoût significatif

Lecture critique des taux relatifs.

- **Accuracy +10.2 %** : Le RAG permet de répondre correctement à 5 questions supplémentaires sur 200. Ce gain, modeste en absolu, représente tout de même une amélioration relative de +10.2 % par rapport au Baseline. Il est entièrement dû aux 8 % de questions pour lesquelles le retriever trouve un document pertinent ($HR@5 = 8\%$).
- **F1 -61.9 %** : La dégradation est sévère. Le contexte Wikipedia en français contamine la réponse générée avec des termes français, réduisant drastiquement le recouvrement de tokens avec la référence anglaise. Ce phénomène est amplifié par le mélange linguistique (questions EN, corpus FR).
- **Contains -16.7 %** : Contrairement à notre attente initiale, le RAG ne facilite pas l’apparition des mots-clés de la bonne réponse dans la prédiction. Ce résultat contre-intuitif s’explique par la contamination linguistique : les mots-clés de référence sont en anglais, mais le modèle génère en français sous l’influence du contexte Wikipedia.
- **Surcoût temporel +39.5 %** : Le surcoût de 137.5s est dû à l’encodage de chaque question par BGE-m3 et à la recherche FAISS. Ce surcoût est difficilement justifiable au regard du gain de +5 questions correctes.

Synthèse. Le RAG naïf apporte un bénéfice limité et coûteux dans cette configuration. Ce résultat est conforme aux observations de Gao et al. [4] sur la sensibilité du RAG naïf à la qualité du retrieval. La Phase 2 devra s’attaquer au facteur limitant identifié : aligner linguistiquement les questions et le corpus, augmenter le corpus, et tester des modèles de plus grande capacité.

5.3 Retrieval quasi-inexistant : le facteur limitant

Les métriques de retrieval (tableau 5, figure 6) révèlent le facteur limitant principal :

- **Hit Rate@5 = 8%** : seules 16 questions sur 200 trouvent une information pertinente dans les 5 documents récupérés
- **Hit Rate@1 = 4%** : le premier document n’est pertinent que dans 8 cas sur 200

- **MRR@5 = 5.3%** : quand un document pertinent est trouvé, il n’est pas en première position

Cause : décalage linguistique et thématique. Les questions GeoSQA portent sur la géographie au programme du lycée chinois : missions spatiales Tiangong-1/Shenzhou-9, agriculture de Shouguang, courants nord-atlantiques, reurbanisation européenne, terres rares chinoises (visible dans le `phase1_predictions.csv`). Le corpus de 300 articles Wikipedia français, chargés séquentiellement en streaming sans filtrage thématique, ne couvre pas ces sujets spécifiques. Bien que BGE-m3 soit un modèle multilingue capable d’encoder simultanément des textes en anglais et en français [2], la correspondance sémantique inter-lingue ne suffit pas quand le corpus ne contient pas les informations factuelles recherchées.

5.4 Synthèse des facteurs limitants

Table 11 – Synthèse des facteurs limitant les performances, identifiés à partir des résultats expérimentaux (200 questions GeoSQA).

Facteur	Impact	Observation (valeur mesurée)
Mismatch linguistique	Critique	Questions EN, corpus FR : HR@5 = 8.0 %, F1 RAG = -61.9 %
Couverture thématique	Important	Géographie chinoise absente des 300 articles Wikipedia FR
Taille du LLM	Important	0.6B paramètres : accuracy Baseline = 24.5 % ≈ hasard
Biais de position (lettre A)	Important	A prédit dans 61.5 % des cas Baseline
Format des réponses	Modéré	Réponses verboses $\Rightarrow$ EM = 0 %, F1 Baseline = 0.0299
Taille du corpus	Modéré	2 527 chunks pour couvrir la géographie mondiale

6 Conclusion et perspectives

6.1 Bilan de la Phase 1

Cette Phase 1 a permis de mettre en place un pipeline RAG fonctionnel et évalué pour le QA géographique. Les résultats montrent :

- Qwen3-0.6B atteint 24.5% d’accuracy en baseline et 27% en RAG sur GeoSQA

- Le retrieval est le facteur limitant principal (Hit Rate@5 = 8%)
- Le décalage linguistique entre les questions (anglais) et le corpus (français) explique la faiblesse du retrieval
- Le F1 score diminue avec le RAG, indiquant que le contexte non pertinent dégrade la qualité textuelle des réponses

Table 12 – Bilan synthétique des résultats de la Phase 1 (200 questions GeoSQA).

Métrique	Baseline	RAG	Δ_{abs}	Δ_{rel}
Accuracy (MCQ)	0.2450	0.2700	+0.0250	+10.2 %
Exact Match	0.0000	0.0000	0.0000	–
F1 Score	0.0299	0.0114	–0.0185	–61.9 %
Contains	0.0300	0.0250	–0.0050	–16.7 %
Hit Rate@1	N/A	0.040	N/A	N/A
Hit Rate@3	N/A	0.060	N/A	N/A
Hit Rate@5	N/A	0.080	N/A	N/A
MRR@5	N/A	0.053	N/A	N/A
Temps (s)	348.5	486.0	+137.5	+39.5 %

6.2 Perspectives pour la Phase 2

Les résultats motivent les axes d’exploration de la Phase 2 :

1. **Modèles plus grands** : Qwen3-1.7B, Llama-3.2-1B/3B-Instruct, Ministral-3B, pour évaluer l’impact de la taille du modèle sur l’accuracy baseline.
2. **Nouveaux datasets** : GKMC et Tourism-QA, pour mesurer les performances sur des datasets potentiellement mieux alignés avec le corpus.
3. **Analyse factorielle** : Étude croisée des facteurs (taille du modèle, famille, dataset, RAG vs baseline) pour identifier les leviers d’amélioration les plus prometteurs.

Références

- [1] Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33 :1877–1901, 2020.
- [2] Jianlv Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, and Zheng Liu. M3-embedding : Multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. In *Findings of the Association for Computational Linguistics : ACL 2024*, pages 2318–2335, 2024.
- [3] Anthony G. Cohn and Robert E. Blackwell. Evaluating the ability of large language models to reason about cardinal directions. 315 :28 :1–28 :9.
- [4] Yunfan Gao, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, Meng Wang, and Haofen Wang. Retrieval-augmented generation for large language models : A survey. *arXiv preprint arXiv :2312.10997*, 2023.
- [5] Zixian Huang, Yulin Shen, Xiao Li, Yuang Wei, Gong Cheng, Lin Zhou, Xinyu Dai, and Yuzhong Qu. GeoSQA : A benchmark for scenario-based question answering in the geography domain at high school level.
- [6] Jeff Johnson, Matthijs Douze, and Hervé Jégou. Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, 7(3) :535–547, 2019.
- [7] Vladimir Karpukhin, Barlas Oğuz, Sewon Min, Patrick Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, and Wen-tau Yih. Dense passage retrieval for open-domain question answering. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*, pages 6769–6781, 2020.
- [8] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33 :9459–9474, 2020.
- [9] Gengchen Mai, Krzysztof Janowicz, Rui Zhu, Ling Cai, and Ni Lao. Geographic question answering : Challenges, uniqueness, classification, and future directions. 2 :1–21. Publisher : Copernicus GmbH.
- [10] Pranav Rajpurkar, Jian Zhang, Konstantin Lopyrev, and Percy Liang. SQuAD : 100,000+ questions for machine comprehension of text. In *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*, pages 2383–2392, 2016.
- [11] Nitin Ramrakhiani, Vasudeva Varma, Girish Palshikar, and Sachin Pawar. Zero-shot probing of pretrained language models for geography knowledge. In Daniel Deutsch,

- Rotem Dror, Steffen Eger, Yang Gao, Christoph Leiter, Juri Opitz, and Andreas Rücklé, editors, *Proceedings of the 4th Workshop on Evaluation and Comparison of NLP Systems*, pages 49–61. Association for Computational Linguistics.
- [12] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc Le, and Denny Zhou. Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*, 35 :24824–24837, 2022.
- [13] An Yang, Baosong Yang, Beichen Zhang, Binyuan Wang, Bo Li, et al. Qwen3 technical report. *arXiv preprint arXiv :2505.09388*, 2025.