

UNIVERSITÉ TOULOUSE III – PAUL SABATIER

MASTER 2 INTELLIGENCE ARTIFICIELLE

IRIT – Institut de Recherche en Informatique de Toulouse

Système Question-Réponse en Géographie avec RAG

Rapport de travail – Phase 1 : Plateforme de base

Projet GeoR2LLMs

Réalisé par :

Mohamed DIALLO

Hiba L'MOUDDEN

Feras MAKHLOUF

Osama BAAZZI

Ousama BOUTEZROUT

Sous la direction de :

Madame Lynda TAMINE-LECHANI

Professeure – IRIT

UE : Chef d'œuvre

Année : 2025–2026

Février 2026

Table des matières

1	Introduction	2
1.1	Contexte et motivations	2
1.2	Objectif de la Phase 1	2
1.3	Organisation du rapport	2
2	Architecture du système	3
2.1	Module Retriever	3
2.2	Module Generator	3
2.3	Module Evaluator	4
3	Méthodologie	4
3.1	Configuration expérimentale	4
3.2	Dataset : GeoSQA	5
3.3	Corpus : Wikipedia français	5
3.4	Protocole d'évaluation	5
3.4.1	Métriques de génération	5
3.4.2	Métriques de retrieval	6
4	Résultats expérimentaux	6
4.1	Comparaison Baseline vs RAG	6
4.2	Métriques de retrieval	7
4.3	Distribution des scores F1	8
4.4	Analyse qualitative des prédictions	9
4.5	Temps d'exécution	9
5	Analyse et discussion	10
5.1	Performance du baseline proche du hasard	10
5.2	Impact limité du RAG	10
5.3	Retrieval quasi-inexistant : le facteur limitant	10
5.4	Synthèse des facteurs limitants	11
6	Conclusion et perspectives	11
6.1	Bilan de la Phase 1	11
6.2	Perspectives pour la Phase 2	11

1 Introduction

Le projet GeoR2LLMs (*Geographic Retrieval-augmented generation with Large Language Models*) s'inscrit dans le cadre du chef-d'œuvre du Master 2 Intelligence Artificielle de l'Université Toulouse III – Paul Sabatier, sous la direction de Madame Lynda Tamine-Lechani à l'IRIT. Ce rapport de travail documente l'implémentation et les résultats de la Phase 1 du projet.

1.1 Contexte et motivations

Le Question-Réponse géographique (GeoQA) constitue un défi particulier pour les systèmes de traitement automatique des langues. Mai et al. [8] identifient les questions géographiques comme nécessitant un raisonnement spatial, la compréhension de relations topologiques et l'intégration de connaissances spécifiques au domaine. Cohn et Blackwell [2] montrent qu'aucun LLM actuel ne parvient à raisonner de manière fiable sur les directions cardinales, même avec une température de zéro.

L'architecture RAG (*Retrieval-Augmented Generation*), introduite par Lewis et al. [7] dans le cadre de NeurIPS 2020, propose d'augmenter les LLMs avec des connaissances externes récupérées dynamiquement depuis un corpus. Gao et al. [3] proposent une taxonomie des systèmes RAG distinguant le RAG naïf (retrieve-then-read) du RAG avancé (avec réécriture de requêtes ou re-ranking). Notre implémentation suit l'approche naïve.

1.2 Objectif de la Phase 1

La Phase 1 du projet vise à mettre en place une **plateforme de base** pour le système GeoQA-RAG, conformément au cahier des charges. Les objectifs sont :

1. Implémenter un pipeline RAG complet avec les composants spécifiés (Qwen3-0.6B, BGE-m3, FAISS)
2. Établir une baseline (LLM seul, sans RAG) comme point de comparaison
3. Évaluer l'apport du RAG sur le dataset GeoSQA [4]
4. Mesurer la qualité du retrieval indépendamment de la génération

1.3 Organisation du rapport

La section 2 présente l'architecture du système. La section 3 détaille les choix méthodologiques. Les résultats expérimentaux sont rapportés en section 4 et analysés en section 5. La section 6 conclut et ouvre sur la Phase 2.

2 Architecture du système

Le système repose sur une architecture RAG composée de trois modules : un **Retriever**, un **Generator** et un **Evaluator**. La figure 1 illustre le pipeline.




Figure 1 – Architecture du pipeline RAG. Le corpus Wikipedia est découpé en chunks, encodé par BGE-m3 et indexé dans FAISS. Les questions sont encodées puis les top-K passages récupérés sont fournis comme contexte au générateur Qwen3-0.6B.

2.1 Module Retriever

Le retriever utilise le modèle d'embeddings multilingue **BGE-m3** (BAAI), présenté par Chen et al. [1] à ACL 2024 Findings. BGE-m3 produit des vecteurs denses de 1024 dimensions et supporte plus de 100 langues. Les documents sont encodés et stockés dans un index **FAISS** [5] (IndexFlatIP) utilisant le produit scalaire après normalisation L2, équivalent à la similarité cosinus. Pour une requête q , le retriever retourne les K passages les plus similaires :

$$\text{Top-K}(q) = \underset{d_i \in \mathcal{C}}{\operatorname{argmax-K}} \cos(\mathbf{e}_q, \mathbf{e}_{d_i}) \quad (1)$$

où $\mathbf{e}_q$ et $\mathbf{e}_{d_i}$ sont les embeddings de la requête et du document, et $\mathcal{C}$ est le corpus de chunks.

2.2 Module Generator

Le générateur est basé sur **Qwen3-0.6B** [11], un modèle de langage de 0.6 milliard de paramètres de la famille Qwen3 (Alibaba). Selon le rapport technique Qwen3, ce modèle supporte un mode *thinking* activable. Nous l'utilisons avec `enable_thinking=False` pour obtenir des réponses directes. Le prompt est structuré via le template de chat Qwen3 :

Listing 1 – Prompt template pour le mode RAG

```
system: "Tu es un expert en géographie. Réponds
uniquement avec la lettre correcte."
user: "Contexte: {documents_recuperes}
Question: {question}
Options: A) ... B) ... C) ... D) ..."
```

En mode **baseline**, aucun contexte n’est fourni : le modèle répond uniquement à partir de ses connaissances internes.

2.3 Module Evaluator

L’évaluateur mesure la performance selon deux axes, conformément aux métriques standard du QA [9] :

- **Qualité de génération** : Accuracy MCQ, Exact Match, F1 token-level, Contains
- **Qualité de retrieval** : Hit Rate@K, MRR@K (métriques classiques en recherche d’information [6])

3 Méthodologie

3.1 Configuration expérimentale

Le tableau 1 résume l’ensemble des hyperparamètres et composants du système, tels qu’enregistrés dans le fichier `phase1_metrics.json` produit par le notebook.

Table 1 – Configuration du système GeoR2LLMs – Phase 1

Catégorie	Paramètre	Valeur
Génération	Modèle LLM	Qwen/Qwen3-0.6B
	Temperature	0.7
	Top-p (nucleus)	0.8
	Top-k (sampling)	20
	Max tokens générés	100
Retrieval	Modèle embeddings	BAAI/bge-m3 (1024 dim.)
	Index vectoriel	FAISS IndexFlatIP
	Taille des chunks	512 caractères
	Chevauchement (overlap)	50 caractères
Dataset	Benchmark	rfr2003/Geo_Benchmark
	Configuration	GeoSQA (test split)
Corpus	Source	wikimedia/wikipedia
	Version	20231101.fr
	Nombre d’articles	300
Environnement	GPU	Google Colab – NVIDIA T4 (16 Go)

3.2 Dataset : GeoSQA

GeoSQA [4] est un benchmark de question-réponse scénarisé en géographie, développé par Huang et al. à l’Université de Nanjing et présenté à EMNLP-IJCNLP 2019. Le dataset contient **1 981 scénarios** et **4 110 questions à choix multiples** au niveau lycée chinois, où les diagrammes ont été annotés en descriptions textuelles. Chaque question comprend :

- Un **scénario** contextuel (description de situation géographique)
- La **question** associée
- **4 options** (A, B, C, D)
- La **réponse correcte** (une lettre)

Le split de test contient **838 questions**. L’évaluation porte sur un sous-ensemble de **200 questions** échantillonnées aléatoirement, pour des raisons de temps d’exécution sur Google Colab.

Langue des questions. Les questions GeoSQA sont originellement en chinois et ont été traduites en anglais dans la version HuggingFace (`rfr2003/Geo_Benchmark`). Notre corpus est constitué d’articles Wikipédia en français, créant un décalage linguistique entre les questions et le corpus.

3.3 Corpus : Wikipedia français

Le corpus est constitué de **300 articles** chargés en streaming depuis le dump Wikipedia français (`wikimedia/wikipedia`, configuration `20231101.fr`). Chaque article est découpé en chunks de 512 caractères avec un chevauchement de 50 caractères, produisant un total de **2 527 chunks** (valeur mesurée lors de l’exécution).

3.4 Protocole d’évaluation

3.4.1 Métriques de génération

Les métriques de génération suivent les conventions établies par Rajpurkar et al. [9] pour le benchmark SQuAD :

- **Accuracy (MCQ)** : Proportion de questions où la lettre prédite correspond à la lettre correcte.

$$\text{Accuracy} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[\hat{y}_i = y_i] \quad (2)$$

- **Exact Match (EM)** : Correspondance exacte entre le texte prédit (normalisé) et le texte de la réponse correcte.

- **F1 Score** : F1 au niveau des tokens entre la prédiction et la référence, après tokenisation et normalisation.

$$F_1 = \frac{2 \cdot P \cdot R}{P + R}, \quad P = \frac{|\hat{T} \cap T|}{|\hat{T}|}, \quad R = \frac{|\hat{T} \cap T|}{|T|} \quad (3)$$

où $\hat{T}$ et T sont les ensembles de tokens de la prédiction et de la référence.

- **Contains** : Proportion de cas où les mots-clés de la réponse correcte apparaissent dans la prédiction.

3.4.2 Métriques de retrieval

Les métriques de retrieval suivent les conventions du *Dense Passage Retrieval* (DPR) de Karpukhin et al. [6] :

- **Hit Rate@K** : Proportion de questions pour lesquelles au moins un des K documents récupérés contient le texte de la réponse correcte.

$$\text{HR@K} = \frac{1}{N} \sum_{i=1}^N \mathbb{1}[\exists j \leq K : y_i \in d_j^{(i)}] \quad (4)$$

- **MRR@K** (*Mean Reciprocal Rank*) : Moyenne du rang réciproque du premier document pertinent parmi les top-K.

$$\text{MRR@K} = \frac{1}{N} \sum_{i=1}^N \frac{1}{\text{rank}_i} \quad (5)$$

4 Résultats expérimentaux

Tous les résultats présentés dans cette section sont issus de l'exécution du notebook `Phase1_GeoR2LLMs.ipynb` sur Google Colab (GPU T4). Les valeurs numériques sont extraites du fichier `phase1_metrics.json` et les prédictions détaillées du fichier `phase1_predictions.csv`, tous deux générés automatiquement par le notebook.


4.1 Comparaison Baseline vs RAG

Le tableau 2 présente les résultats de l'évaluation sur 200 questions GeoSQA.

Table 2 – Résultats Baseline vs RAG sur GeoSQA (200 questions). Valeurs issues de `phase1_metrics.json`.

Métrique	Baseline	RAG	Delta
Accuracy (MCQ)	0.270	0.290	+0.020
Exact Match	0.000	0.000	0.000
F1 Score	0.028	0.016	-0.013
Contains	0.025	0.035	+0.010
Temps (secondes)	341	473	+132

La figure 2 illustre cette comparaison. Ce graphique est produit directement par le notebook lors de l'exécution.


**Figure 2** – Comparaison des métriques de génération entre le mode Baseline (LLM seul) et le mode RAG (LLM + Wikipedia). Graphique généré par le notebook `Phase1_GeoR2LLMs.ipynb`.

4.2 Métriques de retrieval

Le tableau 3 et la figure 3 présentent les performances du module de retrieval.


Table 3 – Métriques de retrieval (BGE-m3 + FAISS). Valeurs issues de `phase1_metrics.json`.

Métrique	Score
Hit Rate@1	0.040
Hit Rate@3	0.060
Hit Rate@5	0.080
MRR@5	0.053

**Figure 3** – Métriques de retrieval (Hit Rate@K et MRR@5). Graphique généré par le notebook.

4.3 Distribution des scores F1

La figure 4 montre la distribution des scores F1 par question, en mode Baseline et en mode RAG. La grande majorité des scores F1 sont concentrés à 0.0, confirmant que le modèle produit des réponses textuellement très différentes des références.

**Figure 4** – Distribution des scores F1 par question en mode Baseline (gauche) et RAG (droite). La ligne rouge indique la moyenne. Graphique généré par le notebook.

4.4 Analyse qualitative des prédictions

Le tableau 4 présente des exemples de prédictions extraits du fichier `phase1_predictions.csv`.

Table 4 – Exemples de prédictions extraits de `phase1_predictions.csv`

#	Question (résumée)	Vérité	Base.	RAG
0	“While Tiangong-1 and Shenzhou-9 [...] same level as?”	D	D	D
1	“When Tiangong-1 and Shenzhou-9 docked, which city had longest daylight?”	A	A	A
2	“Statement about Tiangong-1 [...] during orbit is incorrect?”	B	A	A
7	“Shouguang’s vegetable production [...] upstream enterprises?”	B	A	A
24	“Trends in Shandong Province’s socioeconomic development?”	B	B	B

Observations qualitatives issues des prédictions. L’examen du fichier `phase1_predictions.csv` (200 lignes) révèle :

1. **Mélange linguistique** : Le modèle produit des réponses en français alors que les questions sont en anglais. Par exemple, pour la question #0 en anglais sur Tiangong-1, la réponse RAG est : “La réponse est : le système céleste avec laquelle Tiangong-1 et Shenzhou-9 forment.”.
2. **Verbosité** : Au lieu de répondre par la lettre seule, le modèle génère des phrases complètes (ex. question #7 : “Shouguang’s concentrated vegetable production has spurred the growth of related supporting industries [...]”), ce qui explique l’Exact Match à 0%.
3. **Prédiction fréquente de la lettre A** : On observe dans les prédictions que le modèle prédit souvent A par défaut quand il est incertain (questions #2, #7 dans le tableau).
4. **RAG identique au baseline** : Pour les questions #0, #1, #2, #7 et #24, la lettre extraite est identique en baseline et RAG, confirmant que les contextes récupérés ne modifient pas la décision du modèle.

4.5 Temps d’exécution

Table 5 – Temps d’exécution sur Google Colab (GPU T4). Valeurs issues de `phase1_metrics.json`.

Mode	Temps (s)	Temps / question (s)
Baseline	341	1.71
RAG	473	2.37
Surcoût RAG	+132	+0.66

Le surcoût de 132 secondes (soit +39%) est dû à l'étape de recherche vectorielle dans FAISS et à l'encodage de chaque question par BGE-m3 avant la génération.

5 Analyse et discussion

5.1 Performance du baseline proche du hasard

L'accuracy baseline de **27%** est proche du seuil aléatoire de **25%** pour un QCM à 4 choix. Cela indique que Qwen3-0.6B, avec 0.6 milliard de paramètres, possède peu de connaissances géographiques pertinentes pour les questions GeoSQA. Ramrakhiyani et al. [10] ont montré dans leur évaluation *zero-shot* de PLMs sur des faits géographiques que les modèles de petite taille peinent à restituer des connaissances géographiques précises, ce qui est cohérent avec notre observation.

5.2 Impact limité du RAG

Le RAG n'apporte qu'un gain de **+2 points** en accuracy MCQ (de 27% à 29%). Le F1 score **diminue** de 0.028 à 0.016 (delta de -0.013). Cette dégradation est observable sur la figure 4 : la distribution des scores F1 en mode RAG est encore plus concentrée autour de 0 qu'en baseline.

La métrique Contains montre une légère amélioration (de 0.025 à 0.035), indiquant que dans quelques cas, le contexte Wikipedia apporte des mots-clés présents dans la réponse attendue.

5.3 Retrieval quasi-inexistant : le facteur limitant

Les métriques de retrieval (tableau 3, figure 3) révèlent le facteur limitant principal :

- **Hit Rate@5 = 8%** : seules 16 questions sur 200 trouvent une information pertinente dans les 5 documents récupérés
- **Hit Rate@1 = 4%** : le premier document n'est pertinent que dans 8 cas sur 200
- **MRR@5 = 5.3%** : quand un document pertinent est trouvé, il n'est pas en première position

Cause : décalage linguistique et thématique. Les questions GeoSQA portent sur la géographie au programme du lycée chinois : missions spatiales Tiangong-1/Shenzhou-9, agriculture de Shouguang, courants nord-atlantiques, reurbanisation européenne, terres rares chinoises (visible dans le `phase1_predictions.csv`). Le corpus de 300 articles Wikipedia français, chargés séquentiellement en streaming sans filtrage thématique, ne couvre pas ces sujets spécifiques. Bien que BGE-m3 soit un modèle multilingue capable

d’encoder simultanément des textes en anglais et en français [1], la correspondance sémantique inter-langue ne suffit pas quand le corpus ne contient pas les informations factuelles recherchées.

5.4 Synthèse des facteurs limitants

Table 6 – Synthèse des facteurs limitant les performances, identifiés à partir des résultats

Facteur	Impact	Observation
Mismatch linguistique	Critique	Questions en anglais, corpus en français : HR@5 = 8%
Couverture thématique	Important	Géographie chinoise absente des 300 articles Wikipedia FR
Taille du LLM	Important	0.6B paramètres : accuracy baseline = 27% $\approx$ hasard
Taille du corpus	Important	2 527 chunks pour couvrir la géographie mondiale
Format des réponses	Modéré	Réponses verbeuses $\Rightarrow$ EM = 0%, F1 faible

6 Conclusion et perspectives

6.1 Bilan de la Phase 1

Cette Phase 1 a permis de mettre en place un pipeline RAG fonctionnel et évalué pour le QA géographique. Les résultats montrent :

- Qwen3-0.6B atteint 27% d’accuracy en baseline et 29% en RAG sur GeoSQA
- Le retrieval est le facteur limitant principal (Hit Rate@5 = 8%)
- Le décalage linguistique entre les questions (anglais) et le corpus (français) explique la faiblesse du retrieval
- Le F1 score diminue avec le RAG (−0.013), indiquant que le contexte non pertinent dégrade la qualité textuelle des réponses

6.2 Perspectives pour la Phase 2

Les résultats motivent les axes d’exploration de la Phase 2 :

1. **Modèles plus grands** : Qwen3-1.7B, Llama-3.2-1B/3B-Instruct, Ministral-3B, pour évaluer l’impact de la taille du modèle sur l’accuracy baseline.
2. **Nouveaux datasets** : GKMC et Tourism-QA, pour mesurer les performances sur des datasets potentiellement mieux alignés avec le corpus.

3. **Analyse factorielle** : Étude croisée des facteurs (taille du modèle, famille, dataset, RAG vs baseline) pour identifier les leviers d'amélioration les plus prometteurs.

Références

- [1] Jianlv Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, and Zheng Liu. M3-embedding : Multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. In *Findings of the Association for Computational Linguistics : ACL 2024*, pages 2318–2335, 2024.
- [2] Anthony G. Cohn and Robert E. Blackwell. Evaluating the ability of large language models to reason about cardinal directions. 315 :28 :1–28 :9.
- [3] Yunfan Gao, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, Meng Wang, and Haofen Wang. Retrieval-augmented generation for large language models : A survey. *arXiv preprint arXiv :2312.10997*, 2023.
- [4] Zixian Huang, Yulin Shen, Xiao Li, Yuang Wei, Gong Cheng, Lin Zhou, Xinyu Dai, and Yuzhong Qu. GeoSQA : A benchmark for scenario-based question answering in the geography domain at high school level.
- [5] Jeff Johnson, Matthijs Douze, and Hervé Jégou. Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, 7(3) :535–547, 2019.
- [6] Vladimir Karpukhin, Barlas Oğuz, Sewon Min, Patrick Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, and Wen-tau Yih. Dense passage retrieval for open-domain question answering. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*, pages 6769–6781, 2020.
- [7] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33 :9459–9474, 2020.
- [8] Gengchen Mai, Krzysztof Janowicz, Rui Zhu, Ling Cai, and Ni Lao. Geographic question answering : Challenges, uniqueness, classification, and future directions. 2 :1–21. Publisher : Copernicus GmbH.
- [9] Pranav Rajpurkar, Jian Zhang, Konstantin Lopyrev, and Percy Liang. SQuAD : 100,000+ questions for machine comprehension of text. In *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*, pages 2383–2392, 2016.
- [10] Nitin Ramrakhiyani, Vasudeva Varma, Girish Palshikar, and Sachin Pawar. Zero-shot probing of pretrained language models for geography knowledge. In Daniel Deutsch, Rotem Dror, Steffen Eger, Yang Gao, Christoph Leiter, Juri Opitz, and Andreas Rücklé, editors, *Proceedings of the 4th Workshop on Evaluation and Comparison of NLP Systems*, pages 49–61. Association for Computational Linguistics.
- [11] An Yang, Baosong Yang, Beichen Zhang, Binyuan Wang, Bo Li, et al. Qwen3 technical report. *arXiv preprint arXiv :2505.09388*, 2025.