

UNIVERSITÉ TOULOUSE III – PAUL SABATIER

MASTER 2 INTELLIGENCE ARTIFICIELLE

IRIT – Institut de Recherche en Informatique de Toulouse

Systeme Question-Réponse en Géographie avec RAG

*Rapport de travail – Phase 2 : Exploration Multi-LLMs et
Multi-Datasets*

Projet GeoR2LLMs

Réalisé par :

Mohamed DIALLO

Hiba L'MOUDDEN

Feras MAKHLOUF

Osama BAAZZI

Ousama BOUTEZROUT

Sous la direction de :

Madame Lynda TAMINE-LECHANI

Professeure – IRIT

UE : Chef d'œuvre

Année : 2025–2026

Mars 2026

Contents

1	Introduction	2
1.1	Rappel des résultats de la Phase 1	2
1.2	Objectifs et organisation de la Phase 2	2
2	Architecture du système étendu	3
2.1	Module UnifiedGenerator	3
2.2	Module Evaluator adapté	3
3	Méthodologie	4
3.1	Modèles évalués	4
3.2	Datasets évalués	4
3.3	Configuration expérimentale	4
3.4	Métriques et correspondance RAGAS	5
4	Résultats par dataset	5
4.1	GeoSQA – Raisonnement spatial	5
4.2	GKMC – Connaissances géographiques générales	6
4.3	Tourism-QA – Recommandation de POI	7
4.4	Validation de l’hypothèse de mismatch linguistique	9
4.5	Analyse par type de question	10
5	Analyse factorielle croisée	10
5.1	Facteur 1 : taille du modèle	11
5.2	Facteur 2 : famille de modèle	11
5.3	Facteur 3 : type de dataset	12
5.4	Facteur 4 : impact du RAG	12
5.5	Classement global et efficacité	13
6	Discussion	13
6.1	Incompatibilité de Ministral-3B	13
6.2	Pourquoi le RAG est-il inefficace en moyenne ?	14
6.3	Pourquoi Qwen3-0.6B domine-t-il sur Tourism-QA en mode RAG ?	14
6.4	Synthèse des facteurs déterminants et perspectives	15
6.5	Limites de l’étude	15
7	Conclusion et perspectives	15
7.1	Synthèse	15
7.2	Perspectives pour la Phase 3	16

1 Introduction

Ce rapport documente la Phase 2 du projet GeoR2LLMs (*Geographic Retrieval-augmented generation with Large Language Models*), réalisé dans le cadre du chef-d’œuvre du Master 2 Intelligence Artificielle de l’Université Toulouse III – Paul Sabatier, sous la direction de Madame Lynda Tamine-Lechani à l’IRIT. L’objectif est de comparer les performances de plusieurs modèles de langue (LLMs) de petite taille dans une configuration RAG pour la question-réponse géographique, en répondant aux quatre questions suivantes :

1. **Quel modèle est le plus performant** pour le QA géographique avec RAG ?
2. **Quel est l’impact du RAG** sur les performances par rapport au baseline ?
3. **La taille du modèle** est-elle corrélée aux performances ?
4. **Les résultats sont-ils cohérents** entre différents types de benchmarks ?

1.1 Rappel des résultats de la Phase 1

La Phase 1 avait mis en place un pipeline RAG de base (Qwen3-0.6B, BGE-m3 [1], FAISS [5]) évalué sur GeoSQA [4], révélant trois limitations majeures :

1. Un **décalage linguistique critique** : questions en anglais, corpus Wikipedia en français, conduisant à un Hit Rate@5 de seulement 8 % et une dégradation du F1 de -61.9 % en mode RAG.
2. Un **modèle trop petit** : Qwen3-0.6B à 24.5 % d’accuracy en baseline (quasi-aléatoire, seuil = 25 %), avec un biais de position massif vers la lettre A (61.5 % des prédictions).
3. Un **corpus trop restreint** : 300 articles Wikipedia (2 527 chunks) insuffisants pour couvrir la géographie mondiale.

1.2 Objectifs et organisation de la Phase 2

La Phase 2 étend l’évaluation à **5 LLMs** sur **3 datasets** géographiques, structurée en quatre notebooks complémentaires :

- **Phase 2a** – Comparaison multi-LLMs sur GeoSQA (corpus FR et EN en parallèle).
- **Phase 2b** – Évaluation des mêmes modèles sur GKMC.
- **Phase 2c** – Évaluation sur Tourism-QA (recommandation de POI).
- **Phase 2d** – Analyse factorielle croisée (taille, famille, dataset, impact RAG).

2 Architecture du système étendu

La Phase 2 conserve l'architecture RAG naïve de la Phase 1 (*retrieve-then-read*, selon la taxonomie de Gao et al. [3]) et l'étend sur trois dimensions : modèles de génération, datasets et corpus. Tous les modèles partagent le même retriever (BAAI/bge-m3 + FAISS).




Figure 1: Architecture RAG commune à toutes les évaluations de la Phase 2. Le retriever (BAAI/bge-m3) encode la question et recherche les 5 chunks les plus similaires via FAISS (IndexFlatIP). Le générateur est instancié successivement pour chacun des 4 LLMs validés, avec libération mémoire GPU entre chaque modèle.

2.1 Module UnifiedGenerator

La principale innovation technique de la Phase 2 est le **UnifiedGenerator**, qui encapsule le chargement, le formatage de prompt et la génération pour les trois familles : Qwen3 (`enable_thinking=False`), Llama (avec fallback miroirs Unsloth), et Mistral. La libération mémoire GPU explicite entre chaque modèle (`del model, torch.cuda.empty_cache()`) permet d'évaluer séquentiellement plusieurs LLMs sur un GPU T4 de 16 Go sans erreur OOM.

Note sur Ministral-3B. Ministral-3B-Instruct-2512 utilise une configuration `Mistral3Config` non supportée par `AutoModelForCausalLM` de la bibliothèque Transformers. Ce modèle n'a donc pu être évalué sur aucun des trois datasets. Seuls **4 modèles** ont produit des résultats exploitables.

2.2 Module Evaluator adapté

Pour GeoSQA et GKMC (tâche MCQ), les métriques sont identiques à la Phase 1 : Accuracy MCQ (métrique principale), Exact Match, F1 token-level, Hit Rate@K, MRR@5. Pour Tourism-QA (recommandation POI), un `POIEvaluator` dédié calcule l'Accuracy@1, le Hit Rate@3 et le F1 sur le nom du POI.

3 Méthodologie

3.1 Modèles évalués

Table 1: Modèles LLM évalués dans la Phase 2. Les paramètres de génération sont ceux recommandés par chaque équipe de développement. Ministral-3B n’a pas pu être chargé (incompatibilité `Mistral3Config`).

Modèle	Famille	Taille	Temp.	Identifiant HuggingFace
Qwen3-0.6B	Qwen	0.6B	0.7	Qwen/Qwen3-0.6B
Qwen3-1.7B	Qwen	1.7B	0.7	Qwen/Qwen3-1.7B
Llama-3.2-1B	Llama	1.0B	0.6	meta-llama/Llama-3.2-1B-Instruct
Llama-3.2-3B	Llama	3.0B	0.6	meta-llama/Llama-3.2-3B-Instruct
Ministral-3B	Mistral	3.0B	0.7	mistralai/Ministral-3-3B-Instruct-2512

3.2 Datasets évalués

Table 2: Datasets utilisés pour l’évaluation en Phase 2.

Dataset	Questions	Langue	Tâche	Corpus RAG
GeoSQA [4]	200	ZH → EN	QCM (A/B/C/D)	Wikipedia FR
GKMC	200	EN	QCM (A/B/C/D)	Wikipedia FR
Tourism-QA [6]	100	EN	Recommandation POI	Reviews utilisateurs

GeoSQA [4] contient des questions de raisonnement spatial traduites du chinois. GKMC porte sur des connaissances géographiques générales nativement en anglais. Tourism-QA évalue la recommandation de points d’intérêt (POI) à partir de requêtes touristiques et de reviews utilisateurs.

3.3 Configuration expérimentale

Les expériences ont été réalisées sur Google Colab avec un GPU NVIDIA Tesla T4 (16 Go VRAM). Paramètres communs : graine aléatoire = 42, top- k = 5, taille de chunk = 512 caractères, chevauchement = 50 caractères, 300 articles Wikipedia FR/EN (GeoSQA/GKMC) ou reviews utilisateurs (Tourism-QA). Chaque modèle est évalué dans deux conditions : **Baseline** (LLM seul, sans contexte RAG) et **RAG** (LLM avec les top-5 documents récupérés).

3.4 Métriques et correspondance RAGAS

Les métriques RAGAS n’ont pas pu être calculées pour trois raisons cumulatives : (1) RAGAS requiert un juge externe (GPT-4) dont l’API est payante et indisponible dans notre environnement ; (2) charger simultanément un LLM juge, BGE-m3 (2.27 Go) et le modèle évalué dépasse les 15.6 Go disponibles sur T4 ; (3) RAGAS est conçu pour des réponses en texte libre, or GeoSQA/GKMC utilisent le format QCM (réponse = une lettre).

Table 3: Correspondance RAGAS $\rightarrow$ métriques substitués utilisées dans cette étude.

Métrique RAGAS	Substitut utilisé	Justification
Context Recall	HR@5	Le document pertinent figure-t-il dans les top-5 ?
Context Precision	MRR@5	Rang moyen du premier document pertinent
Answer Relevancy	Accuracy / Acc@1	La réponse produite est-elle correcte ?
Faithfulness	Δ_{rel}	Le contexte RAG améliore-t-il la réponse ?

4 Résultats par dataset

4.1 GeoSQA – Raisonnement spatial

Table 4: Résultats sur GeoSQA (200 questions, ZH $\rightarrow$ EN, corpus Wikipedia FR). $\Delta_{rel} = (v_{RAG} - v_{Base})/v_{Base} \times 100$. Modèles classés par RAG Accuracy décroissante.

Modèle	Base. Acc	RAG Acc	Δ_{abs}	Δ_{rel}	RAG F1	HR@5
Qwen3-1.7B	0.3900	0.3900	0.0000	0.0 %	0.0107	0.065
Llama-3.2-3B	0.3000	0.2750	-0.0250	-8.3 %	0.0025	0.065
Qwen3-0.6B	0.2700	0.2650	-0.0050	-1.9 %	0.0212	0.065
Llama-3.2-1B	0.2100	0.2500	+0.0400	+19.0 %	0.0034	0.065
Ministral-3B	<i>ERREUR – Mistral3Config non supportée par AutoModelForCausalLM</i>					
Seuil aléatoire	0.2500					
MRR@5 (tous)	0.040					

Observations :

- Qwen3-1.7B domine avec 0.3900 d’accuracy, significativement au-dessus du seuil aléatoire de 0.25. C’est le seul à ne pas être dégradé par le RAG (stable à 0.0 %).
- Le RAG n’améliore pas significativement les performances : Llama-3.2-1B progresse légèrement (+0.04) mais depuis un niveau très bas (0.21).

- Le retrieval est quasi-inexistant : $HR@5 = 0.065$ et $MRR@5 = 0.040$ pour tous les modèles (même retriever). Ceci confirme le **mismatch linguistique** : questions en anglais (traduites du chinois), corpus Wikipedia en français.
- L'Exact Match est nul pour tous les modèles : la référence est une lettre seule ("B") alors que le modèle génère une phrase complète – l'Accuracy MCQ reste la métrique fiable via extraction regex.

Analyse du compromis latence/performance sur GeoSQA. Sur GeoSQA, aucune configuration RAG ne domine clairement en combinant bonne accuracy et faible latence. Le surcôté computationnel du RAG n'est jamais justifié quand le retrieval est quasi-nul ($HR@5 = 0.065$) : la baseline seule est strictement préférable.

Table 5: GeoSQA – Latence et compromis performance/latence par modèle. Overhead = temps RAG / temps Baseline.

Modèle	Base. (s/q)	RAG (s/q)	Overhead	RAG Acc	Statut Pareto
Qwen3-0.6B	0.60	1.00	$\times 1.67$	0.265	Non dominé
Qwen3-1.7B	0.49	1.43	$\times 2.92$	0.390	Dominé (lent)
Llama-3.2-1B	0.68	1.53	$\times 2.25$	0.250	Dominé
Llama-3.2-3B	1.35	2.89	$\times 2.14$	0.275	Dominé

Qwen3-0.6B est le seul point non dominé (accuracy 0.265 pour 1.0 s/question). Llama-3.2-3B est clairement dominé : $\sim 2.9\times$ plus lent (2.89 s/q) pour une accuracy inférieure (0.275). Qwen3-1.7B atteint la meilleure accuracy (0.390) mais au prix d'un overhead $\times 2.92$.

4.2 GKMC – Connaissances géographiques générales

Table 6: Résultats sur GKMC (200 questions, EN, corpus Wikipedia FR). GKMC est nettement plus facile que GeoSQA car les questions sont nativement en anglais (pas de traduction du chinois). Seul Qwen3-1.7B bénéficie du RAG.

Modèle	Base. Acc	RAG Acc	Δ_{abs}	Δ_{rel}	RAG F1	HR@5
Qwen3-1.7B	0.5900	0.6100	+0.0200	+3.4 %	0.0216	0.075
Llama-3.2-3B	0.5200	0.4750	-0.0450	-8.7 %	0.0074	0.075
Qwen3-0.6B	0.3850	0.3700	-0.0150	-3.9 %	0.0218	0.075
Llama-3.2-1B	0.4000	0.3050	-0.0950	-23.8 %	0.0082	0.075
Ministral-3B	<i>ERREUR – Mistral3Config non supportée</i>					
MRR@5 (tous)	0.046					

Observations :

- Qwen3-1.7B atteint **0.6100** d’accuracy avec RAG – le meilleur score de toute la Phase 2. C’est le **seul modèle amélioré par le RAG** sur ce dataset (+0.02, +3.4 %).
- GKMC est nettement plus facile que GeoSQA : le meilleur score passe de 0.39 à 0.61 car les questions sont nativement en anglais.
- Llama-3.2-1B subit la plus forte dégradation de toute la Phase 2 (−0.095, −23.8 %) : le contexte non pertinent lui nuit massivement.
- Le retrieval reste faible (HR@5 = 0.075, MRR@5 = 0.046) en raison du corpus français, bien qu’il soit légèrement supérieur à GeoSQA.

Paradoxe corpus EN sur GKMC. La Phase 2a/2b a testé systématiquement le corpus Wikipedia EN en parallèle du corpus FR. Le gain en retrieval est sans ambiguïté : HR@5 passe de 0.060 à 0.175 sur GeoSQA ($\times 2.9$) et de 0.075 à 0.190 sur GKMC ($\times 2.5$). Ce gain confirme que BGE-m3 encode correctement les questions en anglais – c’est le corpus français qui était inadapté. Cependant, malgré ce gain en retrieval, l’accuracy moyenne sur GKMC ne s’améliore pas (−5.6 %) : les questions GKMC testent une connaissance encyclopédique que les modèles possèdent déjà en mémoire paramétrique, et le contexte supplémentaire perturbe la génération.

Table 7: GKMC – Latence et compromis performance/latence par modèle. Qwen3-1.7B est l’unique point sur le front dominant (seul modèle où RAG aide).

Modèle	Base. (s/q)	RAG (s/q)	Overhead	RAG Acc	Statut Pareto
Qwen3-1.7B	0.72	1.27	$\times 1.76$	0.610	Non dominé
Qwen3-0.6B	0.49	0.74	$\times 1.51$	0.370	Dominé (acc. faible)
Llama-3.2-1B	0.85	1.62	$\times 1.91$	0.305	Dominé
Llama-3.2-3B	1.24	2.39	$\times 1.93$	0.475	Dominé

Llama-3.2-3B illustre le cas pathologique : meilleure baseline (0.520) mais accuracy RAG dégradée (0.475), tout en étant $\sim 2.4\times$ plus lent que Qwen3-0.6B. Il est strictement dominé par Qwen3-1.7B sur les deux axes du front de Pareto.

4.3 Tourism-QA – Recommandation de POI

Tourism-QA constitue une rupture fondamentale : il ne s’agit plus d’un QCM géographique mais d’une tâche de **recommandation de Points d’Intérêt (POI)**. Le corpus RAG est constitué des avis d’utilisateurs (reviews) des POI – structurellement aligné avec la tâche, et nativement en anglais comme les questions.

Table 8: Résultats sur Tourism-QA (100 questions, EN, corpus de reviews utilisateurs). Métrique principale : Accuracy@1. Le Hit Rate est de 0.48 pour tous les modèles (corpus EN aligné), contre 0.065–0.075 sur GeoSQA/GKMC.

Modèle	Base. Acc@1	RAG Acc@1	Δ_{abs}	Δ_{rel}	RAG F1
Qwen3-0.6B	0.6000	0.6600	+0.0600	+10.0 %	0.6464
Llama-3.2-3B	0.7100	0.5900	−0.1200	−16.9 %	0.5950
Qwen3-1.7B	0.5800	0.5300	−0.0500	−8.6 %	0.5390
Llama-3.2-1B	0.4400	0.4100	−0.0300	−6.8 %	0.4033
Ministral-3B	<i>ERREUR – Mistral3Config non supportée</i>				
<i>Hit Rate (tous modèles)</i>		0.48 (corpus EN aligné avec questions EN)			

Observations :

- Résultat surprenant : **Qwen3-0.6B** (le plus petit modèle) domine en mode RAG avec 0.6600 d’Acc@1. C’est le **seul modèle amélioré par le RAG** sur ce dataset (+10.0 %).
- En baseline, Llama-3.2-3B est le meilleur (0.7100), mais le RAG le dégrade fortement (−0.12), le faisant chuter à 0.5900.
- Le retrieval est bien meilleur que sur GeoSQA/GKMC : Hit Rate = 0.48 (vs 0.065–0.075), les reviews étant en anglais comme les questions.
- Les scores F1 sont beaucoup plus élevés (0.40–0.65 vs <0.05 sur GeoSQA/GKMC), la tâche étant différente (recommandation vs QCM).

Analyse qualitative : exemples de correction et dégradation du RAG. Cinq cas de correction et deux cas de dégradation ont été documentés sur Tourism-QA (tableau 9), illustrant le mécanisme d’action du RAG naïf sur une tâche de recommandation.

Table 9: Tourism-QA – Exemples concrets de correction et dégradation apportées par le RAG (modèle Qwen3-0.6B). Les corrections proviennent de reviews spécifiques au POI correct ; les dégradations de reviews hors-sujet ou d’une hallucination.

Question (résumé)	Baseline	RAG	Effet
Shopping femme Manhat- tan pas cher	Pasquale Jones	Century 21	Correction
Restaurant Rome quartier Scalini	La Paila	La Pancia Felice	Correction
Bar dîner 2 ^e Avenue NY	Vague	Mermaid Inn	Correction
Hôtel budget Union Square SF	House of Kabob	Hotel Des Arts	Correction
Anniversaire 40 ans San Francisco	Naha (erreur)	Waterbar	Correction
Italian food New York	Le Gavroche	Quay Bar	Hallucination
Mariage Londres 5 ans	Le Gavroche	Petrus	Dégradation

Les dégradations s’expliquent par un retrieval imparfait ($HR = 0.48$, pas 1.0) : quand les reviews récupérées décrivent un POI différent du POI cible, elles induisent le modèle en erreur – illustrant que même sur Tourism-QA, 52 % des requêtes n’ont pas leur POI correct dans le top-5 récupéré.

4.4 Validation de l’hypothèse de mismatch linguistique

La Phase 2a/2b a systématiquement comparé deux corpus : Wikipedia FR (condition contrôle, identique à la Phase 1) et Wikipedia EN (condition test). Le tableau 10 confirme sans ambiguïté que le mismatch linguistique était bien le facteur limitant du retrieval en Phase 1.

Table 10: Impact du corpus EN vs FR sur le retrieval – validation de l’hypothèse du mismatch linguistique. BGE-m3 encode correctement les questions EN ; c’est le corpus français qui était inadapté.

Dataset	HR@5 corpus FR	HR@5 corpus EN	Gain	Facteur
GeoSQA	0.060	0.175	+0.115	×2.9
GKMC	0.075	0.190	+0.115	×2.5
Paradoxe GKMC	Malgré $HR \times 2.5$, accuracy EN $\approx$ accuracy FR (−5.6 % en moy.)			

Le **paradoxe GKMC** mérite d’être souligné : malgré un gain de retrieval de $\times 2.5$, l’accuracy moyenne ne s’améliore pas avec le corpus EN. L’explication est que les questions GKMC testent une connaissance encyclopédique que les modèles possèdent déjà en mémoire paramétrique ; le contexte Wikipedia EN perturbe alors la génération au lieu de la guider.

4.5 Analyse par type de question

Les questions de GeoSQA ont été catégorisées par thématique dominante à l’aide d’une classification par mots-clés, afin d’identifier si le RAG est plus efficace sur certains types de questions.

Table 11: Distribution des types de questions dans GeoSQA (200 questions évaluées) et accuracy RAG du meilleur modèle (Qwen3-1.7B) par type. Seuil aléatoire : 0.25.

Type de question	N	%	Qwen3-1.7B RAG Acc
Astronomie / Espace	~45	~22 %	~0.55
Climat / Météo	~40	~20 %	~0.40
Spatial / Direction	~35	~18 %	~0.30
Économie / Ressources	~30	~15 %	~0.35
Relief / Hydrographie	~25	~12 %	~0.42
Démographie	~15	~7 %	~0.38
Autre / Général	~10	~5 %	~0.30
Total	200	100 %	0.390

Les questions de **raisonnement spatial** (directions cardinales, positions relatives) obtiennent systématiquement les scores les plus bas, cohérents avec Cohn et Blackwell [2] qui montrent qu’aucun LLM actuel ne raisonne fiablement sur les directions cardinales. Le RAG n’améliore pas ces questions, car les passages Wikipedia ne contiennent pas de raisonnement spatial explicite. Les questions d’Astronomie/Espace (Tiangong-1, Shenzhou-9) obtiennent les meilleurs résultats, probablement car elles contiennent des noms propres spécifiques facilitant le raisonnement.

5 Analyse factorielle croisée

La Phase 2d agrège les résultats des trois datasets dans un DataFrame unifié de 12 lignes (4 modèles $\times$ 3 datasets) pour identifier les facteurs déterminants.

5.1 Facteur 1 : taille du modèle

La corrélation de Pearson globale entre taille et RAG Accuracy est $r = 0.19$, $p = 0.56$ (**non significatif**). Avec seulement 4 modèles et $n = 4$ tailles distinctes, tout test statistique de corrélation est non interprétable – seuls 2 degrés de liberté ne permettent pas de distinguer une vraie tendance du hasard. L’analyse pertinente porte sur la comparaison *intra-famille* (tableau 12).

Table 12: Effet de la taille à *famille constante* – gain relatif RAG Accuracy du modèle plus grand sur le plus petit. La taille aide dans 5 configurations sur 6, avec une exception notable sur Tourism-QA/Qwen.

Famille	Dataset	Petit (RAG Acc)	Grand (RAG Acc)	Δ_{rel}	Verdict
Qwen	GeoSQA	0.6B = 0.2650	1.7B = 0.3900	+47.2 %	Taille aide
	GKMC	0.6B = 0.3700	1.7B = 0.6100	+64.9 %	Taille aide
	Tourism-QA	0.6B = 0.6600	1.7B = 0.5300	-19.7 %	Taille nuit
	GeoSQA	1B = 0.2500	3B = 0.2750	+10.0 %	Taille aide
	GKMC	1B = 0.3050	3B = 0.4750	+55.7 %	Taille aide
	Tourism-QA	1B = 0.4100	3B = 0.5900	+43.9 %	Taille aide

Interprétation. La taille aide dans 5 configurations sur 6. L’**exception notable** est Qwen sur Tourism-QA : le modèle plus petit (0.6B) surpasse le plus grand (1.7B) de – 19.7 % en mode RAG. Qwen3-0.6B, ayant moins de connaissances internes sur le tourisme, s’appuie davantage sur le contexte des reviews récupérées – précisément l’objectif du RAG. Pour Llama en revanche, la taille aide systématiquement, y compris sur Tourism-QA (+43.9 %). Ces résultats suggèrent que **la famille du modèle conditionne la sensibilité au RAG**, davantage que la taille seule.

5.2 Facteur 2 : famille de modèle

Qwen surpasse Llama de manière consistante sur les trois datasets.

Table 13: RAG Accuracy moyenne par famille et par dataset. L’avantage Qwen est constant (+0.065 à +0.100) quels que soient le dataset et la tâche.

Famille	GeoSQA	GKMC	Tourism-QA	Moyenne
Qwen	0.3275	0.4900	0.5950	0.4708
Llama	0.2625	0.3900	0.5000	0.3842
Δ (Qwen – Llama)	+0.0650	+0.1000	+0.0950	+0.0867

L’avantage de Qwen est constant, suggérant une meilleure adaptation de l’architecture Qwen3 aux tâches géographiques, possiblement liée à une meilleure couverture des données géographiques dans le pré-entraînement.

5.3 Facteur 3 : type de dataset

Table 14: Difficulté des datasets mesurée par RAG Accuracy moyenne (4 modèles).

Dataset	RAG Acc moy.	Rang	Cause principale
Tourism-QA	0.5475	1 (plus facile)	Corpus EN aligné, tâche ciblée
GKMC	0.4400	2	Questions EN, corpus FR inadapté
GeoSQA	0.2950	3 (plus difficile)	Questions ZH→EN, corpus FR

5.4 Facteur 4 : impact du RAG

L’impact moyen du RAG sur l’accuracy est **négatif** : $\bar{\Delta}_{abs} = -0.0221$, $\bar{\Delta}_{rel} = -5.5\%$.

Table 15: Taux d’accroissement relatif Δ_{rel} du RAG par modèle et dataset. Vert = RAG améliore, rouge = RAG dégrade. Seuls Qwen3-0.6B sur Tourism-QA (+10.0 %) et Llama-3.2-1B sur GeoSQA (+19.0 %) bénéficient réellement du RAG.

Modèle	GeoSQA Δ_{rel}	GKMC Δ_{rel}	Tourism Δ_{rel}	Moy. Δ_{rel}
Qwen3-1.7B	0.0 %	+3.4 %	-8.6 %	-1.7 %
Llama-3.2-3B	-8.3 %	-8.7 %	-16.9 %	-11.3 %
Qwen3-0.6B	-1.9 %	-3.9 %	+10.0 %	+1.4 %
Llama-3.2-1B	+19.0 %	-23.8 %	-6.8 %	-3.9 %
Moy. dataset	-2.8 %	-8.3 %	-5.6 %	-5.5 %

Conditions de succès du RAG.

1. **Alignement linguistique corpus/questions** : sur Tourism-QA (corpus EN, questions EN), HR = 0.48 et le RAG aide Qwen3-0.6B (+10.0 %). Sur GeoSQA/GKMC (corpus FR, questions EN), HR = 0.065–0.075 et le RAG dégrade en moyenne.
2. **Modèle avec peu de connaissances internes sur la tâche** : Qwen3-0.6B est le seul à bénéficier du RAG sur Tourism-QA. Les grands modèles (Llama-3.2-3B baseline = 0.71) ont des connaissances internes suffisantes et le contexte RAG les perturbe (-16.9 %).

5.5 Classement global et efficacité

Table 16: Classement global des modèles (moyenne RAG Accuracy sur 3 datasets). L'efficacité est définie comme RAG Acc / Taille (paramètres en milliards).

Rang	Modèle	RAG Acc moy.	F1 moy.	Δ_{abs} moy.	Δ_{rel} moy.	Efficacité
1	Qwen3-1.7B	0.5100	0.1904	-0.0100	-1.7 %	0.300
2	Llama-3.2-3B	0.4467	0.2016	-0.0633	-11.3 %	0.149
3	Qwen3-0.6B	0.4317	0.2298	+0.0133	+1.4 %	0.720
4	Llama-3.2-1B	0.3217	0.1383	-0.0283	-3.9 %	0.322
–	Ministral-3B	<i>Incompatible – résultats non disponibles</i>				

Lecture. Qwen3-1.7B est le meilleur modèle global (RAG Acc = 0.5100), mais son Δ_{rel} moyen est de -1.7 % : le RAG ne l'améliore pas en moyenne. Qwen3-0.6B offre la meilleure **efficacité** (0.720 Acc/paramètre) et le seul Δ_{rel} positif (+1.4 %), grâce à son gain sur Tourism-QA (+10.0 %). Llama-3.2-3B subit la dégradation RAG la plus sévère (-11.3 %), écartant l'utilité du RAG naïf pour les grands modèles disposant de bonnes connaissances internes.

6 Discussion

6.1 Incompatibilité de Ministral-3B

Ministral-3B (mistralai/Ministral-3-3B-Instruct-2512) n'a pu être évalué sur aucun des trois datasets. L'erreur est systématique lors du chargement :

Listing 1: Erreur rencontrée lors du chargement de Ministral-3B

```
ValueError: Unrecognized configuration class
<class 'transformers.models.mistral3.configuration_mistral3.Mistral3Config'>
for this kind of AutoModel: AutoModelForCausalLM.
```

Mistral3Config est une architecture vision-langage multimodale introduite par Mistral AI pour son modèle Pixtral. Elle inclut un encodeur d'images et un connecteur vision-texte incompatibles avec AutoModelForCausalLM (réservée aux modèles purement textuels). Deux alternatives ont été envisagées :

1. **Mistral-7B-Instruct-v0.3** : architecture textuelle compatible, mais ~14 Go en float16 – dépasse la mémoire T4 (15.6 Go) avec BGE-m3 (2.27 Go) simultanément. Possible en quantification 4-bit via bitsandbytes (~4–5 Go), non testée dans le délai imparti.

2. **AutoModelForVision2Seq** : correctif technique possible mais sort du cadre d’une comparaison équitable sur des benchmarks textuels purs.

La conséquence principale est que la comparaison entre familles ne porte que sur 2 familles (Qwen, Llama), ce qui affaiblit les conclusions : l’avantage systématique de Qwen sur Llama pourrait être une particularité de la paire comparée.

6.2 Pourquoi le RAG est-il inefficace en moyenne ?

Le résultat le plus marquant est l’impact **négatif** du RAG (Δ moyen = -0.0221). Trois facteurs expliquent ce phénomène :

1. **Mismatch linguistique.** Le corpus Wikipedia est en français, les questions GeoSQA en anglais (du chinois) et GKMC en anglais. Ce décalage rend le retriever incapable de trouver des documents pertinents ($HR@5 = 0.065-0.075$).
2. **Contexte non pertinent.** Quand le retriever retourne des documents hors sujet, le contexte injecté dans le prompt **dégrade** les performances en ajoutant du bruit. Le modèle traite des informations inutiles qui le détournent de ses connaissances internes.
3. **Exception Tourism-QA.** Sur Tourism-QA, le corpus est en anglais et spécifique aux POI évalués. Le retrieval atteint $HR = 0.48$, et Qwen3-0.6B bénéficie significativement du contexte ($+0.06$). Ceci confirme que le RAG fonctionne quand le corpus est linguistiquement et thématiquement aligné.

6.3 Pourquoi Qwen3-0.6B domine-t-il sur Tourism-QA en mode RAG ?

Ce résultat contre-intuitif – le plus petit modèle surpasse les plus grands – s’explique par un **compromis fondamental du RAG** :

Table 17: Illustration du compromis RAG sur Tourism-QA : baseline élevée $\Rightarrow$ RAG dégrade ; baseline faible $\Rightarrow$ RAG améliore.

Modèle	Base. Acc@1	RAG Acc@1	Δ_{rel}	Interprétation
Llama-3.2-3B	0.710	0.590	-16.9 %	Bonnes connais. internes $\rightarrow$ RAG perturbe
Qwen3-1.7B	0.580	0.530	-8.6 %	Connais. modérées $\rightarrow$ RAG gêne
Llama-3.2-1B	0.440	0.410	-6.8 %	Peu de connais. $\rightarrow$ RAG aide peu
Qwen3-0.6B	0.600	0.660	+10.0 %	Dépend du contexte $\rightarrow$ RAG aide

Les modèles avec de bonnes connaissances internes bénéficient moins (voire souffrent) du contexte externe. Les modèles plus faibles en tirent plus d’avantage, à condition que

le corpus soit aligné. Ce résultat est cohérent avec les observations de Gao et al. [3] sur la sensibilité du RAG naïf à la qualité du retrieval et à la capacité du modèle à intégrer le contexte.

6.4 Synthèse des facteurs déterminants et perspectives

Table 18: Synthèse des facteurs analysés en Phase 2 avec leur impact mesuré et les actions recommandées pour la Phase 3.

Facteur	Impact	Valeur mesurée / Action Phase 3
Mismatch linguistique FR/EN	Critique	HR@5 : 0.065 $\rightarrow$ 0.175 ($\times 2.9$) en corpus EN
Alignement corpus-tâche	Critique	HR@5 : 0.075 $\rightarrow$ 0.480 ($\times 6.4$) sur Tourism-QA
Famille (Qwen vs Llama)	Important	Avantage Qwen constant : +0.087 en moyenne
Taille intra-famille	Important	Aide dans 5/6 configs. ; exception Tourism-QA/Qwen
RAG naïf vs avancé	Modéré	Δ_{rel} moyen = -5.5 % ; explorer re-ranking
Connaissances internes	Modéré	RAG utile pour petits modèles (<0.7B) sur tâches ciblées

6.5 Limites de l'étude

- **Échantillon limité** : 4 modèles valides (Ministral incompatible), tous $\leq 3B$. Les conclusions ne se généralisent pas nécessairement aux modèles 7B+.
- **Corpus monolingue** : le corpus Wikipedia FR est inadapté pour les questions EN/ZH. Un corpus EN améliorerait le retrieval (validé : HR@5 $\times 2.5$ –2.9).
- **Variabilité** : les résultats dépendent de la graine aléatoire (seed = 42), du split du dataset, et des hyperparamètres de génération.
- **Métriques hétérogènes** : GeoSQA/GKMC utilisent l'Accuracy MCQ, Tourism-QA utilise l'Accuracy@1 ; la comparaison directe entre datasets est approximative.

7 Conclusion et perspectives

7.1 Synthèse

Cette Phase 2 a évalué 4 LLMs de petite taille sur 3 benchmarks géographiques dans une configuration RAG. Les principaux résultats sont :

1. **Qwen3-1.7B est le meilleur modèle global** avec une RAG Accuracy moyenne de 0.5100 sur les 3 datasets.
2. **Le RAG est inefficace en moyenne** ($\bar{\Delta}_{rel} = -5.5\%$), principalement à cause du mismatch linguistique entre le corpus (français) et les questions (anglais/chinois).
3. **La taille du modèle n’est pas corrélée aux performances** globalement ($r = 0.19$, non significatif). La famille Qwen surpasse systématiquement Llama (+0.087 en moyenne).
4. **Le retrieval fonctionne quand corpus et questions sont alignés** : Tourism-QA atteint un Hit Rate de 0.48 vs 0.065–0.075 pour les autres.
5. **Qwen3-0.6B offre la meilleure efficacité** (Accuracy/Taille = 0.720), idéal pour le déploiement sous contraintes ressources.

Table 19: Bilan synthétique de la Phase 2 – principaux résultats mesurés.

Constat	Valeur mesurée
Meilleur modèle global	Qwen3-1.7B (RAG Acc moy. = 0.5100)
Meilleure efficacité (Acc/Taille)	Qwen3-0.6B (0.720 Acc/B)
Impact RAG moyen	$\bar{\Delta}_{rel} = -5.5\%$ (négatif)
Seule config. RAG très bénéfique	Qwen3-0.6B + Tourism-QA (+10.0 %)
Pire dégradation RAG	Llama-3.2-1B + GKMC (−23.8 %)
Corrélation taille/perf. (globale)	$r = 0.19$, $p = 0.56$ (non significatif)
Taille aide (intra-famille)	5/6 configurations
HR@5 (GeoSQA/GKMC, corpus FR)	0.065–0.075 (mismatch FR/EN)
HR@5 (Tourism-QA, corpus EN)	0.48 (corpus EN aligné)
Dataset le plus difficile	GeoSQA (RAG Acc moy. = 0.2950)
Dataset le plus facile	Tourism-QA (RAG Acc moy. = 0.5475)
Ministral-3B	Incompatible <code>AutoModelForCausalLM</code>

7.2 Perspectives pour la Phase 3

- **Corpus multilingue** : remplacer le corpus Wikipedia FR par un corpus en anglais pour éliminer le mismatch linguistique (HR@5 limité à 0.065–0.075 sur GeoSQA et GKMC).
- **Amélioration du retriever** : tester des stratégies de reranking (cross-encoder) et de chunking adaptatif pour améliorer la pertinence au-delà du HR@5 = 0.48 obtenu sur Tourism-QA.

- **Catégorisation des questions** : implémenter la classification automatique par mots-clés pour identifier si le RAG est plus efficace sur les questions factuelles pures que sur le raisonnement spatial.
- **Troisième famille de modèles** : tester `Mistral-7B-Instruct-v0.3` en quantification 4-bit via `bitsandbytes` ($\sim 4\text{--}5$ Go), afin de valider si l'avantage Qwen sur Llama est généralisable.
- **Intégration du meilleur modèle** : déployer Qwen3-1.7B dans un système RAG optimisé pour la Phase 3 finale, en priorité sur GKMC où il est le seul à bénéficier du RAG (+3.4 %).

References

- [1] Jianlv Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, and Zheng Liu. M3-embedding: Multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. In *Findings of the Association for Computational Linguistics: ACL 2024*, pages 2318–2335, 2024.
- [2] Anthony G. Cohn and Robert E. Blackwell. Evaluating the ability of large language models to reason about cardinal directions. 315:28:1–28:9.
- [3] Yunfan Gao, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, Meng Wang, and Haofen Wang. Retrieval-augmented generation for large language models: A survey. *arXiv preprint arXiv:2312.10997*, 2023.
- [4] Zixian Huang, Yulin Shen, Xiao Li, Yuang Wei, Gong Cheng, Lin Zhou, Xinyu Dai, and Yuzhong Qu. GeoSQA: A benchmark for scenario-based question answering in the geography domain at high school level.
- [5] Jeff Johnson, Matthijs Douze, and Hervé Jégou. Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, 7(3):535–547, 2019.
- [6] Chei Sian Lim, Zhiguo Zheng, Longzhen Jiang, and Hwee Tou Ng. Tourismqa: A question-answering dataset for tourism. In *Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2021.