



Un Système Question-Réponse en Géographie

Phase 2 — Comparaison Multi-LLMs

Projet GeoR2LLMs

Réalisé par :

Hiba L'MOUDDEN

Feras MAKHLOUF

Osama BAAZZI

Mohamed DIALLO

Ousama BOUTEZROUT

Sous la direction de :

Lynda TAMINE-LECHANI

IRIT – Institut de Recherche en Informatique de Toulouse

Master 2 Intelligence Artificielle
Université Toulouse III – Paul Sabatier

Année universitaire 2024–2025

Table des matières

1	Introduction	2
2	Méthodologie	2
2.1	Modèles évalués	2
2.2	Datasets	2
2.3	Architecture RAG commune	3
2.4	Protocole d'évaluation	3
2.5	Configuration expérimentale	3
3	Résultats par dataset	4
3.1	GeoSQA — Raisonnement spatial	4
3.2	GKMC — Connaissances géographiques générales	5
3.3	Tourism-QA — Recommandation de POI	6
4	Analyse factorielle croisée	7
4.1	Effet de la taille du modèle	8
4.2	Effet de la famille	8
4.3	Effet du dataset	9
4.4	Impact du RAG	9
4.5	Classement global	10
4.6	Heatmap croisée	11
5	Discussion	12
5.1	Pourquoi le RAG est-il inefficace ?	12
5.2	Pourquoi Qwen3-0.6B domine-t-il sur Tourism-QA ?	12
5.3	Limites de l'étude	13
6	Conclusion et perspectives	13
6.1	Synthèse	13
6.2	Perspectives pour la Phase 3	13

1 Introduction

Ce rapport présente les résultats de la **Phase 2** du projet GeoR2LLMs, dont l’objectif est de comparer les performances de plusieurs modèles de langue (LLMs) de petite taille dans une configuration de génération augmentée par recherche d’information (RAG) pour la question-réponse géographique.

La Phase 1 [1] avait établi un pipeline RAG de référence avec un seul modèle (Qwen3-0.6B) sur le dataset GeoSQA, révélant des performances limitées (accuracy proche du hasard) et un retrieval quasi-inexistant. La Phase 2 étend cette évaluation à **5 LLMs** sur **3 datasets** géographiques distincts pour répondre aux questions suivantes :

1. **Quel modèle est le plus performant** pour le QA géographique avec RAG ?
2. **Quel est l’impact du RAG** sur les performances par rapport au baseline (LLM seul) ?
3. **La taille du modèle** est-elle corrélée aux performances ?
4. **Les résultats sont-ils cohérents** entre différents types de benchmarks ?

2 Méthodologie

2.1 Modèles évalués

Cinq LLMs de petite taille (0.6B à 3B paramètres) ont été sélectionnés, couvrant trois familles distinctes (Tableau 1).

TABLE 1 – Modèles LLM évalués dans la Phase 2.

Modèle	Famille	Taille	Identifiant HuggingFace
Qwen3-0.6B	Qwen	0.6B	Qwen/Qwen3-0.6B
Qwen3-1.7B	Qwen	1.7B	Qwen/Qwen3-1.7B
Llama-3.2-1B	Llama	1.0B	meta-llama/Llama-3.2-1B-Instruct
Llama-3.2-3B	Llama	3.0B	meta-llama/Llama-3.2-3B-Instruct
Ministral-3B	Mistral	3.0B	mistralai/Ministral-3-3B-Instruct-2512

Note : Ministral-3B utilise une configuration Mistral3Config non supportée par AutoModelForCausalLM de la bibliothèque Transformers. Ce modèle n’a donc pu être évalué sur aucun des trois datasets. Seuls **4 modèles** ont produit des résultats exploitables.

2.2 Datasets

Trois benchmarks géographiques de nature différente ont été utilisés (Tableau 2).

TABLE 2 – Datasets utilisés pour l'évaluation.

Dataset	Questions	Langue	Tâche	Corpus RAG
GeoSQA	200	ZH → EN	QCM (A/B/C/D)	Wikipedia FR
GKMC	200	EN	QCM (A/B/C/D)	Wikipedia FR
Tourism-QA	100	EN	Recommandation POI	Reviews utilisateurs

GeoSQA [1] contient des questions de raisonnement spatial traduites du chinois. GKMC porte sur des connaissances géographiques générales en anglais. Tourism-QA évalue la recommandation de points d'intérêt (POI) à partir de requêtes touristiques.

2.3 Architecture RAG commune

Tous les modèles partagent la même architecture RAG (Figure 1).




FIGURE 1 – Architecture RAG commune à toutes les évaluations. Le retriever (BAAI/bge-m3) encode la question et recherche les $k = 5$ chunks les plus similaires via FAISS (Index-FlatIP). Le générateur (LLM) produit la réponse à partir de la question et du contexte récupéré.

2.4 Protocole d'évaluation

Chaque modèle est évalué dans deux conditions :

- **Baseline** — le LLM seul, sans contexte RAG.
- **RAG** — le LLM avec le contexte des top-5 documents récupérés.

Les métriques utilisées sont :

- **Accuracy (MCQ)** — pourcentage de lettres correctes (A/B/C/D) pour GeoSQA et GKMC.
- **Accuracy@1** — le premier POI recommandé est-il correct ? (Tourism-QA).
- **F1** — score F1 au niveau des tokens entre prédiction et vérité terrain.
- **Hit Rate@k** — la réponse apparaît-elle dans les top- k documents récupérés ?
- **MRR@5** — Mean Reciprocal Rank sur les 5 premiers documents.

2.5 Configuration expérimentale

Les expériences ont été réalisées sur Google Colab avec un GPU NVIDIA Tesla T4 (16 Go VRAM). Les paramètres communs sont : graine aléatoire = 42, top- $k = 5$, taille de chunk = 512 tokens, chevauchement = 50 tokens, corpus de 300 articles Wikipedia FR (GeoSQA/GKMC) ou reviews utilisateurs (Tourism-QA).

3 Résultats par dataset

3.1 GeoSQA — Raisonnement spatial

Le Tableau 3 présente les résultats sur GeoSQA (200 questions).

TABLE 3 – Résultats sur GeoSQA (200 questions, chinois $\rightarrow$ anglais, corpus Wikipedia FR).

Modèle	Base. Acc	RAG Acc	Δ Acc	RAG F1	HR@5	MRR@5
Qwen3-1.7B	0.3900	0.3900	+0.0000	0.0107	0.065	0.040
Llama-3.2-3B	0.3000	0.2750	−0.0250	0.0025	0.065	0.040
Qwen3-0.6B	0.2700	0.2650	−0.0050	0.0212	0.065	0.040
Llama-3.2-1B	0.2100	0.2500	+0.0400	0.0034	0.065	0.040
Ministral-3B	<i>ERREUR — Mistral3Config non supportée</i>					

Observations :

- Qwen3-1.7B domine avec 0.3900 d'accuracy (proche du hasard à 0.25 pour un QCM à 4 choix).
- Le RAG n'améliore aucun modèle significativement. Llama-3.2-1B est le seul à progresser légèrement (+0.04).
- Le retrieval est quasi-inexistant : Hit Rate@5 = 0.065 et MRR@5 = 0.040 pour tous les modèles (même retriever). Ceci s'explique par le **mismatch linguistique** : les questions sont en anglais (traduites du chinois) alors que le corpus Wikipedia est en français.
- L'Exact Match est à 0.0 pour tous les modèles.





FIGURE 2 – GeoSQA — Accuracy Baseline vs RAG par modèle.

FIGURE 3 – GeoSQA — Amélioration (Δ) apportée par le RAG.

3.2 GKMC — Connaissances géographiques générales

Le Tableau 4 présente les résultats sur GKMC (200 questions).

TABLE 4 – Résultats sur GKMC (200 questions, anglais, corpus Wikipedia FR).

Modèle	Base. Acc	RAG Acc	Δ Acc	RAG F1	HR@5	MRR@5
Qwen3-1.7B	0.5900	0.6100	+0.0200	0.0216	0.075	0.046
Llama-3.2-3B	0.5200	0.4750	-0.0450	0.0074	0.075	0.046
Llama-3.2-1B	0.4000	0.3050	-0.0950	0.0082	0.075	0.046
Qwen3-0.6B	0.3850	0.3700	-0.0150	0.0218	0.075	0.046
Ministral-3B	<i>ERREUR — Mistral3Config non supportée</i>					

Observations :

- Qwen3-1.7B atteint **0.6100** d'accuracy avec RAG — le meilleur score de toute la Phase 2. C'est aussi le seul modèle amélioré par le RAG (+0.02).
- GKMC est nettement plus facile que GeoSQA : le meilleur score passe de 0.39 à 0.61, car les questions sont en anglais (pas de barrière de traduction du chinois).
- Llama-3.2-1B subit la plus forte dégradation (-0.095), passant de 0.40 à 0.305.
- Le retrieval reste faible ($\text{HR@5} = 0.075$, $\text{MRR@5} = 0.046$) en raison du corpus français.





FIGURE 4 – GKMC — Accuracy Baseline vs RAG par modèle.

FIGURE 5 – GKMC — Amélioration (Δ) apportée par le RAG.

3.3 Tourism-QA — Recommandation de POI

Le Tableau 5 présente les résultats sur Tourism-QA (100 questions).

TABLE 5 – Résultats sur Tourism-QA (100 questions, anglais, corpus de reviews).

Modèle	Base. Acc@1	RAG Acc@1	Δ Acc@1	RAG F1	Retr. HR
Qwen3-0.6B	0.6000	0.6600	+0.0600	0.6464	0.48
Llama-3.2-3B	0.7100	0.5900	-0.1200	0.5950	0.48
Qwen3-1.7B	0.5800	0.5300	-0.0500	0.5390	0.48
Llama-3.2-1B	0.4400	0.4100	-0.0300	0.4033	0.48
Ministral-3B	<i>ERREUR — Mistral3Config non supportée</i>				

Observations :

- Résultat surprenant : **Qwen3-0.6B** (le plus petit modèle) domine en mode RAG avec 0.6600 d'Acc@1. C'est aussi le seul modèle amélioré par le RAG (+0.06).
- En baseline, Llama-3.2-3B est le meilleur (0.7100), mais le RAG le dégrade fortement (−0.12), le faisant chuter à 0.5900.
- Le retrieval est bien meilleur que sur GeoSQA/GKMC : Hit Rate = 0.48 (vs 0.065–0.075). Les reviews sont en anglais, comme les questions, éliminant le mismatch linguistique.
- Les scores F1 sont beaucoup plus élevés (0.40–0.65 vs <0.05 sur GeoSQA/GKMC) car la tâche est différente (recommandation vs QCM).




FIGURE 6 – Tourism-QA — Accuracy@1 Baseline vs RAG par modèle.




FIGURE 7 – Tourism-QA — Amélioration (Δ) apportée par le RAG.

4 Analyse factorielle croisée

La Phase 2d agrège les résultats des trois datasets pour identifier les facteurs déterminants. Le DataFrame unifié contient 12 lignes (4 modèles $\times$ 3 datasets).

4.1 Effet de la taille du modèle

La corrélation de Pearson entre la taille du modèle et la RAG Accuracy, calculée sur l'ensemble des 12 configurations, est :

$$r = 0.19, \quad p = 0.56 \quad (\text{non significatif})$$

Par dataset :

- GeoSQA : $r = 0.19, p = 0.81$
- GKMC : $r = 0.52, p = 0.48$
- Tourism-QA : $r = 0.08, p = 0.92$

La tendance est positive mais la corrélation n'est **jamais significative**. Les modèles Qwen (0.6B et 1.7B) surpassent systématiquement les Llama de taille supérieure, montrant que la **famille du modèle** est un facteur plus déterminant que sa taille.




FIGURE 8 – Taille du modèle vs RAG Accuracy (tous datasets confondus).

4.2 Effet de la famille

Qwen surpasse Llama de manière consistante sur les trois datasets :

TABLE 6 – RAG Accuracy moyenne par famille et par dataset.

Famille	GeoSQA	GKMC	Tourism-QA
Qwen	0.3275	0.4900	0.5950
Llama	0.2625	0.3900	0.5000
Δ (Qwen – Llama)	+0.0650	+0.1000	+0.0950

L'avantage de Qwen est constant (+0.065 à +0.100) quels que soient le dataset et la tâche.




FIGURE 9 – Analyse par famille de modèle.

4.3 Effet du dataset

La difficulté relative des datasets (mesurée par la RAG Accuracy moyenne) est :

TABLE 7 – Difficulté des datasets (RAG Accuracy moyenne sur 4 modèles).

Dataset	RAG Acc moyenne	Classement
Tourism-QA	0.5475	1 (plus facile)
GKMC	0.4400	2
GeoSQA	0.2950	3 (plus difficile)

GeoSQA est le dataset le plus difficile, principalement en raison du mismatch linguistique (questions traduites du chinois, corpus en français). Tourism-QA bénéficie d'un corpus de reviews en anglais, aligné linguistiquement avec les questions.



FIGURE 10 – Analyse par dataset.


4.4 Impact du RAG

L'impact moyen du RAG sur l'accuracy est **négatif** : $\Delta = -0.0221$.

TABLE 8 – Impact du RAG par modèle (moyenne sur 3 datasets).

Modèle	Δ Acc moyenne	Modèles améliorés
Qwen3-0.6B	+0.0133	1/3 datasets
Qwen3-1.7B	−0.0100	1/3 datasets
Llama-3.2-1B	−0.0283	1/3 datasets
Llama-3.2-3B	−0.0633	0/3 datasets
Moyenne	−0.0221	—

Le RAG dégrade les performances dans la majorité des cas. Seul Qwen3-0.6B a un Δ moyen positif (+0.0133), grâce à son amélioration sur Tourism-QA (+0.06).

FIGURE 11 – Heatmap de l’impact du RAG (Δ Accuracy) par modèle et dataset.

4.5 Classement global

Le Tableau 9 présente le classement global (moyenne des RAG Accuracy sur les 3 datasets).

TABLE 9 – Classement global des modèles (moyenne RAG Accuracy sur 3 datasets).

Rang	Modèle	RAG Acc	F1 moy	Δ moy	σ	Efficacité
1	Qwen3-1.7B	0.5100	0.1904	−0.0100	0.1114	0.3000
2	Llama-3.2-3B	0.4467	0.2016	−0.0633	0.1594	0.1489
3	Qwen3-0.6B	0.4317	0.2298	+0.0133	0.2046	0.7195
4	Llama-3.2-1B	0.3217	0.1383	−0.0283	0.0813	0.3217

Qwen3-1.7B est le meilleur modèle global avec une RAG Accuracy moyenne de 0.5100. Qwen3-0.6B offre la meilleure **efficacité** (Accuracy/Taille = 0.7195), ce qui en fait le choix optimal sous contraintes de ressources.




FIGURE 12 – Classement final des modèles.




FIGURE 13 – Front de Pareto — Compromis performance/taille.

4.6 Heatmap croisée

La Figure 14 donne une vue d'ensemble de toutes les métriques RAG pour chaque combinaison modèle $\times$ dataset.




FIGURE 14 – Heatmap croisée — RAG Accuracy par modèle et dataset.

5 Discussion

5.1 Pourquoi le RAG est-il inefficace ?

Le résultat le plus marquant de cette Phase 2 est l'impact **négatif** du RAG (Δ moyen = -0.0221). Plusieurs facteurs expliquent ce phénomène :

1. **Mismatch linguistique.** Le corpus Wikipedia est en français, tandis que les questions GeoSQA sont en anglais (traduites du chinois) et GKMC en anglais. Ce décalage rend le retriever incapable de trouver des documents pertinents (Hit Rate@5 = 0.065–0.075 pour ces deux datasets).
2. **Contexte non pertinent.** Lorsque le retriever retourne des documents non pertinents, le contexte injecté dans le prompt **dégrade** les performances du LLM en ajoutant du bruit. Le modèle doit traiter des informations inutiles qui le détournent de ses connaissances internes.
3. **Exception Tourism-QA.** Sur Tourism-QA, le corpus de reviews est en anglais (même langue que les questions) et spécifique aux POI évalués. Le retrieval atteint un Hit Rate de 0.48, et Qwen3-0.6B bénéficie significativement du contexte (+0.06). Ceci confirme que le RAG fonctionne quand le corpus est linguistiquement et thématiquement aligné.

5.2 Pourquoi Qwen3-0.6B domine-t-il sur Tourism-QA ?

Qwen3-0.6B, le plus petit modèle, surpasse tous les autres en mode RAG sur Tourism-QA (0.6600 vs 0.5900 pour le deuxième). Deux hypothèses :

- Les modèles plus grands (Llama-3.2-3B avec 0.71 en baseline) ont déjà de bonnes connaissances internes. L'ajout de contexte RAG perturbe leur raisonnement en introduisant des informations potentiellement contradictoires.
- Qwen3-0.6B, ayant moins de connaissances internes, s'appuie davantage sur le contexte récupéré et en bénéficie.

5.3 Limites de l'étude

- **Échantillon limité** : 4 modèles valides (Ministral incompatible), tous de petite taille ($\leq 3B$). Les conclusions ne se généralisent pas nécessairement aux modèles plus grands (7B+).
- **Corpus monolingue** : Le corpus Wikipedia en français est inadapté pour des questions en anglais ou chinois. Un corpus multilingue ou en anglais améliorerait le retrieval.
- **Variabilité** : Les résultats dépendent de la graine aléatoire (seed=42), du split du dataset, et des hyperparamètres de génération.
- **Métriques hétérogènes** : GeoSQA et GKMC utilisent l'accuracy MCQ, Tourism-QA utilise l'Accuracy@1 pour la recommandation. La comparaison directe entre datasets est donc approximative.

6 Conclusion et perspectives

6.1 Synthèse

Cette Phase 2 a évalué 4 LLMs de petite taille sur 3 benchmarks géographiques dans une configuration RAG. Les principaux résultats sont :

1. **Qwen3-1.7B est le meilleur modèle global** avec une RAG Accuracy moyenne de 0.5100 sur les 3 datasets.
2. **Le RAG est inefficace** en moyenne ($\Delta = -0.0221$), principalement à cause du mismatch linguistique entre le corpus (français) et les questions (anglais/chinois).
3. **La taille du modèle n'est pas corrélée aux performances** ($r = 0.19$, non significatif). La famille Qwen surpasse systématiquement Llama.
4. **Le retrieval fonctionne quand corpus et questions sont alignés** : Tourism-QA atteint un Hit Rate de 0.48 vs 0.065–0.075 pour les autres.
5. **Qwen3-0.6B offre la meilleure efficacité** (Accuracy/Taille = 0.7195), idéal pour le déploiement sous contraintes.

6.2 Perspectives pour la Phase 3

- **Corpus multilingue** : Remplacer le corpus Wikipedia FR par un corpus en anglais ou multilingue pour éliminer le mismatch linguistique.
- **Amélioration du retriever** : Tester des stratégies de reranking (cross-encoder) et de chunking adaptatif.
- **Modèles plus grands** : Évaluer des modèles 7B+ (Qwen3-8B, Llama-3.2-8B) si les ressources GPU le permettent.
- **Intégration du meilleur modèle** (Qwen3-1.7B) dans un système RAG optimisé pour la Phase 3 finale.

Références

- [1] Zixian Huang, Yulin Shen, Xiao Li, Yuang Wei, Gong Cheng, Lin Zhou, Xinyu Dai, and Yuzhong Qu. GeoSQA : A benchmark for scenario-based question answering in the geography domain at high school level.