

GeoR2LLMs

Système Question-Réponse en Géographie
avec Génération Augmentée par la Recherche d'Information

Mohamed DIALLO Hiba L'MOUDDEN Feras MAKHLOUF Osama BAAZZI
Ousama BOUTEZROUT

Master 2 Intelligence Artificielle
Université Paul Sabatier – Toulouse III

Mars 2026

Plan

- 1 Introduction
- 2 Rappel théorique
- 3 Architecture du système
- 4 Méthodologie
- 5 Organisation et Gestion du Projet
- 6 Résultats – Étape 1
- 7 Résultats – Étape 2
- 8 Analyse factorielle croisée
- 9 Discussion
- 10 Conclusion et perspectives

Problématique

Les LLMs peinent à restituer des connaissances géographiques précises et à raisonner spatialement, même avec une température de zéro.

- Modèles $\leq 3B$ particulièrement limités en connaissances factuelles
- Le **RAG** promet de compenser ces lacunes via un contexte externe
- **Question** : Le RAG améliore-t-il réellement le QA géographique ?

Objectif

Implémenter et évaluer un système QA géographique en configuration RAG, en comparant systématiquement Baseline et RAG.

Organisation du travail

Étape 1 – Plateforme de base

- 1 LLM (Qwen3-0.6B)
- 1 dataset (GeoSQA)
- 1 corpus (Wikipedia FR)
- Objectif : pipeline fonctionnel + baseline

Étape 2 – Exploration

- 4 LLMs exploitables (+1 incompatible)
- 3 datasets géographiques
- Analyse factorielle croisée
- Objectif : identifier les facteurs de performance

Environnement : Google Colab, GPU NVIDIA T4 (16 Go VRAM)

LLMs – Transformer


- Attention multi-têtes :
$$\text{Att}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$
- Génération autorégressive (décodeur)
- Capacités émergentes (CoT, in-context learning)

RAG naïf (Retrieve-then-Read)

- LLMs ne stockent pas toutes les connaissances factuelles
- RAG externalise la mémoire dans un corpus
- Injection directe des documents dans le prompt

QA géographique : raisonnement spatial + connaissances encyclopédiques. Aucun LLM actuel ne raisonne de manière fiable sur les directions cardinales $\Rightarrow$ intérêt du RAG.

Pipeline RAG – Vue d'ensemble



Composants clés

Retriever

- **BGE-m3** (BAAI) – embeddings multilingues, 1024 dimensions
- **FAISS** IndexFlatIP – similarité cosinus
- Chunks de 512 car., overlap 50
- Top-K = 5 documents

Generator

- Prompt système : expert géographie
- Mode Baseline : pas de contexte
- Mode RAG : top-5 documents injectés
- Extraction regex de la lettre (A/B/C/D)

Evaluator

Génération : Accuracy MCQ, Exact Match, F1

Tourism-QA : Accuracy@1, F1 POI

Retrieval : Hit Rate@K, MRR@K

Prompt Baseline vs RAG

Mode Baseline (sans contexte)

system: *Tu es un expert en géographie.
Réponds uniquement avec la lettre correcte.*

user: *Question : {question}
Options : A) ... B) ... C) ... D) ...*

Mode RAG (avec contexte)

system: *Tu es un expert en géographie.
Réponds uniquement avec la lettre correcte.*

user: **Contexte : {top-5 documents}**
*Question : {question}
Options : A) ... B) ... C) ... D) ...*

La seule différence : l'injection des **top-5 documents** récupérés par le retriever.
Cela permet d'isoler précisément l'**effet du RAG** sur la performance.

Modèles évalués

Modèle	Famille	Taille	Statut
Qwen3-0.6B	Qwen (Alibaba)	0.6B	OK
Qwen3-1.7B	Qwen (Alibaba)	1.7B	OK
Llama-3.2-1B-Instruct	Llama (Meta)	1.0B	OK
Llama-3.2-3B-Instruct	Llama (Meta)	3.0B	OK
Minstral-3-3B-Instruct	Mistral	3.0B	Incompatible

Minstral-3-3B – Incompatibilité technique

Mistral3Config est une architecture vision-langage multimodale, incompatible avec AutoModelForCausalLM (modèles textuels).

Datasets géographiques

Dataset	<i>N</i>	Langue	Tâche	Corpus RAG
GeoSQA	200	ZH → EN	QCM	Wikipedia FR
GKMC	200	EN natif	QCM	Wikipedia FR
Tourism-QA	100	EN	Reco. POI	Reviews EN

GeoSQA

Raisonnement spatial, lycée
chinois, traduit EN

GKMC

Connaissances
encyclopédiques, nativement
EN

Tourism-QA

Recommandation de POI,
reviews utilisateurs

Stratégie Méthodologique et Approche Agile

- **Agilité adaptée** : Découpage du travail en sprints de production de connaissances pour maintenir la continuité scientifique.
- **Synchronisation** :
 - Réunions hebdomadaires (Google Meet) pour les points de blocage.
 - Échanges opérationnels quotidiens (WhatsApp).
- **Reproductibilité** :
 - Mise en place précoce de l'infrastructure sur GitHub.
 - Versioning du code, des prompts et des configurations.
- **Maîtrise des risques** : Identification rapide des limites du RAG naïf permettant un pivot vers une architecture hybride sans retard.

Organisation Fonctionnelle de l'Équipe

Afin de responsabiliser chaque membre sur un verrou scientifique, l'équipe s'est structurée par pôles d'expertise (selon une matrice RACI) :

- **Pilotage Scientifique** : Lynda TAMINE-LECHANI
- **Coordination & Intégration** : Feras MAKHLOUF
- **Génie Logiciel & RAG** : Hiba L'MOUDDEN
- **Raisonnement Spatial** : Mohamed DIALLO & Ousama BOUTEZROUT
- **Audit & Évaluation** : Osama BAAZZI

Planification Temporelle (Gantt)

Stratégie : Parallélisation entre une phase de recherche théorique étendue et une accélération expérimentale en fin de projet.

Période	Objectifs de la phase
Bloc 1 & 2 (S1-S4)	Gestion des flux : Acquisition théorique, état de l'art et curation du corpus.
Bloc 3 (S5-S6)	Pivot Expérimental : Évaluations, optimisation du RAG, intégration Tool-Use et architecture hybride.
Bloc 4 (S7-S8)	Audit de Qualité : Benchmark "End-to-End", réduction de la dette technique et peer-review finale.


Étape 1 – Stabilité du prompt (Qwen3-0.6B, 50 questions)

Rang	Stratégie	Accuracy
1	P1 – Prompt basique (FR)	52.0 %
2	P4 – Few-Shot 2 exemples	38.0 %
2	P5 – Prompt basique (EN)	38.0 %
4	P2 – Expert contraint (FR)	30.0 %
5	P3 – Chain-of-Thought	20.0 %
<i>Seuil aléatoire</i>		25.0 %

- Écart de **32 points** entre P1 et P3 – forte sensibilité au prompt
- Le CoT dégrade sous le seuil aléatoire (20 %) – inefficace pour 0.6B
- **Prompt P2** retenu malgré un score inférieur : il impose la lettre seule en sortie, garantissant une extraction fiable par regex

Étape 1 – Baseline vs RAG (200 questions GeoSQA)

Métrique	Base.	RAG
Accuracy	0.245	0.270
F1 Score	0.030	0.011
Temps (s)	353.6	495.6
HR@5	–	0.080
MRR@5	–	0.053



- Accuracy : **+10.2 %** relatif (5 questions de plus sur 200)
- Mais F1 chute de **-61.7 %** (corpus FR → réponses en français)
- HR@5 = 8 % ⇒ **92 %** des requêtes sans document pertinent

Étape 1 – Biais de position et analyse qualitative

Biais de position (Baseline)

Lettre	N prédictions	%
A	123	61.5 %
B	8	4.0 %
C	10	5.0 %
D	59	29.5 %
<i>Attendu</i>	50	25.0 %

Le modèle 0.6B se rabat sur la première option par défaut.

Répartition qualitative (200 q.)

Catégorie	%
Double échec	68.5 %
Les deux corrects	20.0 %
RAG sauve	7.0 %
RAG trompe	4.5 %

Le double échec domine : l'info est absente du corpus.


Étape 1 – Facteurs limitants identifiés

Facteur	Impact	Observation
Mismatch linguistique	Critique	Questions EN, corpus FR. HR@5 = 8 %
Couverture thématique	Important	Géo chinoise absente de Wikipedia FR
Taille du LLM	Important	0.6B $\approx$ seuil aléatoire (24.5 %)
Biais de position	Important	Lettre A prédite dans 61.5 % des cas

⇒ Ces facteurs motivent l'**étape 2** : modèles plus grands, datasets variés, corpus alignés.

GeoSQA – Raisonnement spatial (200 questions)

Modèle	Base.	RAG	Δ_{rel}
Qwen3-1.7B	0.390	0.335	-14.1 %
Qwen3-0.6B	0.275	0.260	-5.5 %
Llama-3.2-3B	0.270	0.230	-14.8 %
Llama-3.2-1B	0.275	0.205	-25.5 %




Constat

Le RAG dégrade **tous les modèles sans exception** sur GeoSQA.
HR@5 = 0.060 – le retriever ne trouve quasi rien (mismatch FR/EN).

GKMC – Connaissances encyclopédiques (200 questions)

Modèle	Base.	RAG	Δ_{rel}
Qwen3-1.7B	0.585	0.605	+3.4 %
Llama-3.2-3B	0.565	0.485	-14.2 %
Qwen3-0.6B	0.420	0.415	-1.2 %
Llama-3.2-1B	0.330	0.335	+1.5 %




Observations

- Qwen3-1.7B atteint **0.605** – meilleur score absolu du projet
- Llama-3.2-3B : forte dégradation malgré de bonnes connaissances internes
- Le contexte non pertinent déstabilise les modèles performants

Tourism-QA – Recommandation de POI (100 questions)

Modèle	Base.	RAG	Δ_{rel}
Qwen3-1.7B	0.590	0.590	0.0 %
Qwen3-0.6B	0.560	0.570	+1.8 %
Llama-3.2-3B	0.700	0.540	-22.9 %
Llama-3.2-1B	0.520	0.410	-21.2 %



Paradoxe Tourism-QA

- Hit Rate = **0.48** ($\times 8$ vs GeoSQA/GKMC) – le retriever fonctionne
- Pourtant, le RAG dégrade massivement les modèles Llama (-21 à -23 %)
- Les modèles Qwen résistent au contexte non pertinent

Tourism-QA – Exemples qualitatifs (Qwen3-0.6B)

Question	Baseline	RAG	Effet
Shopping femme Man- hattan pas cher	Pasquale Jones	Century 21	Correction
Restaurant Rome quar- tier Scalini	La Paila	La Pancia Fe- lice	Correction
Bar pour dîner 2 ^e Avenue NY	Vague	Mermaid Inn	Correction
Italian food New York	Le Gavroche	Quay Bar	Hallucination
Mariage Londres 5 ans	Le Gavroche	Petrus	Dégradation

- **Corrections** : le retriever récupère les reviews du bon POI
- **Dégradations** : reviews d'un autre POI → le modèle est induit en erreur

Validation du mismatch linguistique


Dataset	HR@5 corpus FR	HR@5 corpus EN	Facteur
GeoSQA	0.060	0.175	×2.9
GKMC	0.075	0.190	×2.5

Conclusion

- Le corpus EN multiplie le Hit Rate par **2.5 à 2.9**
- BGE-m3 encode correctement les questions – c'est le **corpus FR** qui est inadapté
- Mais sur GKMC, un meilleur retrieval ne suffit pas : les modèles possèdent déjà les connaissances en mémoire paramétrique

Facteur 1 – Taille du modèle

Fam.	Dataset	Petit	Grand	Δ_{rel}
Qwen	GeoSQA	0.260	0.335	+28.8 %
	GKMC	0.415	0.605	+45.8 %
	TourismQA	0.570	0.590	+3.5 %
Llama	GeoSQA	0.205	0.230	+12.2 %
	GKMC	0.335	0.485	+44.8 %
	TourismQA	0.410	0.540	+31.7 %




Résultat

La taille aide dans **6/6 configurations** sans exception, de +3.5 % à +45.8 %.

Facteur 2 – Famille de modèle


	GeoSQA	GKMC	Tourism
Qwen	0.298	0.510	0.580
Llama	0.218	0.410	0.475
Δ	+0.080	+0.100	+0.105

Avantage Qwen : **+0.095** en moyenne,
constant sur les 3 datasets.



Facteur 3 – Impact du RAG

Modèle	GeoSQA	GKMC	Tourism	Moy.
Qwen3-1.7B	-14.1	+3.4	0.0	-3.6
Llama-3.2-3B	-14.8	-14.2	-22.9	-17.3
Qwen3-0.6B	-5.5	-1.2	+1.8	-1.6
Llama-3.2-1B	-25.5	+1.5	-21.2	-15.0
Moy.	-15.0	-2.6	-10.6	-9.4



Constat central

$\bar{\Delta}_{rel} = -9.4\%$ – Le RAG naïf est **négatif en moyenne**.


3 cas positifs marginaux, 1 neutre, **8 dégradés** sur 12 configurations.

Classement global

#	Modèle	RAG Acc	Effic.
1	Qwen3-1.7B	0.510	0.300
2	Llama-3.2-3B	0.418	0.139
3	Qwen3-0.6B	0.415	0.692
4	Llama-3.2-1B	0.317	0.317

Efficacité = RAG Acc / Taille (B)

Qwen3-0.6B : meilleur ratio qualité/taille



Pourquoi le RAG est-il inefficace ?

❶ Mismatch linguistique (facteur dominant)

- Corpus FR, questions EN $\Rightarrow$ HR@5 = 0.060 – 0.075
- Corpus EN valide l'hypothèse (HR@5 $\times 2.5$ à $\times 2.9$)

❷ Contexte non pertinent

- Documents hors sujet injectés $\Rightarrow$ détournement des connaissances internes
- Llama-Instruct particulièrement sensible (suit fidèlement le contexte fourni)

❸ Exception partielle Tourism-QA

- HR = 0.48 (corpus EN aligné) mais RAG toujours négatif en moyenne
- Qwen résiste, Llama chute (-21 à -23 %) $\Rightarrow$ différence architecturale

Limites de l'étude

- **4 modèles $\leq$ 3B** uniquement – les modèles 7B+ n'ont pas pu être chargés sur le GPU T4
- **Corpus monolingue FR** pour GeoSQA et GKMC – inadapté aux questions EN
- **RAG naïf** uniquement – pas de re-ranking, pas de réécriture de requête
- **200 questions** par dataset – variance d'échantillonnage possible
- **Minstral incompatible** – comparaison inter-familles limitée à Qwen vs Llama

Bilan synthétique

Constat	Valeur mesurée
Meilleur modèle global	Qwen3-1.7B (RAG Acc = 0.510)
Meilleure efficacité	Qwen3-0.6B (0.692 Acc/B)
Impact RAG moyen	$\bar{\Delta}_{rel} = -9.4 \%$ (négatif)
Taille aide (intra-famille)	6/6 configurations
Avantage Qwen vs Llama	+0.095 (constant)
HR@5 corpus FR	0.060 – 0.075
HR@5 corpus EN (Tourism)	0.48

Enseignements et perspectives

4 enseignements clés

- ❶ Le **RAG naïf dégrade** les performances en moyenne ($\Delta_{rel} = -9.4\%$)
- ❷ La **qualité du retrieval** est le facteur déterminant ($HR@5 = 0.06 \rightarrow 0.48$)
- ❸ La **famille** importe davantage que la taille seule (Qwen > Llama)
- ❹ **Qwen résiste mieux** au contexte non pertinent que Llama

Perspectives

- **Corpus multilingue** – éliminer le mismatch linguistique
- **RAG avancé** – re-ranking par cross-encoder, réécriture de requête
- **Modèles 7B+** en quantification 4-bit (QLoRA / bitsandbytes)
- **3^e famille** – Mistral-7B-Instruct-v0.3 (architecture compatible)

Merci de votre attention

Questions ?

Code source : <https://github.com/Hiba-Lmoudden/GeoR2LLMs>
Responsable : Lynda TAMINE-LECHANI (IRIT)