

GeoR2LLMs

Système Question-Réponse en Géographie
avec Génération Augmentée par la Recherche d'Information

Mohamed DIALLO Hiba L'MOUDDEN Feras MAKHLOUF Osama BAAZZI
Ousama BOUTEZROUT

Master 2 Intelligence Artificielle
Université Paul Sabatier – Toulouse III

Mars 2026



Plan

- 1 Introduction
- 2 Rappel théorique
- 3 Architecture du système
- 4 Méthodologie
- 5 Résultats – Étape 1
- 6 Résultats – Étape 2
- 7 Analyse factorielle croisée
- 8 Discussion
- 9 Conclusion et perspectives

Problématique

Les LLMs peinent à restituer des connaissances géographiques précises et à raisonner spatialement, même avec une température de zéro.

- Modèles $\leq 3B$ particulièrement limités en connaissances factuelles
- Le **RAG** promet de compenser ces lacunes via un contexte externe
- **Question** : Le RAG améliore-t-il réellement le QA géographique ?

Objectif

Implémenter et évaluer un système QA géographique en configuration RAG, en comparant systématiquement Baseline et RAG.

Organisation du travail

Étape 1 – Plateforme de base

- 1 LLM (Qwen3-0.6B)
- 1 dataset (GeoSQA)
- 1 corpus (Wikipedia FR)
- Objectif : pipeline fonctionnel + baseline

Étape 2 – Exploration

- 4 LLMs exploitables (+1 incompatible)
- 3 datasets géographiques
- Analyse factorielle croisée
- Objectif : identifier les facteurs de performance

Environnement : Google Colab, GPU NVIDIA T4 (16 Go VRAM)

LLMs – Transformer


- Attention multi-têtes :
$$\text{Att}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$
- Génération autorégressive (décodeur)
- Capacités émergentes (CoT, in-context learning)

RAG naïf (Retrieve-then-Read)

- LLMs ne stockent pas toutes les connaissances factuelles
- RAG externalise la mémoire dans un corpus
- Injection directe des documents dans le prompt

QA géographique : raisonnement spatial + connaissances encyclopédiques. Aucun LLM actuel ne raisonne de manière fiable sur les directions cardinales $\Rightarrow$ intérêt du RAG.

Pipeline RAG – Vue d'ensemble



Composants clés

Retriever

- **BGE-m3** (BAAI) – embeddings multilingues, 1024 dimensions
- **FAISS** IndexFlatIP – similarité cosinus
- Chunks de 512 car., overlap 50
- Top-K = 5 documents

Generator

- Prompt système : expert géographie
- Mode Baseline : pas de contexte
- Mode RAG : top-5 documents injectés
- Extraction regex de la lettre (A/B/C/D)

Evaluator

Génération : Accuracy MCQ, Exact Match, F1

Tourism-QA : Accuracy@1, F1 POI

Retrieval : Hit Rate@K, MRR@K

Prompt Baseline vs RAG

Mode Baseline (sans contexte)

system: *Tu es un expert en géographie.
Réponds uniquement avec la lettre correcte.*

user: *Question : {question}
Options : A) ... B) ... C) ... D) ...*

Mode RAG (avec contexte)

system: *Tu es un expert en géographie.
Réponds uniquement avec la lettre correcte.*

user: **Contexte : {top-5 documents}**
*Question : {question}
Options : A) ... B) ... C) ... D) ...*

La seule différence : l'injection des **top-5 documents** récupérés par le retriever.
Cela permet d'isoler précisément l'**effet du RAG** sur la performance.

Modèles évalués

Modèle	Famille	Taille	Statut
Qwen3-0.6B	Qwen (Alibaba)	0.6B	OK
Qwen3-1.7B	Qwen (Alibaba)	1.7B	OK
Llama-3.2-1B-Instruct	Llama (Meta)	1.0B	OK
Llama-3.2-3B-Instruct	Llama (Meta)	3.0B	OK
Minstral-3-3B-Instruct	Mistral	3.0B	Incompatible

Minstral-3-3B – Incompatibilité technique

Mistral3Config est une architecture vision-langage multimodale, incompatible avec AutoModelForCausalLM (modèles textuels).

Datasets géographiques

Dataset	N	Langue	Tâche	Corpus RAG
GeoSQA	200	ZH $\rightarrow$ EN	QCM	Wikipedia FR
GKMC	200	EN natif	QCM	Wikipedia FR
Tourism-QA	100	EN	Reco. POI	Reviews EN

GeoSQA

Raisonnement spatial, lycée
chinois, traduit EN

GKMC

Connaissances
encyclopédiques, nativement
EN

Tourism-QA

Recommandation de POI,
reviews utilisateurs


Étape 1 – Stabilité du prompt (Qwen3-0.6B, 50 questions)

Rang	Stratégie	Accuracy
1	P1 – Prompt basique (FR)	52.0 %
2	P4 – Few-Shot 2 exemples	38.0 %
2	P5 – Prompt basique (EN)	38.0 %
4	P2 – Expert contraint (FR)	30.0 %
5	P3 – Chain-of-Thought	20.0 %
<i>Seuil aléatoire</i>		25.0 %

- Écart de **32 points** entre P1 et P3 – forte sensibilité au prompt
- Le CoT dégrade sous le seuil aléatoire (20 %) – inefficace pour 0.6B
- **Prompt P2** retenu malgré un score inférieur : il impose la lettre seule en sortie, garantissant une extraction fiable par regex

Étape 1 – Baseline vs RAG (200 questions GeoSQA)

Métrique	Base.	RAG
Accuracy	0.245	0.270
F1 Score	0.030	0.011
Temps (s)	353.6	495.6
HR@5	–	0.080
MRR@5	–	0.053



- Accuracy : **+10.2 %** relatif (5 questions de plus sur 200)
- Mais F1 chute de **-61.7 %** (corpus FR → réponses en français)
- HR@5 = 8 % ⇒ **92 %** des requêtes sans document pertinent

Étape 1 – Biais de position et analyse qualitative

Biais de position (Baseline)

Lettre	N prédictions	%
A	123	61.5 %
B	8	4.0 %
C	10	5.0 %
D	59	29.5 %
<i>Attendu</i>	50	25.0 %

Le modèle 0.6B se rabat sur la première option par défaut.

Répartition qualitative (200 q.)

Catégorie	%
Double échec	68.5 %
Les deux corrects	20.0 %
RAG sauve	7.0 %
RAG trompe	4.5 %

Le double échec domine : l'info est absente du corpus.


Étape 1 – Facteurs limitants identifiés

Facteur	Impact	Observation
Mismatch linguistique	Critique	Questions EN, corpus FR. HR@5 = 8 %
Couverture thématique	Important	Géo chinoise absente de Wikipedia FR
Taille du LLM	Important	0.6B $\approx$ seuil aléatoire (24.5 %)
Biais de position	Important	Lettre A prédite dans 61.5 % des cas

⇒ Ces facteurs motivent l'**étape 2** : modèles plus grands, datasets variés, corpus alignés.

GeoSQA – Raisonnement spatial (200 questions)

Modèle	Base.	RAG	Δ_{rel}
Qwen3-1.7B	0.390	0.335	-14.1 %
Qwen3-0.6B	0.275	0.260	-5.5 %
Llama-3.2-3B	0.270	0.230	-14.8 %
Llama-3.2-1B	0.275	0.205	-25.5 %




Constat

Le RAG dégrade **tous les modèles sans exception** sur GeoSQA.
HR@5 = 0.060 – le retriever ne trouve quasi rien (mismatch FR/EN).

GKMC – Connaissances encyclopédiques (200 questions)

Modèle	Base.	RAG	Δ_{rel}
Qwen3-1.7B	0.585	0.605	+3.4 %
Llama-3.2-3B	0.565	0.485	-14.2 %
Qwen3-0.6B	0.420	0.415	-1.2 %
Llama-3.2-1B	0.330	0.335	+1.5 %




Observations

- Qwen3-1.7B atteint **0.605** – meilleur score absolu du projet
- Llama-3.2-3B : forte dégradation malgré de bonnes connaissances internes
- Le contexte non pertinent déstabilise les modèles performants

Tourism-QA – Recommandation de POI (100 questions)

Modèle	Base.	RAG	Δ_{rel}
Qwen3-1.7B	0.590	0.590	0.0 %
Qwen3-0.6B	0.560	0.570	+1.8 %
Llama-3.2-3B	0.700	0.540	-22.9 %
Llama-3.2-1B	0.520	0.410	-21.2 %



Paradoxe Tourism-QA

- Hit Rate = **0.48** (×8 vs GeoSQA/GKMC) – le retriever fonctionne
- Pourtant, le RAG dégrade massivement les modèles Llama (-21 à -23 %)
- Les modèles Qwen résistent au contexte non pertinent

Tourism-QA – Exemples qualitatifs (Qwen3-0.6B)

Question	Baseline	RAG	Effet
Shopping femme Man- hattan pas cher	Pasquale Jones	Century 21	Correction
Restaurant Rome quar- tier Scalini	La Paila	La Pancia Fe- lice	Correction
Bar pour dîner 2 ^e Avenue NY	Vague	Mermaid Inn	Correction
Italian food New York	Le Gavroche	Quay Bar	Hallucination
Mariage Londres 5 ans	Le Gavroche	Petrus	Dégradation

- **Corrections** : le retriever récupère les reviews du bon POI
- **Dégradations** : reviews d'un autre POI → le modèle est induit en erreur

Validation du mismatch linguistique


Dataset	HR@5 corpus FR	HR@5 corpus EN	Facteur
GeoSQA	0.060	0.175	×2.9
GKMC	0.075	0.190	×2.5

Conclusion

- Le corpus EN multiplie le Hit Rate par **2.5 à 2.9**
- BGE-m3 encode correctement les questions – c'est le **corpus FR** qui est inadapté
- Mais sur GKMC, un meilleur retrieval ne suffit pas : les modèles possèdent déjà les connaissances en mémoire paramétrique

Facteur 1 – Taille du modèle

Fam.	Dataset	Petit	Grand	Δ_{rel}
Qwen	GeoSQA	0.260	0.335	+28.8 %
	GKMC	0.415	0.605	+45.8 %
	TourismQA	0.570	0.590	+3.5 %
Llama	GeoSQA	0.205	0.230	+12.2 %
	GKMC	0.335	0.485	+44.8 %
	TourismQA	0.410	0.540	+31.7 %




Résultat

La taille aide dans **6/6 configurations** sans exception, de +3.5 % à +45.8 %.

Facteur 2 – Famille de modèle


	GeoSQA	GKMC	Tourism
Qwen	0.298	0.510	0.580
Llama	0.218	0.410	0.475
Δ	+0.080	+0.100	+0.105

Avantage Qwen : **+0.095** en moyenne,
constant sur les 3 datasets.



Facteur 3 – Impact du RAG

Modèle	GeoSQA	GKMC	Tourism	Moy.
Qwen3-1.7B	-14.1	+3.4	0.0	-3.6
Llama-3.2-3B	-14.8	-14.2	-22.9	-17.3
Qwen3-0.6B	-5.5	-1.2	+1.8	-1.6
Llama-3.2-1B	-25.5	+1.5	-21.2	-15.0
Moy.	-15.0	-2.6	-10.6	-9.4



Constat central

$\bar{\Delta}_{rel} = -9.4\%$ – Le RAG naïf est **négatif en moyenne**.


3 cas positifs marginaux, 1 neutre, **8 dégradés** sur 12 configurations.

Classement global

#	Modèle	RAG Acc	Effic.
1	Qwen3-1.7B	0.510	0.300
2	Llama-3.2-3B	0.418	0.139
3	Qwen3-0.6B	0.415	0.692
4	Llama-3.2-1B	0.317	0.317

Effacité = RAG Acc / Taille (B)

Qwen3-0.6B : meilleur ratio qualité/taille



Pourquoi le RAG est-il inefficace ?

❶ Mismatch linguistique (facteur dominant)

- Corpus FR, questions EN $\Rightarrow$ $HR@5 = 0.060 - 0.075$
- Corpus EN valide l'hypothèse ($HR@5 \times 2.5$ à $\times 2.9$)

❷ Contexte non pertinent

- Documents hors sujet injectés $\Rightarrow$ détournement des connaissances internes
- Llama-Instruct particulièrement sensible (suit fidèlement le contexte fourni)

❸ Exception partielle Tourism-QA

- $HR = 0.48$ (corpus EN aligné) mais RAG toujours négatif en moyenne
- Qwen résiste, Llama chute (-21 à -23 %) $\Rightarrow$ différence architecturale

Limites de l'étude

- **4 modèles $\leq$ 3B** uniquement – les modèles 7B+ n'ont pas pu être chargés sur le GPU T4
- **Corpus monolingue FR** pour GeoSQA et GKMC – inadapté aux questions EN
- **RAG naïf** uniquement – pas de re-ranking, pas de réécriture de requête
- **200 questions** par dataset – variance d'échantillonnage possible
- **Minstral incompatible** – comparaison inter-familles limitée à Qwen vs Llama

Bilan synthétique

Constat	Valeur mesurée
Meilleur modèle global	Qwen3-1.7B (RAG Acc = 0.510)
Meilleure efficacité	Qwen3-0.6B (0.692 Acc/B)
Impact RAG moyen	$\bar{\Delta}_{rel} = -9.4 \%$ (négatif)
Taille aide (intra-famille)	6/6 configurations
Avantage Qwen vs Llama	+0.095 (constant)
HR@5 corpus FR	0.060 – 0.075
HR@5 corpus EN (Tourism)	0.48

Enseignements et perspectives

4 enseignements clés

- ❶ Le **RAG naïf dégrade** les performances en moyenne ($\Delta_{rel} = -9.4\%$)
- ❷ La **qualité du retrieval** est le facteur déterminant ($HR@5 = 0.06 \rightarrow 0.48$)
- ❸ La **famille** importe davantage que la taille seule (Qwen > Llama)
- ❹ **Qwen résiste mieux** au contexte non pertinent que Llama

Perspectives

- **Corpus multilingue** – éliminer le mismatch linguistique
- **RAG avancé** – re-ranking par cross-encoder, réécriture de requête
- **Modèles 7B+** en quantification 4-bit (QLoRA / bitsandbytes)
- **3^e famille** – Mistral-7B-Instruct-v0.3 (architecture compatible)

Merci de votre attention

Questions ?

Code source : <https://github.com/Hiba-Lmoudden/GeoR2LLMs>
Responsable : Lynda TAMINE-LECHANI (IRIT)