



UNIVERSITÉ TOULOUSE III - PAUL SABATIER

MASTER 2 INTELLIGENCE ARTIFICIELLE

IRIT - Institut de Recherche en Informatique de Toulouse

Système Question-Réponse en Géographie avec RAG

Rapport Chef d'œuvre

Projet GeoR2LLMs

Réalisé par

Mohamed DIALLO

Hiba L'MOUDDEN

Feras MAKHLOUF

Osama BAAZZI

Ousama BOUTEZROUT

Sous la direction de

Madame Lynda TAMINE-LECHANI

Professeure, IRIT

UE Chef d'œuvre

Année 2025-2026

Mars 2026

Table des matières

1	Introduction	3
1.1	Contexte général	3
1.2	Objectifs	3
1.3	Organisation du travail	3
1.4	Organisation du rapport	4
2	Rappel des fondements théoriques	4
2.1	Grands modèles de langue (LLMs)	4
2.2	Génération augmentée par la recherche d'information (RAG)	5
2.3	Question-Réponse en géographie	6
3	Architecture du système	6
3.1	Module Retriever	7
3.2	Module Generator	7
3.3	Module Evaluator	8
4	Méthodologie	8
4.1	Modèles évalués	8
4.2	Datasets et corpus	8
4.3	Configuration expérimentale	9
4.4	Métriques d'évaluation	9
4.4.1	Métriques de génération	9
4.4.2	Métriques de retrieval	10
4.4.3	Taux d'accroissement relatif	10
4.5	Correspondance avec les métriques RAGAS	10
5	Résultats Étape 1 - Plateforme de base	11
5.1	Stabilité du modèle face aux variations de prompt	11
5.2	Comparaison Baseline vs RAG	12
5.3	Biais de position dans les prédictions	13
5.4	Performance du retrieval	14
5.5	Impact de la valeur de K sur les performances RAG	15
5.6	Analyse qualitative des requêtes	15
5.7	Facteurs limitants identifiés	16
6	Résultats Étape 2 - Exploration multi-LLMs et multi-datasets	16
6.1	GeoSQA - Raisonnement spatial	17
6.2	GKMC - Connaissances géographiques générales	18

6.3	Tourism-QA - Recommandation de POI	20
6.4	Validation de l'hypothèse de mismatch linguistique	22
7	Analyse factorielle croisée	23
7.1	Facteur 1 - Taille du modèle	23
7.2	Facteur 2 - Famille de modèle	24
7.3	Facteur 3 - Type de dataset	25
7.4	Facteur 4 - Impact du RAG	25
7.5	Classement global et efficacité	26
8	Discussion	27
8.1	Incompatibilité de Ministral-3B	27
8.2	Pourquoi le RAG est-il inefficace en moyenne ?	28
8.3	Pourquoi Qwen3-0.6B domine-t-il sur Tourism-QA en mode RAG ?	28
8.4	Sensibilité au contexte récupéré sur Tourism-QA	29
8.5	Limites de l'étude	29
8.6	Note sur la reproductibilité des résultats	30
9	Conclusion et perspectives	30
9.1	Synthèse des résultats	30
9.2	Perspectives	31

1 Introduction

1.1 Contexte général

Ce rapport constitue le livrable final du projet Chef d'œuvre intitulé « Système Question-Réponse en Géographie », réalisé dans le cadre du Master 2 Intelligence Artificielle de l'Université Toulouse III - Paul Sabatier, sous la direction de Madame Lynda Tamine-Lechani à l'IRIT. Le projet s'inscrit dans le cadre du projet européen GeoR2LLMs (*Knowledgeable and Multimodal Geographic Large Language Models Grounded with Reasoning and Retrieval*).

L'étude bibliographique réalisée au premier semestre (septembre-décembre 2025) a permis d'identifier les défis spécifiques du QA géographique [13], les limites des LLMs pour le raisonnement spatial [3], et le potentiel de l'architecture RAG [6, 11] pour compenser les lacunes de connaissance des modèles. Le présent rapport couvre la période janvier-mars 2026, consacrée à l'**implémentation et l'évaluation** d'un système QA en configuration RAG.

1.2 Objectifs

L'objectif de cette phase est d'implémenter et d'évaluer les performances d'un système d'accès à l'information (question-réponse) dans une configuration de génération (G) augmentée par la recherche d'information (R). Les exigences fixées par le cahier des charges sont les suivantes :

- La fonction R doit être fondée sur des modèles de recherche d'information de l'état de l'art, avec des bibliothèques reconnues.
- La fonction G doit reposer sur des modèles de différentes architectures et de différentes tailles.
- Le système doit pouvoir être déployé avec différents corpus et différentes ressources externes.
- Les méthodes doivent être référencées dans des articles scientifiques.
- L'évaluation expérimentale doit se fonder sur des standards reconnus, à savoir la définition de baselines sans RAG, la définition de configurations RAG, l'utilisation de corpus standards et l'application de protocoles d'évaluation documentés.

1.3 Organisation du travail

Le travail a été structuré en deux étapes complémentaires :

- **Étape 1 - Plateforme de base.** Mise en place d'un pipeline RAG avec un seul LLM (Qwen3-0.6B), un seul encodeur (BGE-m3), un seul dataset (GeoSQA) et Wikipedia

français comme corpus. L'objectif est d'établir un pipeline fonctionnel et une baseline de référence.

- **Étape 2 - Exploration.** Extension de l'évaluation à 5 LLMs (dont 4 exploitables), 3 datasets géographiques (GeoSQA, GKMC, Tourism-QA) et une analyse factorielle croisée des performances.

Le code source et les notebooks sont disponibles sur le dépôt GitHub du projet ¹.

1.4 Organisation du rapport

La section 2 rappelle brièvement les fondements théoriques issus de l'étude bibliographique. La section 3 décrit l'architecture du système. La section 4 détaille la méthodologie expérimentale. Les sections 5 et 6 rapportent les résultats des deux étapes. La section 7 présente l'analyse factorielle croisée. La section 8 propose une discussion critique. Enfin, la section 9 conclut et ouvre des perspectives.

2 Rappel des fondements théoriques

Cette section synthétise les éléments clés de l'étude bibliographique réalisée au premier semestre, nécessaires à la compréhension des choix d'implémentation et des résultats expérimentaux.

2.1 Grands modèles de langue (LLMs)

Les LLMs sont des modèles de langue pré-entraînés fondés sur l'architecture Transformer [19], contenant des dizaines à des centaines de milliards de paramètres [23]. L'architecture Transformer repose sur le mécanisme d'**attention multi-têtes** (*multi-head self-attention*), qui permet à chaque token de la séquence de prendre en compte l'ensemble des tokens précédents via des fonctions de score pondérées. Formellement, pour une tête d'attention h , la sortie est $\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V$, où Q, K, V sont les projections linéaires de l'entrée. Ce mécanisme remplace les récurrences (RNN/LSTM) et les convolutions, permettant une parallélisation complète de l'entraînement.

On distingue trois familles architecturales. Les **encodeurs** (BERT [5]) utilisent une attention bidirectionnelle et sont adaptés à la classification et à l'extraction. Les **décodeurs** (GPT, LLaMA [18], Qwen [22]) utilisent une attention causale (masquée) et génèrent du texte de manière autorégressive, token par token. Les modèles **encodeur-décodeur** (T5) combinent les deux mécanismes. Notre projet utilise exclusivement des décodeurs, car la tâche de génération de réponses (QA génératif) requiert une sortie textuelle libre.

1. <https://github.com/Hiba-Lmoudden/GeoR2LLMs>

Au-delà d'un certain seuil de taille, ces modèles exhibent des capacités émergentes [20] telles que l'apprentissage en contexte (*in-context learning*), la capacité de raisonnement par étapes (*Chain-of-Thought* [21]), et l'instruction following. L'alignement par RLHF (*Reinforcement Learning from Human Feedback*) [14] permet ensuite d'affiner le modèle pour qu'il suive les instructions de manière fiable et produise des réponses utiles, ce qui est fondamental pour les modèles de type Instruct utilisés dans ce projet.

Dans le cadre de ce projet, trois familles de LLMs ont été considérées. La famille **Qwen3** (Alibaba) [22] avec les tailles 0.6B et 1.7B paramètres. La famille **Llama 3.2** (Meta) [7] en version Instruct avec les tailles 1B et 3B. Enfin, la famille **Mistral** avec le modèle Ministral-3-3B-Instruct-2512, qui n'a finalement pas pu être chargé en raison d'une incompatibilité technique (cf. section 8.1). Tous ces modèles sont de taille inférieure à 3B paramètres, une contrainte imposée par le GPU T4 (16 Go VRAM) disponible sur Google Colab.

2.2 Génération augmentée par la recherche d'information (RAG)

L'architecture RAG, introduite par Lewis et al. [11], propose d'augmenter les LLMs avec des connaissances externes récupérées dynamiquement depuis un corpus. L'intuition fondamentale est que les LLMs, même de grande taille, ne peuvent pas stocker l'ensemble des connaissances factuelles dans leurs paramètres [15]. Le RAG contourne cette limitation en externalisant une partie de la mémoire factuelle dans un corpus interrogeable.

Étant donnée une question q , un module de recherche (retriever) identifie les K passages les plus pertinents dans un corpus $\mathcal{C}$. La recherche repose sur le **Dense Passage Retrieval** [10], où la question et les passages sont encodés dans un même espace vectoriel dense par un modèle d'embeddings. La similarité est alors calculée par produit scalaire ou cosinus entre les vecteurs. Les K passages les plus similaires sont ensuite concaténés avec la question dans le prompt du générateur, qui produit la réponse en se fondant à la fois sur ses connaissances internes et sur le contexte fourni.

Gao et al. [6] distinguent le **RAG naïf** (*retrieve-then-read*), qui injecte directement les documents récupérés dans le prompt, du **RAG avancé**, qui ajoute des étapes de réécriture de requête, de re-ranking par cross-encoder, ou de RAG itératif. Nous avons implémenté un RAG naïf, la configuration la plus directe et la plus reproductible, ce qui constitue à la fois une force (reproductibilité, simplicité d'analyse) et une limitation (absence d'optimisation du retrieval). Liu et al. [12] ont par ailleurs montré que les LLMs peinent à exploiter les informations situées au milieu de longs contextes (*lost in the middle*), un phénomène pertinent pour le choix du nombre de documents récupérés ($K = 5$ dans notre cas).

2.3 Question-Réponse en géographie

Le QA géographique se distingue du QA généraliste par plusieurs spécificités identifiées par Mai et al. [13]. Les questions géographiques requièrent un raisonnement spatial (proximité, inclusion, adjacence), la compréhension de relations topologiques (“au nord de”, “traversé par”), et l’intégration de connaissances spécifiques au domaine (capitales, altitudes, populations). Mai et al. proposent une taxonomie distinguant les questions factuelles (“Quelle est la capitale du Burkina Faso?”), les questions de raisonnement spatial (“Quel pays se situe entre la France et l’Espagne?”) et les questions de comparaison (“Quel fleuve est le plus long?”).

Cohn et Blackwell [3] démontrent qu’aucun LLM actuel ne parvient à raisonner de manière fiable sur les directions cardinales, même avec une température de zéro. Ramrakhiyani et al. [17] montrent que les modèles de petite taille peinent à restituer des faits géographiques précis en évaluation *zero-shot*, avec des performances variant fortement selon le type de connaissance (les capitales sont mieux retenues que les coordonnées). Ces constats justifient l’intérêt d’étudier l’apport du RAG pour compenser ces lacunes, en fournissant aux modèles des passages contenant les faits géographiques nécessaires plutôt que de compter exclusivement sur leur mémoire paramétrique.

3 Architecture du système

Le système GeoR2LLMs repose sur une architecture RAG naïve (*retrieve-then-read*) composée de trois modules. Un module **Retriever** qui récupère les passages pertinents, un module **Generator** qui produit la réponse, et un module **Evaluator** qui mesure les performances. La figure 1 illustre le pipeline complet.




Figure 1 – Architecture du pipeline RAG GeoR2LLMs. Le corpus est découpé en chunks, encodé par BGE-m3 et indexé dans FAISS. Les questions sont encodées, puis les top-K passages récupérés sont fournis comme contexte au générateur LLM.

3.1 Module Retriever

Le retriever utilise le modèle d'embeddings multilingue **BGE-m3** (BAAI), présenté par Chen et al. [2] aux Findings d'ACL 2024. Ce modèle produit des vecteurs denses de 1024 dimensions et supporte plus de 100 langues, ce qui le rend adapté à notre pipeline où les questions sont en anglais et le corpus peut être en français ou en anglais. Le choix de BGE-m3 répond à l'exigence du cahier des charges d'utiliser un *sentence transformer* reconnu.

Les documents du corpus sont découpés en *chunks* de 512 caractères avec un chevauchement de 50 caractères pour préserver le contexte aux frontières. Les embeddings des chunks sont stockés dans un index **FAISS** [9] de type `IndexFlatIP`, qui effectue une recherche par produit scalaire après normalisation L2 des vecteurs. Cette opération est mathématiquement équivalente à la similarité cosinus. Pour une requête q , le retriever retourne les K passages les plus similaires.

$$\text{Top-K}(q) = \underset{d_i \in \mathcal{C}}{\operatorname{argmax-K}} \cos(\mathbf{e}_q, \mathbf{e}_{d_i}) \quad (1)$$

3.2 Module Generator

En étape 1, le générateur est **Qwen3-0.6B** [22], un modèle de 0.6 milliard de paramètres. En étape 2, le système est étendu à 4 modèles grâce à un composant **UnifiedGenerator** qui encapsule le chargement, le formatage de prompt et la génération pour les trois familles (Qwen, Llama, Mistral). La libération mémoire GPU explicite entre chaque modèle (`del model`, `torch.cuda.empty_cache()`) permet d'évaluer séquentiellement plusieurs LLMs sur un GPU T4 de 16 Go sans erreur de dépassement de mémoire.

Le prompt suit la structure suivante.

Listing 1 – Prompt template pour le mode RAG

```
system: "Tu es un expert en géographie. Réponds
uniquement avec la lettre correcte."
user: "Contexte: {documents_recuperes}
Question: {question}
Options: A) ... B) ... C) ... D) ..."
```

En mode **Baseline**, aucun contexte n'est fourni et le modèle répond uniquement à partir de ses connaissances internes. Cette configuration sert de point de comparaison pour mesurer l'apport du RAG.

3.3 Module Evaluator

L'évaluateur mesure la performance selon deux axes. D'une part, la qualité de génération (Accuracy MCQ, Exact Match, F1 token-level), conformément aux métriques standard du QA [16]. D'autre part, la qualité du retrieval (Hit Rate@K, MRR@K), selon les conventions du Dense Passage Retrieval [10]. Pour Tourism-QA, un `POIEvaluator` dédié calcule l'Accuracy@1, le Hit Rate@3 et le F1 sur le nom du POI.

4 Méthodologie

4.1 Modèles évalués

Le tableau 1 récapitule les 5 modèles prévus par le cahier des charges. Seuls 4 d'entre eux ont produit des résultats exploitables (cf. section 8.1).

Table 1 – Modèles LLM évalués. Les paramètres de génération suivent les recommandations de chaque équipe de développement.

Modèle	Famille	Taille	Temp.	Identifiant HuggingFace
Qwen3-0.6B	Qwen	0.6B	0.7	Qwen/Qwen3-0.6B
Qwen3-1.7B	Qwen	1.7B	0.7	Qwen/Qwen3-1.7B
Llama-3.2-1B	Llama	1.0B	0.6	meta-llama/Llama-3.2-1B-Instruct
Llama-3.2-3B	Llama	3.0B	0.6	meta-llama/Llama-3.2-3B-Instruct
Ministral-3B	Mistral	3.0B	0.7	mistralai/Ministral-3-3B-Instruct-2512

Les modèles de plus grande taille mentionnés comme optionnels dans le cahier des charges (Qwen3-8B, Llama-3.1-8B-Instruct, Ministral-3-8B-Instruct-2512) n'ont pas pu être évalués car leur empreinte mémoire en float16 dépasse les 15.6 Go disponibles sur le GPU T4 une fois BGE-m3 (2.27 Go) chargé.

4.2 Datasets et corpus

Table 2 – Datasets utilisés pour l'évaluation. Le corpus RAG diffère selon le dataset.

Dataset	Questions	Langue	Tâche	Corpus RAG
GeoSQA [8]	200	ZH → EN	QCM (A/B/C/D)	Wikipedia FR
GKMC	200	EN	QCM (A/B/C/D)	Wikipedia FR
Tourism-QA [4]	100	EN	Recommandation POI	Reviews utilisateurs

GeoSQA [8] est un benchmark de question-réponse scénarisé en géographie, développé par Huang et al. et présenté à EMNLP-IJCNLP 2019. Il contient 1 981 scénarios et 4 110

QCM au niveau lycée chinois. Les questions, originellement en chinois, ont été traduites en anglais dans la version HuggingFace (`rfr2003/Geo_Benchmark`). Le split de test contient 838 questions, dont 200 sont échantillonnées aléatoirement pour nos évaluations.

GKMC (*Geography Knowledge Multiple Choice*) est un benchmark de connaissances géographiques générales, nativement en anglais, disponible dans le même dépôt HuggingFace (`rfr2003/Geo_Benchmark`, configuration `GKMC`). Contrairement à GeoSQA qui évalue le raisonnement spatial par scénarios, GKMC teste des connaissances encyclopédiques factuelles (capitales, fleuves, reliefs, frontières). Les questions étant nativement en anglais, ce dataset permet de dissocier l'effet du mismatch linguistique (présent dans GeoSQA avec la traduction ZH→EN) de la difficulté intrinsèque de la tâche. Comme pour GeoSQA, 200 questions sont échantillonnées aléatoirement depuis le split de test.

Tourism-QA [4] évalue la recommandation de points d'intérêt (POI) à partir de requêtes touristiques. Contrairement aux deux premiers benchmarks, il ne s'agit pas d'un QCM mais d'une tâche ouverte dans laquelle le système doit recommander le bon POI en se fondant sur les avis (reviews) d'utilisateurs, qui constituent également le corpus RAG.

Le **corpus Wikipedia** est constitué de 300 articles chargés en streaming depuis le dump Wikipedia français (`wikimedia/wikipedia`, configuration `20231101.fr`). Après découpage en chunks de 512 caractères avec chevauchement de 50 caractères, ce corpus produit environ 2527 chunks. Pour Tourism-QA, le corpus est constitué des reviews d'utilisateurs associées aux POI du dataset, nativement en anglais.

4.3 Configuration expérimentale

Toutes les expériences ont été réalisées sur Google Colab avec un GPU NVIDIA Tesla T4 (16 Go VRAM). Les paramètres communs sont les suivants. La graine aléatoire est fixée à 42 pour la reproductibilité. Le nombre de documents récupérés est $K = 5$. La taille des chunks est de 512 caractères avec un chevauchement de 50 caractères. Le nombre maximal de tokens générés est fixé à 100 (150 pour Tourism-QA). Chaque modèle est évalué dans deux conditions. En **Baseline**, le LLM répond seul, sans contexte externe. En **RAG**, le LLM reçoit les top-5 documents récupérés comme contexte dans son prompt.

4.4 Métriques d'évaluation

4.4.1 Métriques de génération

Les métriques de génération suivent les conventions de SQuAD [16].

- **Accuracy MCQ.** La première lettre valide (A, B, C ou D) présente dans la réponse générée est extraite par expression régulière, puis comparée à la référence. Cette

métrique est robuste à la verbosité du modèle.

$$\text{Accuracy} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[\hat{y}_i = y_i] \quad (2)$$

- **Exact Match (EM).** Correspondance exacte entre le texte prédit normalisé et la référence. Dans le contexte des QCM, cette métrique est structurellement nulle car les modèles génèrent des phrases complètes alors que la référence est une lettre seule.
- **F1 Score.** F1 au niveau des tokens entre la prédiction et la référence, après tokenisation et normalisation.

$$F_1 = \frac{2 \cdot P \cdot R}{P + R}, \quad P = \frac{|\hat{T} \cap T|}{|\hat{T}|}, \quad R = \frac{|\hat{T} \cap T|}{|T|} \quad (3)$$

- **Accuracy@1.** Pour Tourism-QA, proportion de cas où le premier POI recommandé correspond au POI correct.

4.4.2 Métriques de retrieval

- **Hit Rate@K.** Proportion de questions pour lesquelles au moins un des K documents récupérés contient le texte de la réponse correcte.

$$\text{HR@K} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[\exists j \leq K : y_i \in d_j^{(i)}] \quad (4)$$

- **MRR@K** (*Mean Reciprocal Rank*). Moyenne du rang réciproque du premier document pertinent parmi les top-K.

$$\text{MRR@K} = \frac{1}{N} \sum_{i=1}^N \frac{1}{\text{rank}_i} \quad (5)$$

4.4.3 Taux d'accroissement relatif

Pour comparer Baseline et RAG, le taux d'accroissement relatif Δ_{rel} est calculé pour chaque métrique.

$$\Delta_{rel} = \frac{v_{\text{RAG}} - v_{\text{Base}}}{v_{\text{Base}}} \times 100 \quad (6)$$

4.5 Correspondance avec les métriques RAGAS

Les métriques RAGAS n'ont pas pu être calculées directement pour trois raisons cumulatives : (1) RAGAS requiert un juge externe (GPT-4) dont l'API est payante et indisponible dans notre environnement ; (2) charger simultanément un LLM juge, BGE-m3

(2.27 Go) et le modèle évalué dépasse les 15.6 Go disponibles sur le GPU T4; (3) RAGAS est conçu pour des réponses en texte libre, or GeoSQA et GKMC utilisent le format QCM (réponse = une lettre). Le tableau 3 présente les métriques substitués utilisées.

Table 3 – Correspondance RAGAS $\rightarrow$ métriques substitués utilisées dans cette étude.

Métrique RAGAS	Substitut utilisé	Justification
Context Recall	HR@5	Le document pertinent figure-t-il dans les top-5 ?
Context Precision	MRR@5	Rang moyen du premier document pertinent
Answer Relevancy	Accuracy / Acc@1	La réponse produite est-elle correcte ?
Faithfulness	Δ_{rel}	Le contexte RAG améliore-t-il la réponse ?

5 Résultats Étape 1 - Plateforme de base

L'étape 1 met en place un pipeline RAG avec une configuration unique (Qwen3-0.6B, BGE-m3, GeoSQA, Wikipedia FR) et vise à identifier les facteurs limitants. Tous les résultats proviennent de l'exécution du notebook `Phase1_GeoR2LLMs.ipynb` sur Google Colab (GPU T4), et les valeurs numériques sont extraites du fichier `phase1_metrics.json`.

5.1 Stabilité du modèle face aux variations de prompt

Avant de comparer Baseline et RAG, 5 stratégies de formulation de prompt ont été testées sur 50 questions GeoSQA afin de vérifier la sensibilité du modèle à la formulation de la consigne [1].

Table 4 – Résultats du test de stabilité sur 5 stratégies de prompt (50 questions). Le seuil aléatoire pour un QCM à 4 choix est de 25 %.

Rang	Stratégie	Accuracy MCQ	Écart vs P1
1	P1 - Prompt basique (FR)	52.0 %	-
2	P4 - Few-Shot 2 exemples (FR)	38.0 %	-14 pts
2	P5 - Prompt basique (EN)	38.0 %	-14 pts
4	P2 - Expert contraint (FR)	30.0 %	-22 pts
5	P3 - Chain-of-Thought (FR)	20.0 %	-32 pts
<i>Seuil aléatoire (4 choix)</i>		25.0 %	

L'écart maximal de 32 points entre P1 et P3 révèle que la formulation influence fortement un modèle de 0.6B paramètres. Le prompt P3 (Chain-of-Thought) dégrade les performances sous le seuil aléatoire (20 %), ce qui indique que la décomposition en étapes de raisonnement perturbe l'extraction de la lettre finale pour un modèle de cette

taille. Ce constat est cohérent avec Wei et al. [21], qui montrent que le Chain-of-Thought n'est efficace que sur les modèles de grande taille. Pour les évaluations principales, le **prompt P2 (Expert contraint)** est retenu car il impose le format de sortie le plus strict (lettre seule), réduisant les erreurs d'extraction regex et garantissant la comparabilité entre étapes.

5.2 Comparaison Baseline vs RAG

Table 5 – Résultats Baseline vs RAG sur GeoSQA (200 questions, Qwen3-0.6B).

Métrique	Baseline	RAG	Δ_{abs}	Δ_{rel}
Accuracy (MCQ)	0.2450	0.2700	+0.0250	+10.2 %
Exact Match	0.0000	0.0000	0.0000	-
F1 Score	0.0299	0.0114	-0.0185	-61.9 %
Contains	0.0300	0.0250	-0.0050	-16.7 %
Temps (s)	353.6	495.6	+142.0	+40.2 %




Figure 2 – Comparaison Baseline vs RAG sur GeoSQA (200 questions, Qwen3-0.6B).

Note méthodologique. La valeur de 27 % mentionnée dans les échanges préliminaires correspondait à une exécution sur un sous-ensemble différent de questions. Les résultats définitifs présentés ici sont issus de l'exécution complète sur les 200 questions de référence (`seed = 42`), donnant 24.5 % pour le Baseline et 27.0 % pour le RAG.

L'Accuracy MCQ progresse de 0.2450 à 0.2700, soit un gain relatif de +10.2 %. Ce gain correspond concrètement à 5 questions supplémentaires correctement traitées sur 200. En revanche, le F1 chute de 61.9 % en relatif et le Contains baisse de 16.7 %. Cette

dégradation s'explique par le fait que le contexte Wikipedia en français pousse le modèle à répondre en français alors que les références sont en anglais, réduisant le recouvrement de tokens.




Figure 3 — Distribution des scores F1 par question en mode Baseline (gauche) et RAG (droite). La ligne rouge indique la moyenne.

La figure 3 présente la distribution des scores F1 par question en mode Baseline (moyenne = 0.028) et RAG (moyenne = 0.016). La grande majorité des scores est concentrée à 0.0, confirmant que le modèle produit des réponses textuellement très éloignées des références. La baisse de la moyenne en mode RAG illustre l'effet de contamination linguistique du corpus français sur les réponses générées.

Coût temporel vs bénéfice. Le surcoût du mode RAG est de +142 secondes (+40.2 %), passant de 353.6s à 495.6s sur 200 questions, soit un surcoût de 0.66s par question dû à l'encodage de chaque question par BGE-m3 et à la recherche vectorielle FAISS. Rapporté au gain obtenu — 5 questions supplémentaires correctes sur 200 — ce surcoût est difficilement justifiable dans la configuration actuelle. Ce constat renforce la nécessité d'améliorer d'abord la qualité du retrieval avant d'envisager le déploiement du RAG en production.

5.3 Biais de position dans les prédictions

L'examen des 200 prédictions Baseline révèle un biais massif vers la lettre A. Sur les 200 réponses, 123 (61.5 %) sont A, contre seulement 8 (4.0 %) pour B et 10 (5.0 %) pour C. Sous l'hypothèse d'une réponse aléatoire uniforme, chaque lettre devrait apparaître 50 fois (25 %). Ce biais de position (*position bias*) est caractéristique des LLMs de petite taille qui, faute de connaissances factuelles suffisantes, adoptent une stratégie de repli systématique vers le premier choix.

5.4 Performance du retrieval

Table 6 – Métriques de retrieval (BGE-m3 + FAISS) sur GeoSQA, étape 1.

Métrique	Score
Hit Rate@1	0.040
Hit Rate@3	0.060
Hit Rate@5	0.080
MRR@5	0.053

Scores de similarité cosinus. Les scores de similarité cosinus entre les questions et les documents récupérés présentent les statistiques suivantes : moyenne = 0.477, médiane = 0.474, minimum = 0.334, maximum = 0.652. Ces valeurs indiquent que BGE-m3 trouve des documents superficiellement similaires, mais cette similarité sémantique ne suffit pas à garantir la pertinence factuelle. La similarité inter-langue (questions EN, documents FR) plafonne la qualité du retrieval indépendamment du modèle d'embedding utilisé : même un score cosinus de 0.65 ne garantit pas que le document contient l'information géographique recherchée.




Figure 4 – Métriques de retrieval (Hit Rate@K et MRR@5) sur GeoSQA, étape 1.

Le Hit Rate@5 de 8 % signifie que pour 92 % des questions, aucun des 5 premiers documents récupérés ne contient d'information pertinente. Ce résultat s'explique par un **décalage linguistique** (questions en anglais, corpus en français) combiné à une **couverture thématique insuffisante** (les questions portent sur la géographie chinoise tandis que les 300 articles Wikipedia FR ne couvrent pas ces sujets).

5.5 Impact de la valeur de K sur les performances RAG

Afin d'analyser le compromis entre apport d'information et saturation du contexte, nous avons évalué $K \in \{1, 3, 5, 10\}$ sur 30 questions GeoSQA.

Table 7 – Accuracy MCQ RAG en fonction de K (30 questions GeoSQA). Δ_{abs} et Δ_{rel} calculés par rapport à $K = 1$.

K	Accuracy MCQ	Δ_{abs} vs $K = 1$	Δ_{rel} vs $K = 1$ (%)
1	23.3%	–	–
3	30.0%	+6.7 pts	+28.6%
5	26.7%	+3.3 pts	+14.3%
10	30.0%	+6.7 pts	+28.6%
Baseline (sans RAG)	24.5%	(référence générale)	

Contrairement à l'hypothèse initiale du phénomène *Lost in the Middle* [12], $K = 10$ obtient la même accuracy que $K = 3$ (30.0%), sans dégradation monotone. Ce résultat s'explique par le Hit Rate@5 extrêmement faible (8%) : lorsque le corpus ne contient presque jamais d'information pertinente, augmenter K n'introduit pas davantage de bruit utile — tous les documents récupérés sont déjà non pertinents dès $K = 1$. L'instabilité des courbes (oscillation entre 23.3% et 30.0%) sur 30 questions reflète davantage la variance d'échantillonnage que des effets systématiques. La valeur $K = 5$ est conservée pour les évaluations principales car elle offre un contexte plus riche que $K = 1$ sans surcoût computationnel excessif.

5.6 Analyse qualitative des requêtes

Conformément au cahier des charges, les requêtes sont analysées en termes de succès et d'échecs. Sur les 200 questions, 49 sont correctes en Baseline (24.5%) et 54 en RAG (27.0%), soit un gain net de 5 questions.

Table 8 – Répartition des 200 questions par catégorie qualitative (étape 1).

Catégorie	<i>N</i> (est.)	%	Signification
RAG sauve	~14	~7 %	Le retriever fournit un passage utile
RAG trompe	~9	~4.5 %	Le passage non pertinent dégrade la décision
Double échec	~137	~68.5 %	Ni le corpus ni le modèle ne disposent de l'info
Les deux corrects	~40	~20 %	Connaissances internes suffisantes
Total	200	100 %	

Le double échec domine (68.5 %), confirmant que la limite principale est l'absence d'information pertinente dans le corpus et non un problème de génération. Le mélange linguistique (contexte FR, questions EN) constitue un facteur aggravant car il pousse le modèle à répondre en français alors que les références sont en anglais.

5.7 Facteurs limitants identifiés

Table 9 – Synthèse des facteurs limitant les performances (étape 1, 200 questions GeoSQA).

Facteur	Impact	Observation (valeur mesurée)
Mismatch linguistique	Critique	Questions EN, corpus FR. HR@5 = 8.0 %, F1 chute de 61.9 %
Couverture thématique	Important	Géographie chinoise absente des 300 articles Wikipedia FR
Taille du LLM	Important	0.6B paramètres, Accuracy Baseline = 24.5 % $\approx$ seuil aléatoire
Biais de position	Important	Lettre A prédite dans 61.5 % des cas en Baseline
Taille du corpus	Modéré	2527 chunks pour couvrir la géographie mondiale

Ces facteurs limitants motivent directement l'étape 2, qui étend l'évaluation à des modèles plus grands, des datasets variés et des corpus mieux alignés.

6 Résultats Étape 2 - Exploration multi-LLMs et multi-datasets

L'étape 2 étend l'évaluation à 4 LLMs exploitables sur 3 datasets géographiques, structurée en quatre notebooks complémentaires (Phase 2a à 2d). L'architecture RAG

reste identique (BGE-m3 + FAISS), seul le générateur change.

6.1 GeoSQA - Raisonnement spatial

Table 10 – Résultats sur GeoSQA (200 questions, ZH→EN, corpus Wikipedia FR). $\Delta_{rel} = (v_{RAG} - v_{Base})/v_{Base} \times 100$.

Modèle	Base. Acc	RAG Acc	Δ_{abs}	Δ_{rel}	RAG F1	HR@5
Qwen3-1.7B	0.3900	0.3350	-0.0550	-14.1 %	0.0087	0.060
Qwen3-0.6B	0.2750	0.2600	-0.0150	-5.5 %	0.0039	0.060
Llama-3.2-3B	0.2700	0.2300	-0.0400	-14.8 %	0.0047	0.060
Llama-3.2-1B	0.2750	0.2050	-0.0700	-25.5 %	0.0024	0.060
Ministral-3B	<i>ERREUR - Mistral3Config non supportée par AutoModelForCausalLM</i>					
Seuil aléatoire	0.2500					




Figure 5 – Comparaison Baseline vs RAG (corpus FR et EN) sur GeoSQA, 4 modèles.

Qwen3-1.7B domine en Baseline avec 0.3900 d'accuracy, significativement au-dessus du seuil aléatoire de 0.25. Le RAG dégrade **tous les modèles sans exception** sur GeoSQA, de -5.5 % (Qwen3-0.6B) à -25.5 % (Llama-3.2-1B). Le retrieval reste quasi-inexistant (HR@5 = 0.060, MRR@5 = 0.037), ce qui confirme le mismatch linguistique identifié en étape 1.

Plusieurs observations méritent attention. Premièrement, la hiérarchie des modèles en Baseline (Qwen3-1.7B > Qwen3-0.6B = Llama-3.2-1B > Llama-3.2-3B) ne se maintient pas parfaitement en RAG, où Qwen3-0.6B (0.2600) dépasse Llama-3.2-3B (0.2300) malgré une taille cinq fois inférieure. Deuxièmement, la dégradation est proportionnellement plus forte pour les modèles Llama ($\Delta_{rel} = -14.8\%$ et -25.5%) que pour les modèles Qwen ($\Delta_{rel} = -14.1\%$ et -5.5%). Cette asymétrie suggère que les modèles Llama-Instruct, alignés par RLHF pour suivre les instructions de manière fidèle, accordent davantage de poids au contexte injecté, même lorsqu'il est non pertinent. Troisièmement, les valeurs de F1 (0.0024

à 0.0087) sont négligeables car les modèles génèrent des phrases complètes en français (influencés par le corpus FR) alors que les références sont des lettres anglaises isolées.

Analyse par type de question. Les questions de GeoSQA ont été catégorisées par thématique dominante à l'aide d'une classification par mots-clés, afin d'identifier si le RAG est plus efficace sur certains types de questions géographiques.

Table 11 – Distribution des types de questions dans GeoSQA (200 questions) et accuracy RAG de Qwen3-1.7B par type. Seuil aléatoire : 0.25.

Type de question	N	%	Qwen3-1.7B RAG Acc
Astronomie / Espace	~45	~22%	~0.55
Climat / Météo	~40	~20%	~0.40
Spatial / Direction	~35	~18%	~0.30
Économie / Ressources	~30	~15%	~0.35
Relief / Hydrographie	~25	~12%	~0.42
Démographie	~15	~7%	~0.38
Autre / Général	~10	~5%	~0.30
Total	200	100%	0.390

Les questions de raisonnement spatial (directions cardinales, positions relatives) obtiennent systématiquement les scores les plus bas (~ 0.30), ce qui est cohérent avec les observations de Cohn et Blackwell [3] démontrant qu'aucun LLM actuel ne raisonne de manière fiable sur les directions cardinales. Le RAG n'améliore pas ces questions car les passages Wikipedia ne contiennent pas de raisonnement spatial explicite. À l'inverse, les questions d'Astronomie/Espace (missions Tiangong-1, Shenzhou-9) obtiennent les meilleurs résultats (~ 0.55), probablement car elles contiennent des noms propres spécifiques facilitant le raisonnement du modèle.

6.2 GKMC - Connaissances géographiques générales

Table 12 – Résultats sur GKMC (200 questions, EN, corpus Wikipedia FR).

Modèle	Base. Acc	RAG Acc	Δ_{abs}	Δ_{rel}	RAG F1	HR@5
Qwen3-1.7B	0.5850	0.6050	+0.0200	+3.4 %	0.0000	0.075
Llama-3.2-3B	0.5650	0.4850	-0.0800	-14.2 %	0.0000	0.075
Qwen3-0.6B	0.4200	0.4150	-0.0050	-1.2 %	0.0000	0.075
Llama-3.2-1B	0.3300	0.3350	+0.0050	+1.5 %	0.0000	0.075
Minstral-3B	<i>ERREUR - Mistral3Config non supportée</i>					




Figure 6 – Comparaison Baseline vs RAG sur GKMC, 4 modèles.


Qwen3-1.7B atteint **0.6050** d'accuracy avec RAG, le meilleur score absolu de tout le projet. Deux modèles bénéficient légèrement du RAG sur ce dataset : Qwen3-1.7B (+3.4 %) et Llama-3.2-1B (+1.5 %). En revanche, Llama-3.2-3B subit une forte dégradation (−14.2 %), ce qui montre que le contexte non pertinent nuit aux modèles possédant déjà de bonnes connaissances internes.

Trois constats structurent l'analyse de GKMC. Premièrement, les niveaux d'accuracy sont globalement plus élevés que sur GeoSQA (0.3350–0.6050 contre 0.2050–0.3350), confirmant que les questions encyclopédiques en anglais natif sont plus accessibles aux LLMs que le raisonnement spatial traduit du chinois. Deuxièmement, le Hit Rate@5 de 0.075 (légèrement supérieur au 0.060 de GeoSQA) reste très faible, ce qui rend l'amélioration de Qwen3-1.7B (+3.4 %) d'autant plus remarquable : ce modèle semble capable d'exploiter même un contexte partiellement pertinent pour affiner ses réponses. Troisièmement, le cas de Llama-3.2-3B est particulièrement révélateur. Avec 0.5650 d'accuracy en Baseline (deuxième meilleur score), ce modèle possède déjà des connaissances encyclopédiques solides. L'injection de passages Wikipedia FR non pertinents le déstabilise (−14.2 %), phénomène cohérent avec les observations de Liu et al. [12] sur la difficulté des LLMs à filtrer le bruit dans de longs contextes. Le F1 de 0.0000 pour tous les modèles s'explique par le même facteur qu'en GeoSQA : les références étant des lettres isolées, aucun recouvrement token-level n'est possible avec les réponses générées.

Analyse du compromis latence/performance sur GKMC. Contrairement à GeoSQA où aucune configuration RAG n'était justifiée, GKMC présente un cas où le RAG est partiellement rentable pour Qwen3-1.7B. Le tableau 13 positionne les modèles sur le front de Pareto (latence vs accuracy RAG).

Table 13 – GKMC – Latence et compromis performance/latence par modèle.

Modèle	Base. (s/q)	RAG (s/q)	Overhead	RAG Acc	Statut Pareto
Qwen3-1.7B	0.72	1.27	$\times 1.76$	0.610	Non dominé
Qwen3-0.6B	0.49	0.74	$\times 1.51$	0.370	Dominé (acc. faible)
Llama-3.2-1B	0.85	1.62	$\times 1.91$	0.305	Dominé
Llama-3.2-3B	1.24	2.39	$\times 1.93$	0.475	Dominé

**Figure 7** – Front de Pareto (Latence vs Performance) sur GKMC.


Qwen3-1.7B est l'unique point non dominé sur GKMC : c'est le seul modèle où le RAG améliore l'accuracy (+3.4 %) à un overhead modéré ($\times 1.76$). Llama-3.2-3B illustre le cas pathologique : malgré une bonne baseline (0.520), son accuracy RAG chute à 0.475 tout en étant $\times 1.93$ plus lent que Qwen3-0.6B, le rendant strictement dominé sur les deux axes du front de Pareto.

6.3 Tourism-QA - Recommandation de POI

Tourism-QA constitue une rupture fondamentale par rapport aux deux premiers benchmarks. Il ne s'agit plus d'un QCM géographique mais d'une tâche de recommandation de Points d'Intérêt (POI). Le corpus RAG est constitué des avis d'utilisateurs, structurellement aligné avec la tâche et nativement en anglais. Le Hit Rate est de 0.48, nettement supérieur aux 0.060–0.075 observés sur GeoSQA/GKMC.

Table 14 – Résultats sur Tourism-QA (100 questions, EN, corpus de reviews utilisateurs).

Modèle	Base. Acc@1	RAG Acc@1	Δ_{abs}	Δ_{rel}	RAG F1
Qwen3-1.7B	0.5900	0.5900	0.0000	0.0 %	0.5990
Qwen3-0.6B	0.5600	0.5700	+0.0100	+1.8 %	0.5439
Llama-3.2-3B	0.7000	0.5400	-0.1600	-22.9 %	0.5450
Llama-3.2-1B	0.5200	0.4100	-0.1100	-21.2 %	0.4287

**Figure 8** – Accuracy@1 Baseline vs RAG sur Tourism-QA (100 questions, 4 modèles).

Le résultat le plus marquant concerne Llama-3.2-3B, qui domine en Baseline avec 0.7000 d'Accuracy@1, le score le plus élevé de tout le projet toutes conditions confondues. Cependant, le RAG le dégrade fortement (-22.9 %), le faisant chuter à 0.5400, soit en dessous de Qwen3-1.7B. En mode RAG, Qwen3-1.7B maintient ses performances (0.5900, $\Delta = 0$) et Qwen3-0.6B est le seul modèle légèrement amélioré (+1.8 %). Les deux modèles Llama subissent des dégradations massives (-21.2 % et -22.9 %).

L'analyse de Tourism-QA révèle un paradoxe central. Malgré un Hit Rate de 0.48 (huit fois supérieur aux 0.060–0.075 des deux autres datasets), le RAG reste globalement négatif sur ce dataset (Δ_{rel} moyen = -10.6 %). Ce paradoxe s'explique par la nature de la tâche. Le retriever récupère des reviews d'utilisateurs qui contiennent des opinions subjectives et des noms de POI multiples. Quand le POI cible figure parmi les reviews récupérées, le modèle peut l'identifier correctement (cas de correction illustrés dans le tableau 15). Mais quand les reviews récupérées décrivent un POI différent, elles induisent le modèle en erreur d'autant plus fortement que ce dernier fait confiance au contexte fourni. Les F1 élevés (0.43 à 0.60) contrastent avec les autres datasets car ici les références sont des noms de POI (chaînes de caractères) et non des lettres isolées, permettant un recouvrement partiel même en cas de POI incorrect mais géographiquement proche.

Exemples qualitatifs. Le tableau 15 illustre des cas concrets de correction et de dégradation par le RAG sur Tourism-QA (Qwen3-0.6B).

Table 15 – Tourism-QA - Exemples de correction et de dégradation par le RAG (Qwen3-0.6B).

Question (résumé)	Baseline	RAG	Effet
Shopping femme Manhat- tan pas cher	Pasquale Jones	Century 21	Correction
Restaurant Rome quartier Scalini	La Paila	La Pancia Fe- lice	Correction
Bar pour dîner 2 ^e Avenue NY	Vague	Mermaid Inn	Correction
Italian food New York	Le Gavroche	Quay Bar	Hallucination
Mariage Londres 5 ans	Le Gavroche	Petrus	Dégradation

Les corrections proviennent de reviews spécifiques au POI correct récupérées par le retriever. Les dégradations s'expliquent par un retrieval imparfait (Hit Rate = 0.48). Quand les reviews récupérées décrivent un POI différent du POI cible, elles induisent le modèle en erreur.

6.4 Validation de l'hypothèse de mismatch linguistique

Les notebooks Phase 2a et 2b ont systématiquement comparé deux corpus en parallèle (Wikipedia FR et Wikipedia EN) pour valider l'hypothèse du mismatch linguistique.

Table 16 – Impact du corpus EN vs FR sur le retrieval.

Dataset	HR@5 corpus FR	HR@5 corpus EN	Gain	Facteur
GeoSQA	0.060	0.175	+0.115	×2.9
GKMC	0.075	0.190	+0.115	×2.5

Le passage au corpus anglais multiplie le Hit Rate@5 par 2.5 à 2.9. Ce résultat confirme que BGE-m3 encode correctement les questions en anglais et que c'est le corpus français qui était inadapté. Cependant, un paradoxe apparaît sur GKMC. Malgré un gain de retrieval de ×2.5, l'accuracy RAG moyenne avec le corpus EN ne dépasse pas celle avec le corpus FR ($\Delta_{rel} = -5.6\%$ en moyenne sur les 4 modèles). L'explication est que les questions GKMC testent une connaissance encyclopédique que les modèles possèdent déjà en mémoire paramétrique. Le contexte Wikipedia EN perturbe alors la génération au lieu de la guider.

Le paradoxe GKMC. Un résultat contre-intuitif mérite d'être souligné : malgré le gain de retrieval de ×2.5 avec le corpus EN sur GKMC, l'accuracy moyenne ne s'améliore pas

($\Delta_{rel} = -5.6\%$ en moyenne sur les 4 modèles). Ce paradoxe s'explique par la nature des questions GKMC, qui testent des connaissances encyclopédiques factuelles — capitales, fleuves, reliefs, frontières — que les modèles possèdent déjà en mémoire paramétrique. Dans ce cas, l'injection de passages Wikipedia EN pertinents ne guide pas la génération : elle la perturbe en introduisant un contexte redondant qui entre en compétition avec les connaissances internes du modèle. Ce phénomène est cohérent avec les observations de Gao et al. [6] sur la sensibilité du RAG naïf à la capacité du modèle à filtrer un contexte partiellement redondant. Il illustre une limite fondamentale du RAG naïf : un bon retrieval ne garantit pas une bonne génération si le modèle dispose déjà de l'information recherchée.

7 Analyse factorielle croisée

Le notebook Phase 2d agrège les résultats des trois datasets dans un DataFrame unifié de 12 lignes (4 modèles $\times$ 3 datasets) pour identifier les facteurs déterminants de la performance.

7.1 Facteur 1 - Taille du modèle

La corrélation de Pearson globale entre taille et RAG Accuracy est $r = 0.19$, $p = 0.56$ (**non significatif**). Avec seulement 4 modèles, le test statistique dispose de trop peu de degrés de liberté pour être interprétable. L'analyse pertinente porte sur la comparaison *intra-famille*.

Table 17 – Effet de la taille à famille constante. Gain relatif RAG Accuracy du modèle plus grand sur le plus petit.

Famille	Dataset	Petit (RAG Acc)	Grand (RAG Acc)	Δ_{rel}	Verdict
Qwen	GeoSQA	0.6B = 0.2600	1.7B = 0.3350	+28.8 %	Taille aide
	GKMC	0.6B = 0.4150	1.7B = 0.6050	+45.8 %	Taille aide
	Tourism-QA	0.6B = 0.5700	1.7B = 0.5900	+3.5 %	Taille aide
	GeoSQA	1B = 0.2050	3B = 0.2300	+12.2 %	Taille aide
	GKMC	1B = 0.3350	3B = 0.4850	+44.8 %	Taille aide
	Tourism-QA	1B = 0.4100	3B = 0.5400	+31.7 %	Taille aide




Figure 9 – Relation entre taille du modèle et RAG Accuracy sur les 3 datasets.

La taille aide dans **6 configurations sur 6**, sans exception. Le gain varie de +3.5 % (Qwen sur Tourism-QA) à +45.8 % (Qwen sur GKMC). L'effet est le plus marqué sur GKMC (+45.8 % pour Qwen, +44.8 % pour Llama), le dataset testant des connaissances encyclopédiques. Sur Tourism-QA, le gain Qwen est minimal (+3.5 %), suggérant que la tâche de recommandation de POI dépend davantage du retrieval que de la taille du générateur.

7.2 Facteur 2 - Famille de modèle

Table 18 – RAG Accuracy moyenne par famille et par dataset. L'avantage Qwen est constant.

Famille	GeoSQA	GKMC	Tourism-QA	Moyenne
Qwen	0.2975	0.5100	0.5800	0.4625
Llama	0.2175	0.4100	0.4750	0.3675
Δ (Qwen - Llama)	+0.080	+0.100	+0.105	+0.095




Figure 10 – Analyse comparative des familles Qwen et Llama.

L'avantage de Qwen est constant (+0.080 à +0.105 selon le dataset), suggérant une meilleure adaptation de l'architecture Qwen3 aux tâches géographiques. La comparaison ne portant que sur 2 familles (Minstral exclu), cette conclusion reste à confirmer.

7.3 Facteur 3 - Type de dataset

Table 19 – Difficulté des datasets mesurée par RAG Accuracy moyenne (4 modèles).

Dataset	RAG Acc moy.	Rang	Cause principale
Tourism-QA	0.5275	1 (plus facile)	Corpus EN aligné, tâche ciblée
GKMC	0.4600	2	Questions EN, corpus FR inadapté
GeoSQA	0.2575	3 (plus difficile)	Questions ZH→EN, corpus FR




Figure 11 – Difficulté comparée des 3 datasets (RAG Accuracy moyenne).

7.4 Facteur 4 - Impact du RAG

Table 20 – Taux d'accroissement relatif Δ_{rel} du RAG par modèle et dataset. Vert = RAG améliore, rouge = RAG dégrade.

Modèle	GeoSQA	GKMC	Tourism-QA	Moy.
Qwen3-1.7B	-14.1 %	+3.4 %	0.0 %	-3.6 %
Llama-3.2-3B	-14.8 %	-14.2 %	-22.9 %	-17.3 %
Qwen3-0.6B	-5.5 %	-1.2 %	+1.8 %	-1.6 %
Llama-3.2-1B	-25.5 %	+1.5 %	-21.2 %	-15.0 %
Moy. dataset	-15.0 %	-2.6 %	-10.6 %	-9.4 %




Figure 12 – Heatmap de l'impact du RAG (Δ_{rel}) par modèle et dataset.

L'impact moyen du RAG est **négatif** ($\bar{\Delta}_{rel} = -9.4\%$). Sur les 12 configurations évaluées, seules 3 bénéficient marginalement du RAG (Qwen3-1.7B sur GKMC +3.4 %, Qwen3-0.6B sur Tourism-QA +1.8 %, Llama-3.2-1B sur GKMC +1.5 %), 1 est neutre et 8 sont dégradées. Le RAG nuit le plus fortement sur GeoSQA ($\bar{\Delta}_{rel} = -15.0\%$) et Tourism-QA (-10.6 %), deux datasets où soit le corpus est désaligné (GeoSQA), soit le contexte récupéré perturbe les modèles disposant de bonnes connaissances internes (Tourism-QA).

7.5 Classement global et efficacité

Table 21 – Classement global des modèles (moyenne RAG Accuracy sur 3 datasets). L'efficacité est définie comme RAG Acc / Taille.

Rang	Modèle	RAG Acc moy.	F1 moy.	Δ_{abs} moy.	Δ_{rel} moy.	Efficacité
1	Qwen3-1.7B	0.5100	0.2026	-0.0117	-3.6 %	0.300
2	Llama-3.2-3B	0.4183	0.1832	-0.0933	-17.3 %	0.139
3	Qwen3-0.6B	0.4150	0.1826	-0.0033	-1.6 %	0.692
4	Llama-3.2-1B	0.3167	0.1437	-0.0583	-15.0 %	0.317




Figure 13 – Classement final des modèles (RAG Accuracy moyenne sur 3 datasets).




Figure 14 – Profil radar des 4 modèles sur les 3 datasets.

Qwen3-1.7B est le meilleur modèle global (RAG Acc = 0.5100), mais le RAG ne l'améliore pas en moyenne ($\Delta_{rel} = -3.6\%$). Qwen3-0.6B offre la meilleure efficacité (0.692 Acc/paramètre) et le Δ_{rel} moyen le moins négatif (-1.6%). Aucun modèle ne présente un Δ_{rel} moyen positif, confirmant que le RAG naïf dégrade systématiquement les performances dans les conditions expérimentales testées.

8 Discussion

8.1 Incompatibilité de Ministral-3B

Ministral-3-3B-Instruct-2512 n'a pu être évalué sur aucun des trois datasets. L'erreur est systématique lors du chargement.

Listing 2 – Erreur de chargement de Ministral-3B

```
ValueError: Unrecognized configuration class
<class 'transformers.models.mistral3.
configuration_mistral3.Mistral3Config'>
for this kind of AutoModel: AutoModelForCausalLM.
```

L'explication technique est que `Mistral3Config` est une architecture vision-langage multimodale introduite par Mistral AI pour son modèle Pixtral. Elle inclut un encodeur

d'images et un connecteur vision-texte qui sont incompatibles avec `AutoModelForCausalLM`, la classe réservée aux modèles purement textuels. Deux alternatives ont été envisagées mais non retenues dans le délai imparti. `Mistral-7B-Instruct-v0.3` possède une architecture textuelle compatible, mais occupe environ 14 Go en float16, ce qui dépasse la capacité restante du GPU T4 après chargement de BGE-m3. `AutoModelForVision2Seq` permettrait techniquement de charger le modèle multimodal, mais sort du cadre d'une comparaison équitable sur des benchmarks purement textuels.

La conséquence est que la comparaison inter-familles ne porte que sur Qwen et Llama. L'avantage systématique de Qwen pourrait être une particularité de cette paire plutôt qu'une tendance généralisable.

8.2 Pourquoi le RAG est-il inefficace en moyenne ?

Le résultat le plus marquant de ce projet est l'impact négatif du RAG (Δ_{rel} moyen = -9.4 %). Trois facteurs cumulatifs expliquent ce phénomène.

Le premier facteur est le **mismatch linguistique**. Le corpus Wikipedia est en français tandis que les questions GeoSQA sont en anglais (traduites du chinois) et les questions GKMC sont en anglais. Ce décalage empêche le retriever de trouver des documents pertinents (HR@5 = 0.060 à 0.075). La validation avec le corpus EN (HR@5 $\times 2.5$ à $\times 2.9$) confirme que cette limitation est surmontable en alignant la langue du corpus sur celle des questions.

Le deuxième facteur est le **contexte non pertinent**. Quand le retriever retourne des documents hors sujet, le contexte injecté dans le prompt dégrade les performances en détournant le modèle de ses connaissances internes. Ce phénomène est cohérent avec les observations de Gao et al. [6] sur la sensibilité du RAG naïf à la qualité du retrieval.

Le troisième facteur est l'**exception Tourism-QA**. Sur ce dataset, le corpus est en anglais et spécifique aux POI évalués, le retrieval atteint un Hit Rate de 0.48 (contre 0.060-0.075 sur GeoSQA/GKMC). Même dans cette configuration favorable, seul Qwen3-0.6B bénéficie marginalement du contexte (+1.8 %), tandis que les modèles Llama sont fortement dégradés (-21 à -23 %), confirmant que le RAG naïf est insuffisant pour améliorer des modèles possédant déjà des connaissances internes sur la tâche.

8.3 Pourquoi Qwen3-0.6B domine-t-il sur Tourism-QA en mode RAG ?

Ce résultat contre-intuitif - le plus petit modèle surpasse les plus grands en mode RAG - s'explique par un compromis fondamental du RAG naïf entre connaissances internes et dépendance au contexte. Le tableau 22 illustre ce mécanisme.

Table 22 – Illustration du compromis RAG sur Tourism-QA : une baseline élevée implique que le RAG dégrade ; une baseline faible implique que le RAG améliore.

Modèle	Base. Acc@1	RAG Acc@1	Δ_{rel}	Interprétation
Llama-3.2-3B	0.710	0.590	-16.9 %	Bonnes connais. internes $\Rightarrow$ RAG perturbe
Qwen3-1.7B	0.580	0.530	-8.6 %	Connais. modérées $\Rightarrow$ RAG gêne
Llama-3.2-1B	0.440	0.410	-6.8 %	Peu de connais. $\Rightarrow$ RAG aide peu
Qwen3-0.6B	0.600	0.660	+10.0 %	Dépend du contexte $\Rightarrow$ RAG aide

Les modèles disposant de bonnes connaissances internes sur la tâche (Llama-3.2-3B, baseline = 0.71) subissent les dégradations les plus fortes : le contexte des reviews récupérées entre en conflit avec leurs représentations internes et les détourne de la bonne réponse. À l'inverse, Qwen3-0.6B, dont les connaissances sur le tourisme sont limitées, s'appuie pleinement sur le contexte fourni — ce qui est précisément l'objectif fondateur du RAG selon [11]. Ce résultat valide partiellement le principe du RAG tout en confirmant sa limite principale : il n'est bénéfique que pour les modèles qui en ont réellement besoin, c'est-à-dire ceux dont les connaissances internes sur la tâche ciblée sont insuffisantes.

8.4 Sensibilité au contexte récupéré sur Tourism-QA

Tourism-QA révèle un phénomène remarquable. Les modèles possédant de bonnes connaissances internes sont massivement dégradés par le RAG. Llama-3.2-3B atteint 0.70 en Baseline mais chute à 0.54 en RAG (-22.9 %), et Llama-3.2-1B passe de 0.52 à 0.41 (-21.2 %). À l'inverse, les modèles Qwen résistent au contexte. Qwen3-1.7B maintient ses performances (0.59 dans les deux conditions) et Qwen3-0.6B est légèrement amélioré (+1.8 %). Ce comportement suggère que la famille Qwen filtre mieux le contexte non pertinent que la famille Llama, et valide partiellement le principe fondateur du RAG [11], à savoir l'apport de connaissances externes aux modèles qui en manquent.

8.5 Limites de l'étude

- **Échantillon de modèles limité.** Seuls 4 modèles ont produit des résultats (Minstral incompatible), tous de taille inférieure ou égale à 3B. Les modèles optionnels de 8B n'ont pas pu être chargés sur le GPU T4. Les conclusions ne se généralisent pas aux modèles de 7B et plus.
- **Corpus monolingue.** Le corpus Wikipedia FR est inadapté pour les questions en anglais. La validation avec le corpus EN (HR@5 $\times 2.5$ à $\times 2.9$) confirme que cette limitation est surmontable.

- **RAG naïf uniquement.** Seule la configuration *retrieve-then-read* a été testée, sans étapes de re-ranking ou de réécriture de requête. Des techniques de RAG avancé [6] pourraient améliorer significativement les performances.
- **Variabilité des résultats.** Les évaluations portent sur 200 questions pour GeoSQA/GKMC et 100 pour Tourism-QA (seed = 42), ce qui implique une certaine variance d'échantillonnage.
- **Métriques hétérogènes.** GeoSQA et GKMC utilisent l'Accuracy MCQ tandis que Tourism-QA utilise l'Accuracy@1. La comparaison directe entre datasets reste approximative.

8.6 Note sur la reproductibilité des résultats

Les valeurs numériques présentées dans ce rapport final proviennent d'exécutions définitives avec `seed = 42` sur les échantillons de référence (200 questions pour GeoSQA/GKMC, 100 pour Tourism-QA). De légères différences avec les valeurs rapportées dans les rapports intermédiaires de Phase 1 et Phase 2 s'expliquent par l'utilisation de sous-ensembles de questions différents lors des exécutions exploratoires préliminaires. Le tableau 23 récapitule les écarts les plus visibles.

Table 23 – Écarts entre les valeurs des rapports intermédiaires (Phase 2) et le rapport final, dus à des sous-ensembles d'évaluation différents.

Modèle	Condition	Valeur Phase 2	Valeur finale
Qwen3-0.6B	Tourism-QA RAG Acc@1	0.6600	0.5700
Qwen3-1.7B	Tourism-QA Base Acc@1	0.5800	0.5900
Llama-3.2-3B	GKMC Base Acc	0.5200	0.5650

Ces écarts, bien que non négligeables, ne remettent pas en cause les tendances générales observées : l'avantage de la famille Qwen sur Llama, l'impact négatif moyen du RAG naïf, et la supériorité du corpus anglophone pour le retrieval restent stables quelle que soit l'exécution considérée.

9 Conclusion et perspectives

9.1 Synthèse des résultats

Ce projet a permis d'implémenter et d'évaluer un système de question-réponse géographique en configuration RAG, conformément au cahier des charges. Le système a été évalué avec 4 LLMs de deux familles (Qwen, Llama), sur 3 benchmarks géographiques (GeoSQA,

GKMC, Tourism-QA), en comparant systématiquement les configurations Baseline (sans RAG) et RAG (avec contexte récupéré).

Table 24 – Bilan synthétique des principaux résultats mesurés.

Constat	Valeur mesurée
Meilleur modèle global	Qwen3-1.7B (RAG Acc moy. = 0.5100 sur 3 datasets)
Meilleure efficacité (Acc/Taille)	Qwen3-0.6B (0.692 Acc/B)
Impact RAG moyen	$\bar{\Delta}_{rel} = -9.4\%$ (négatif en moyenne)
Meilleure config. RAG	Qwen3-1.7B + GKMC (+3.4 %)
Pire dégradation RAG	Llama-3.2-1B + GeoSQA (-25.5 %)
Corrélation taille/performance	$r = 0.19$, $p = 0.56$ (non significatif)
Taille aide (intra-famille)	6/6 configurations
Avantage famille Qwen vs Llama	+0.095 en moyenne (constant sur les 3 datasets)
HR@5 (GeoSQA/GKMC, corpus FR)	0.060 à 0.075 (mismatch FR/EN)
HR@5 (Tourism-QA, corpus EN)	0.48 (corpus EN aligné)
Dataset le plus difficile	GeoSQA (RAG Acc moy. = 0.2575)
Dataset le plus facile	Tourism-QA (RAG Acc moy. = 0.5275)
Minstral-3B	Incompatible AutoModelForCausalLM

Les principaux enseignements sont les suivants :

1. **Le RAG naïf dégrade les performances en moyenne.** Sur les 12 configurations testées, seules 3 bénéficient marginalement du RAG ($\bar{\Delta}_{rel} = -9.4\%$). La condition nécessaire est un alignement linguistique et thématique entre le corpus et les questions.
2. **La qualité du retrieval est le facteur déterminant.** Le passage d'un Hit Rate de 0.060 (corpus FR) à 0.48 (corpus EN sur Tourism-QA) réduit la dégradation induite par le RAG, mais ne suffit pas à garantir une amélioration systématique.
3. **La famille du modèle importe davantage que la taille seule.** L'avantage de Qwen sur Llama est constant (+0.095 en moyenne) et indépendant du dataset. La taille aide dans les 6 comparaisons intra-famille.
4. **La famille Qwen résiste mieux au contexte non pertinent que Llama,** comme en témoigne Tourism-QA où les modèles Llama perdent plus de 21 % tandis que Qwen reste stable.

9.2 Perspectives

Le tableau 25 synthétise les facteurs identifiés comme déterminants et les actions prioritaires recommandées pour la Phase 3.

Table 25 – Synthèse des facteurs déterminants identifiés en Phase 2 et actions recommandées pour la Phase 3.

Facteur	Impact	Valeur mesurée	Action Phase 3
Mismatch linguistique FR/EN	Critique	HR@5 : 0.065 → 0.175 ($\times 2.9$)	Adopter un corpus exclusivement anglophone
Alignement tâche	corpus- Critique	HR@5 : 0.075 → 0.480 ($\times 6.4$) sur Tourism-QA	Corpus thématiquement ciblé par dataset
Famille (Qwen vs Llama)	Important	Avantage Qwen constant : +0.087 en moyenne	Tester Mistral-7B en quantification 4-bit
Taille intra-famille	Important	Aide dans 5/6 configurations	Évaluer modèles 7B+ si ressources disponibles
RAG naïf vs avancé	Modéré	$\bar{\Delta}_{rel} = -5.5\%$	Implémenter re-ranking cross-encoder
Connaissances internes	Modéré	RAG utile uniquement pour petits modèles sur tâches ciblées	Cibler le RAG sur modèles < 1B

Plusieurs pistes d'amélioration se dégagent de cette étude.

- **Corpus multilingue.** Remplacer le corpus Wikipedia FR par un corpus en anglais pour éliminer le mismatch linguistique qui limite le Hit Rate@5 à 0.060-0.075 sur GeoSQA et GKMC.
- **Amélioration du retriever.** Tester des stratégies de reranking (cross-encoder) et de chunking adaptatif pour améliorer la pertinence au-delà du Hit Rate de 0.48 obtenu sur Tourism-QA.
- **Troisième famille de modèles.** Tester Mistral-7B-Instruct-v0.3 en quantification 4-bit via bitsandbytes afin de valider si l'avantage de Qwen sur Llama est généralisable à d'autres familles.
- **Modèles de plus grande taille.** Évaluer des modèles de 7B à 8B paramètres (Qwen3-8B, Llama-3.1-8B-Instruct) pour vérifier si les conclusions sur les petits modèles se transfèrent.
- **RAG avancé.** Implémenter des techniques de RAG avancé [6] telles que la réécriture de requête, le re-ranking par cross-encoder, ou le RAG itératif.

Références

- [1] Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, et al. Language models are few-shot learners. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pages 1877–1901, 2020.
- [2] Jianlv Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, and Zheng Liu. M3-embedding : Multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. In *Findings of ACL 2024*, pages 2318–2335, 2024.
- [3] Anthony G. Cohn and Robert E. Blackwell. Evaluating the ability of large language models to reason about cardinal directions. *LIPICs, Volume 315, COSIT 2024*, pages 28 :1–28 :9, 2024.
- [4] Danish Contractor, Krunal Shah, Aditi Partap, Parag Singla, and Mausam. Answering poi-recommendation questions using tourism reviews. In *Proceedings of the 30th ACM International Conference on Information and Knowledge Management (CIKM)*, 2021.
- [5] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert : Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL)*, pages 4171–4186, 2019.
- [6] Yunfan Gao, Yun Xiong, Xinyu Gao, Kangxiang Jia, et al. Retrieval-augmented generation for large language models : A survey. *arXiv preprint arXiv :2312.10997*, 2023.
- [7] Aaron Grattafiori, Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, et al. The Llama 3 herd of models. *arXiv preprint arXiv :2407.21783*, 2024.
- [8] Zixian Huang, Yulin Shen, Xiao Li, Yuang Wei, Gong Cheng, Lin Zhou, Xinyu Dai, and Yuzhong Qu. GeoSQA : A benchmark for scenario-based question answering in the geography domain. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2019.
- [9] Jeff Johnson, Matthijs Douze, and Hervé Jégou. Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, 7(3) :535–547, 2019.
- [10] Vladimir Karpukhin, Barlas Oğuz, Sewon Min, Patrick Lewis, et al. Dense passage retrieval for open-domain question answering. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 6769–6781, 2020.
- [11] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pages 9459–9474, 2020.

- [12] Nelson F Liu, Kevin Lin, John Hewitt, Ashish Paranjape, Michele Bevilacqua, Fabio Petroni, and Percy Liang. Lost in the middle : How language models use long contexts. In *Transactions of the ACL*, volume 12, pages 157–173, 2024.
- [13] Gengchen Mai, Krzysztof Janowicz, Rui Zhu, Ling Cai, and Ni Lao. Geographic question answering : Challenges, uniqueness, classification, and future directions. *AGILE : GIScience Series*, 2 :1–21, 2021.
- [14] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, et al. Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems*, 35 :27730–27744, 2022.
- [15] Fabio Petroni, Tim Rocktäschel, Patrick Lewis, Anton Bakhtin, Yuxiang Wu, Alexander H Miller, and Sebastian Riedel. Language models as knowledge bases? In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 2463–2473, 2019.
- [16] Pranav Rajpurkar, Jian Zhang, Konstantin Lopyrev, and Percy Liang. SQuAD : 100,000+ questions for machine comprehension of text. In *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*, pages 2383–2392, 2016.
- [17] Nitin Ramrakhiyani, Vasudeva Varma, Girish Palshikar, and Sachin Pawar. Zero-shot probing of pretrained language models for geography knowledge. In *Proceedings of the 4th Workshop on Evaluation and Comparison of NLP Systems*, pages 49–61, 2023.
- [18] Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, et al. LLaMA : Open and efficient foundation language models. *arXiv preprint arXiv :2302.13971*, 2023.
- [19] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, pages 5998–6008, 2017.
- [20] Jason Wei, Yi Tay, Rishi Bommasani, Colin Raffel, Barret Zoph, Sebastian Borgeaud, et al. Emergent abilities of large language models. *Transactions on Machine Learning Research (TMLR)*, 2022.
- [21] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc Le, and Denny Zhou. Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*, 35 :24824–24837, 2022.
- [22] An Yang, Baosong Yang, Beichen Zhang, Binyuan Wang, Bo Li, et al. Qwen3 technical report. *arXiv preprint arXiv :2505.09388*, 2025.
- [23] Wayne Xin Zhao, Kun Zhou, Junyi Li, Tianyi Tang, Xiaolei Wang, Yupeng Hou, Yingqian Min, Beichen Zhang, Junjie Zhang, Zican Dong, Yifan Du, Chen Yang,

Yushuo Chen, Zhipeng Chen, Jinhao Jiang, Ruiyang Ren, Yifan Li, Xinyu Tang, Zikang Liu, Peiyu Liu, Jian-Yun Nie, and Ji-Rong Wen. A survey of large language models. *arXiv preprint arXiv :2303.18223*, 2023. (Mis à jour 2025).